分类集成问题中的多样性研究与应用

答辩: 卞一珺
(BA16011030)
导师: 陈欢欢 教授

计算机软件与理论
计算机科学与技术学院
中国科学技术大学

2020-08-26

大纲

1. 研究意义
2. 分类问题中集成器的多样性与泛化性能的关系
   - 集成器的误差分解及其多样性度量
   - 集成器的多样性与泛化性能的关系
   - 基于多样性的集成剪枝方法及框架
3. 基于信息熵的集成剪枝方法及其通用并行框架
   - 形式化集成剪枝任务为目标最大化问题
   - 集中式的基于目标最大化的集成剪枝算法
   - 分布式的基于目标最大化的集成剪枝算法
   - 可通用的分布式集成剪枝框架
4. 神经架构搜索中的集成子结构剪枝
   - 基准算法与问题定义
   - 神经架构搜索中的集成子结构剪枝
5. 总结与展望

大纲

1 研究意义
- 研究背景
- 研究内容

2 分类问题中集成器的多样性与泛化性能的关系

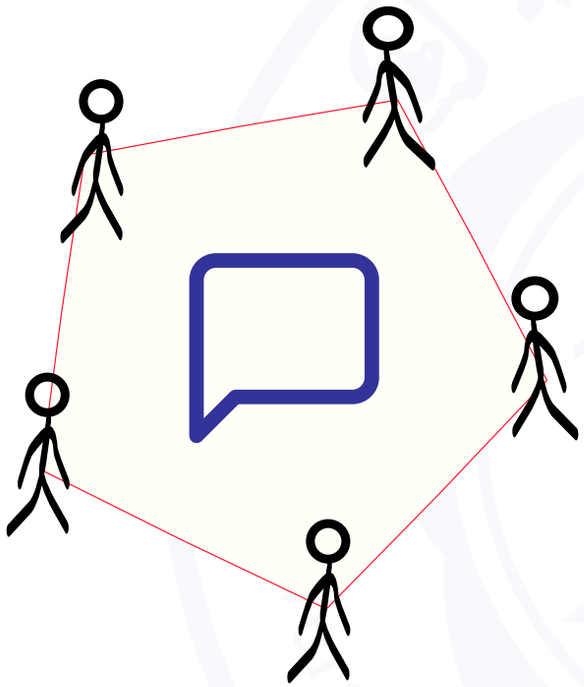
3 基于信息熵的集成剪枝方法及其通用并行框架

4 神经架构搜索中的集成子结构剪枝

5 总结与展望

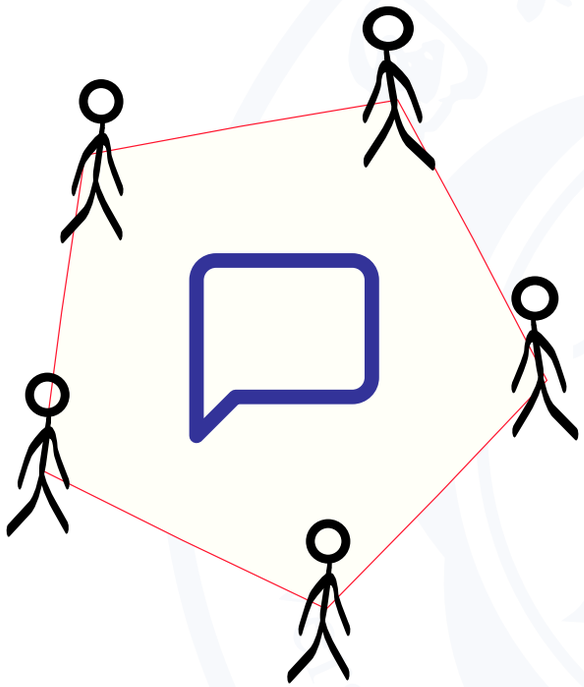
6 附录

例子



集思广益

例子

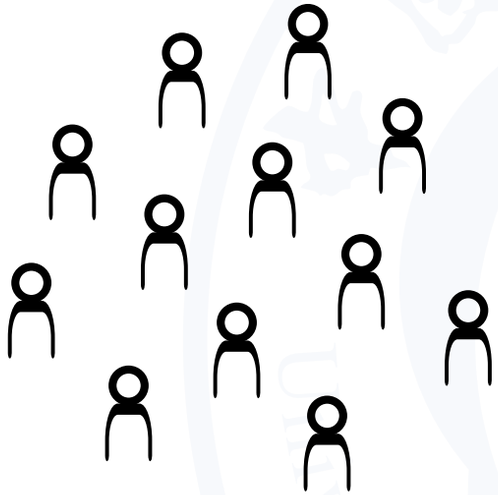


集思广益



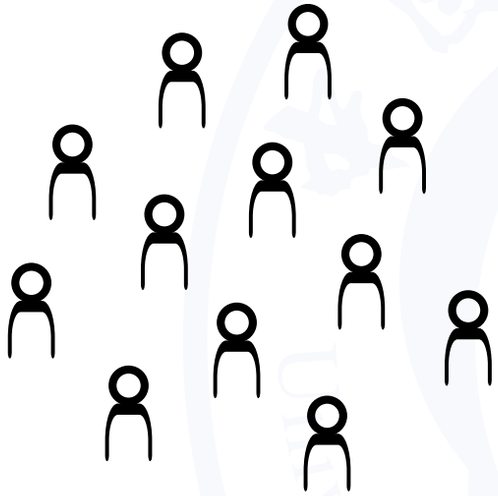
各奔东西

集成学习



集成学习
(ensemble learning)

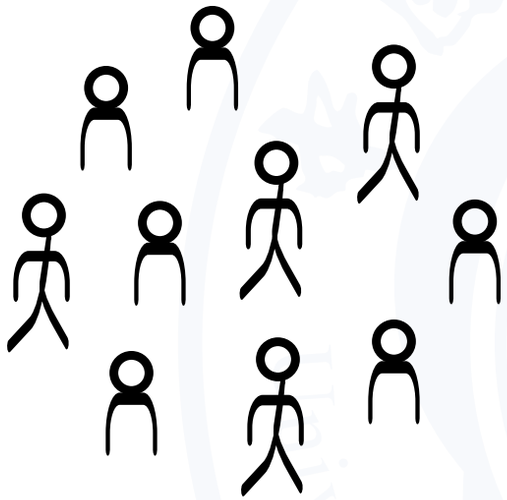
集成学习



集成学习
(ensemble learning)

- 应用
  情感分析、目标检测、目标识别、目标跟踪、图像检索、图像分类、基因函数预测和 RNA 拼接等

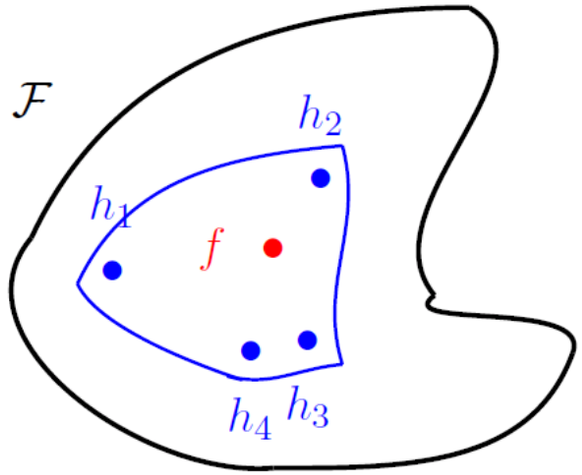
集成学习



集成学习
(ensemble learning)

- 应用
  情感分析、目标检测、目标识别、目标跟踪、图像检索、图像分类、基因函数预测和 RNA 拼接等
- 分类
  - 同质集成器
    (homogeneous ensembles)
  - 异质集成器
    (heterogeneous ensembles)

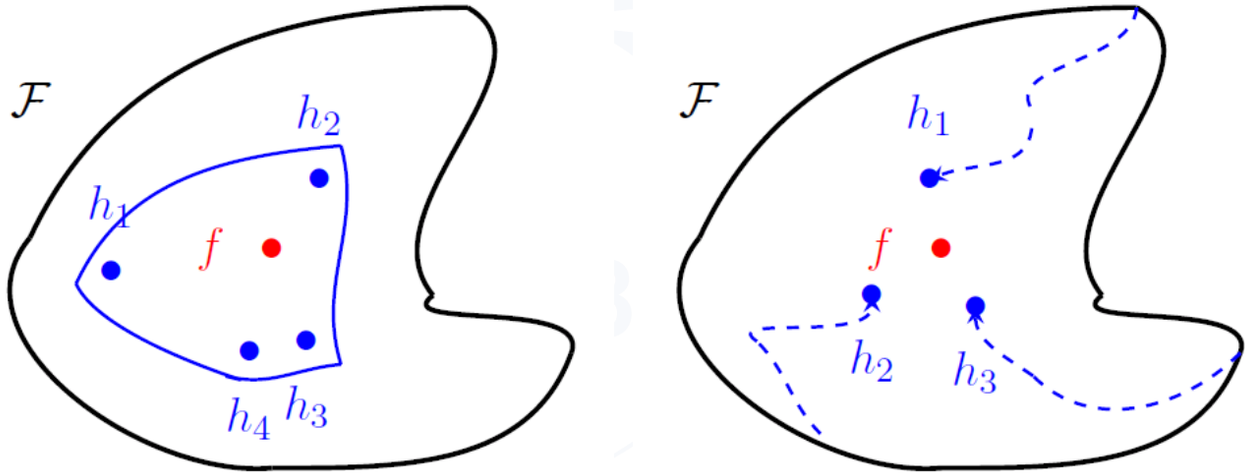
集成学习



(a) 统计角度

Figure 1: 集成器多优于单个分类器的三个根本原因 [1]

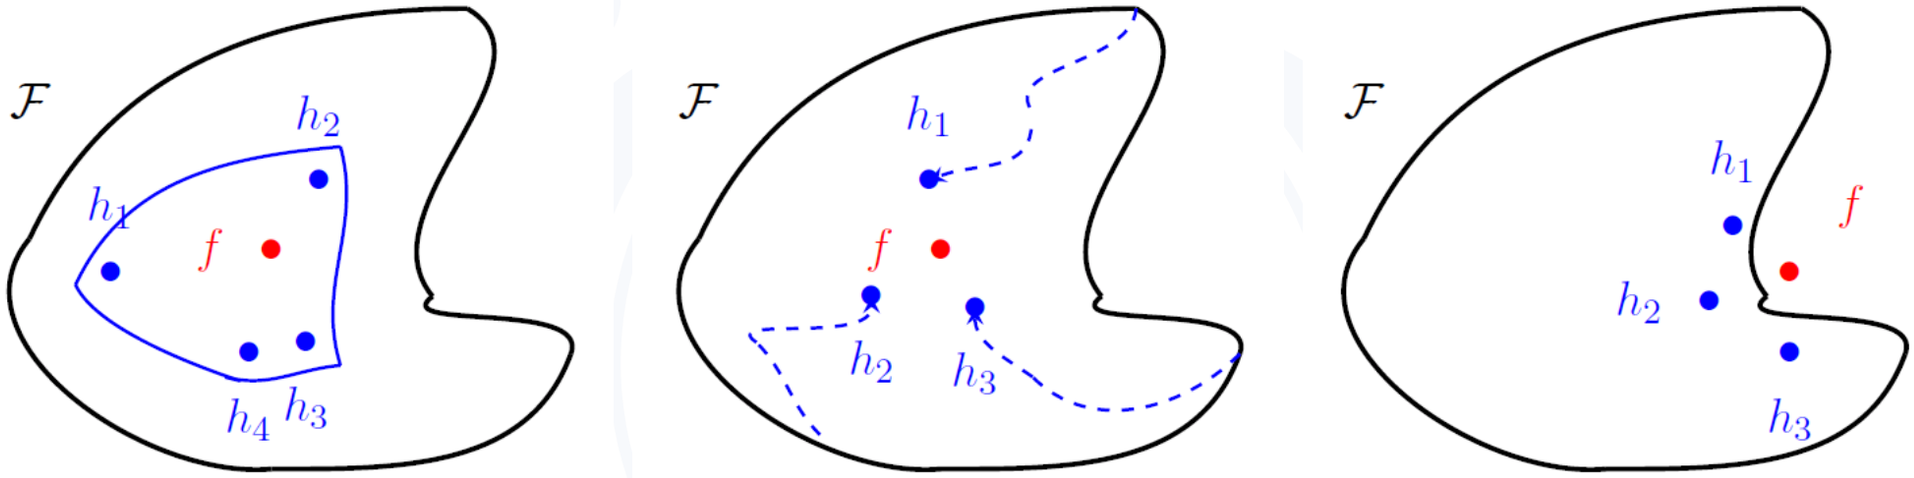
集成学习



(a) 统计角度　　(b) 计算角度

Figure 1: 集成器多优于单个分类器的三个根本原因 [1]

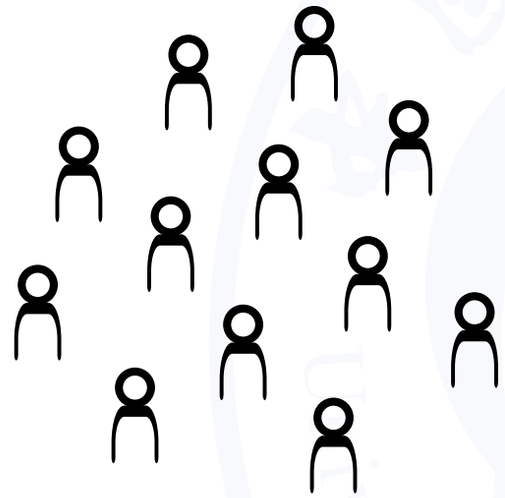
集成学习



(a) 统计角度　(b) 计算角度　(c) 可代表性角度

Figure 1: 集成器多优于单个分类器的三个根本原因 [1]

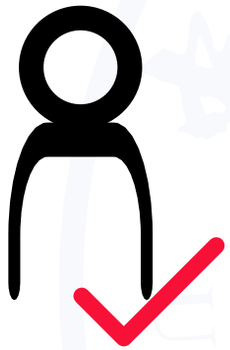
集成学习



集成学习
(ensemble learning)

- 要素

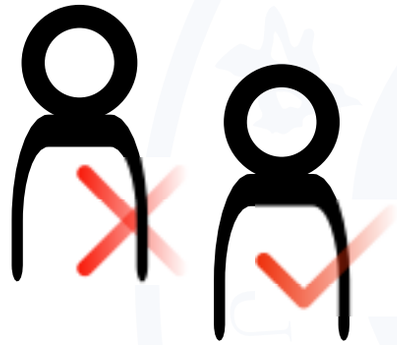
集成学习



集成学习
(ensemble learning)

- 要素
  - 准确 (accurate)

集成学习



集成学习
(ensemble learning)

- 要素
  - 准确 (accurate)
  - 多样 (diverse)

集成学习



集成学习
(ensemble learning)

- 要素
  - 准确 (accurate)
  - 多样 (diverse)
- 如何平衡?
  理解多样性

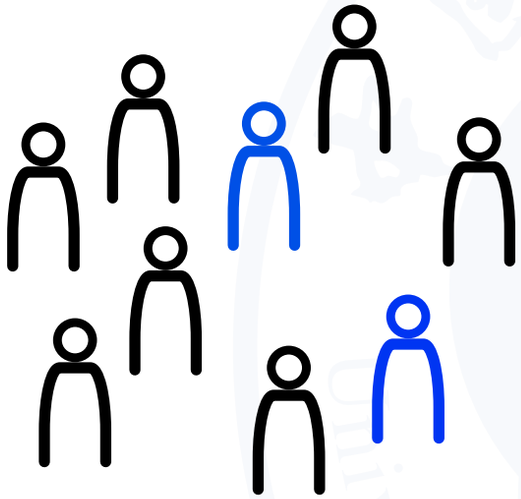
多样性



多样性
(diversity)

- 构造
  - 多样的基分类器
  - 隐式的，启发式的

多样性



多样性
(diversity)

- 构造
- 来源
  - 回归问题的误差分解

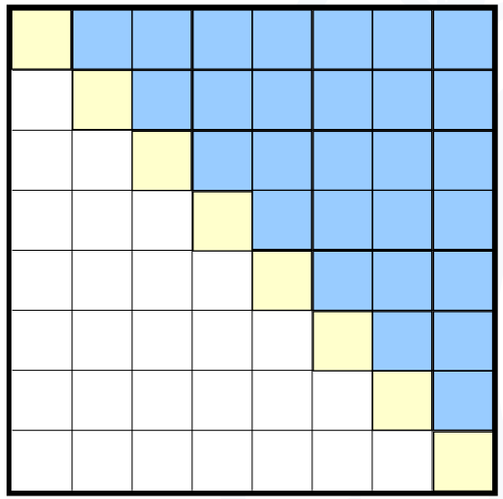
多样性



多样性
(diversity)

- 构造
- 来源
- 度量

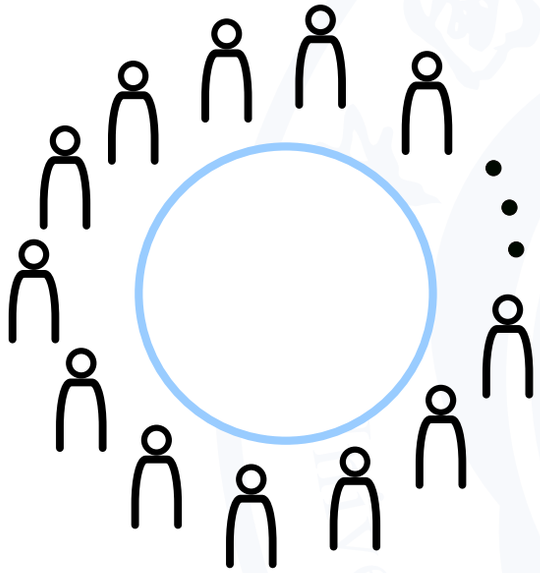
多样性



多样性
(diversity)

- 构造
- 来源
- 度量
  - 成对多样性度量

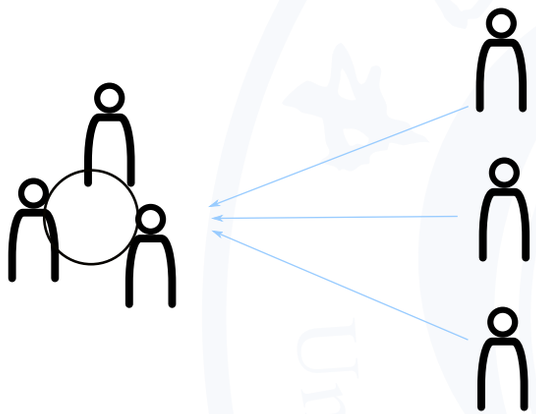
多样性



多样性
(diversity)

- 构造
- 来源
- 度量
  - 成对多样性度量
  - 非成对多样性度量

多样性



多样性
(diversity)

- 构造
- 来源
- 度量
  - 成对多样性度量
  - 非成对多样性度量
  - 相关惩罚函数、模糊项

多样性



多样性
(diversity)

- 构造
- 来源
- 度量
- 关系

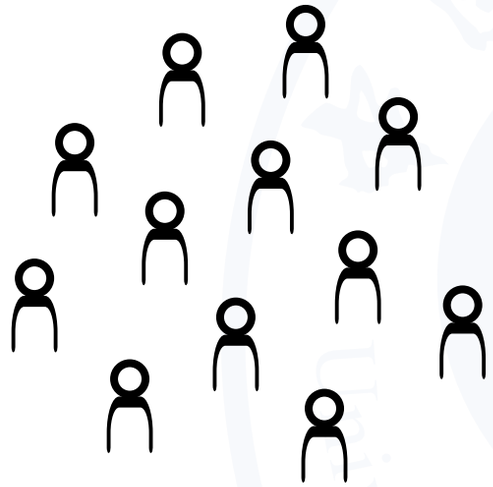
多样性



多样性
(diversity)

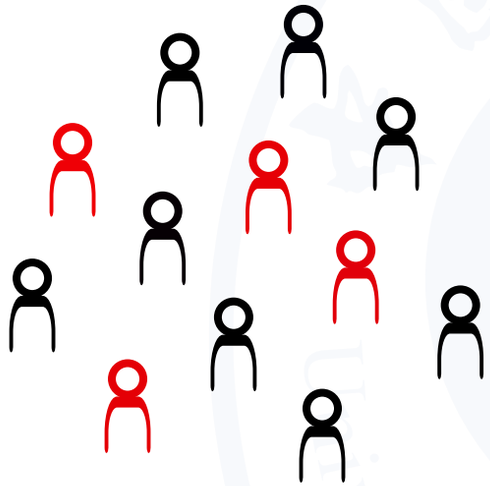
- 构造
- 来源
- 度量
- 关系
- 利用

集成剪枝



集成剪枝
(ensemble pruning)

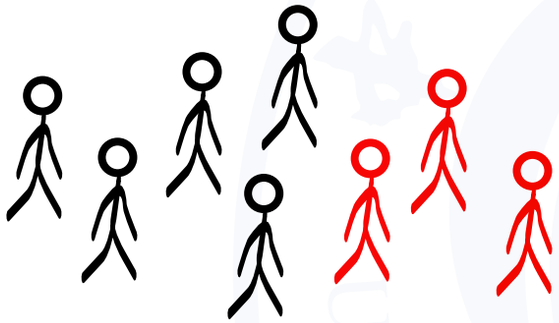
集成剪枝



集成剪枝
(ensemble pruning)

- 分类

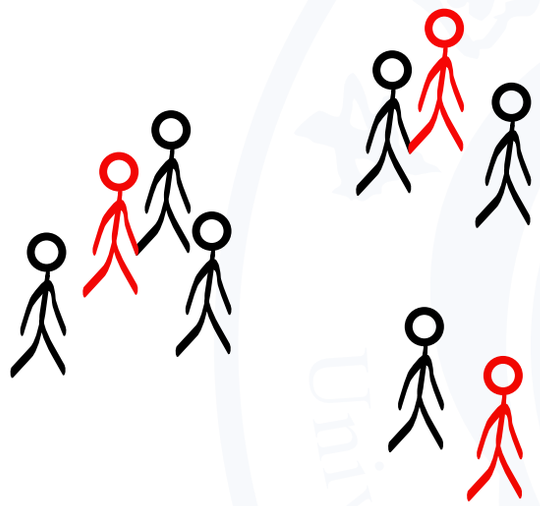
集成剪枝



集成剪枝
(ensemble pruning)

- 分类
  - 基于排序 (ranking-based)

集成剪枝



集成剪枝
(ensemble pruning)

- 分类
  - 基于排序 (ranking-based)
  - 基于聚类 (clusting-based)

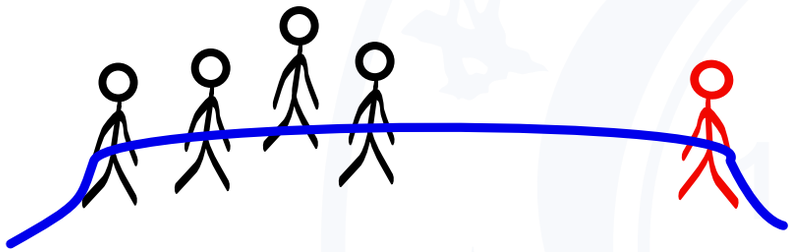
集成剪枝



集成剪枝
(ensemble pruning)

- 分类
  - 基于排序 (ranking-based)
  - 基于聚类 (clusting-based)
  - 基于优化 (optimization-based)

集成剪枝

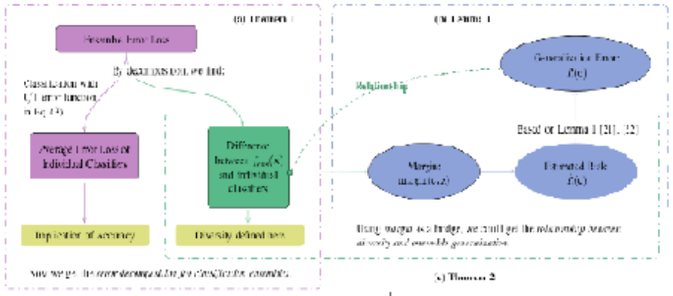
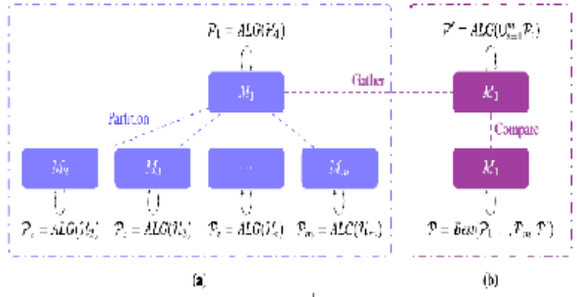
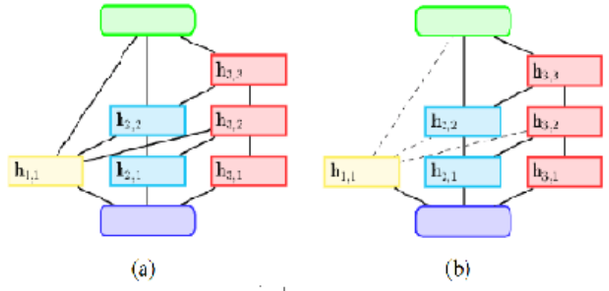


集成剪枝
(ensemble pruning)

- 分类
  - 基于排序 (ranking-based)
  - 基于聚类 (clusting-based)
  - 基于优化 (optimization-based)
- 集中式 (centralized)

研究整体框架

分类集成问题中的多样性研究与应用

	集成学习领域		其他领域
主要挑战	多样性在集成器中所起的作用不够明确	多样性与准确度因有所冲突而难以平衡	在利用集成学习的同时却忽视了多样性
出发点	探索多样性在集成学习中的作用	合理平衡二者并加速剪枝过程	弥补多样性的缺口研究
技术方案			
研究内容	分类集成问题中集成器的多样性与泛化性能的关系	基于信息熵的集成剪枝方法及其通用并行框架	神经架构搜索中的集成子结构剪枝

大纲

1 研究意义

2 分类问题中集成器的多样性与泛化性能的关系
- 背景意义
- 方法介绍
- 实验评估
- 本章小结

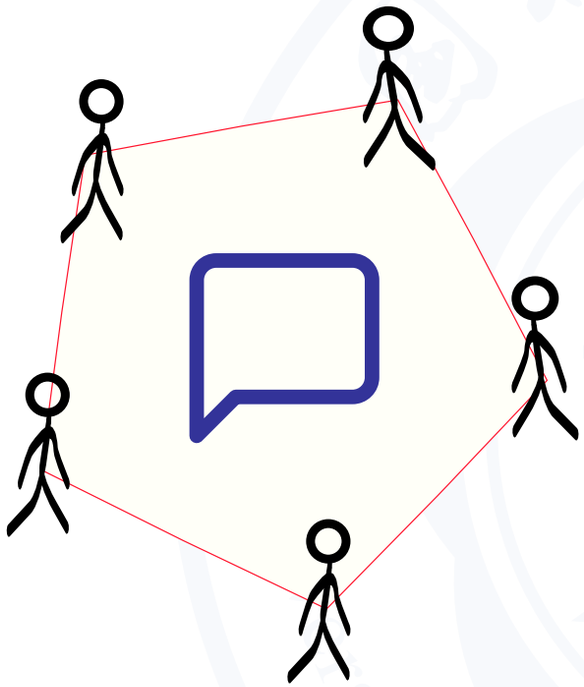
3 基于信息熵的集成剪枝方法及其通用并行框架

4 神经架构搜索中的集成子结构剪枝

5 总结与展望

6 附录

背景意义



集思广益



各奔东西

技术方案

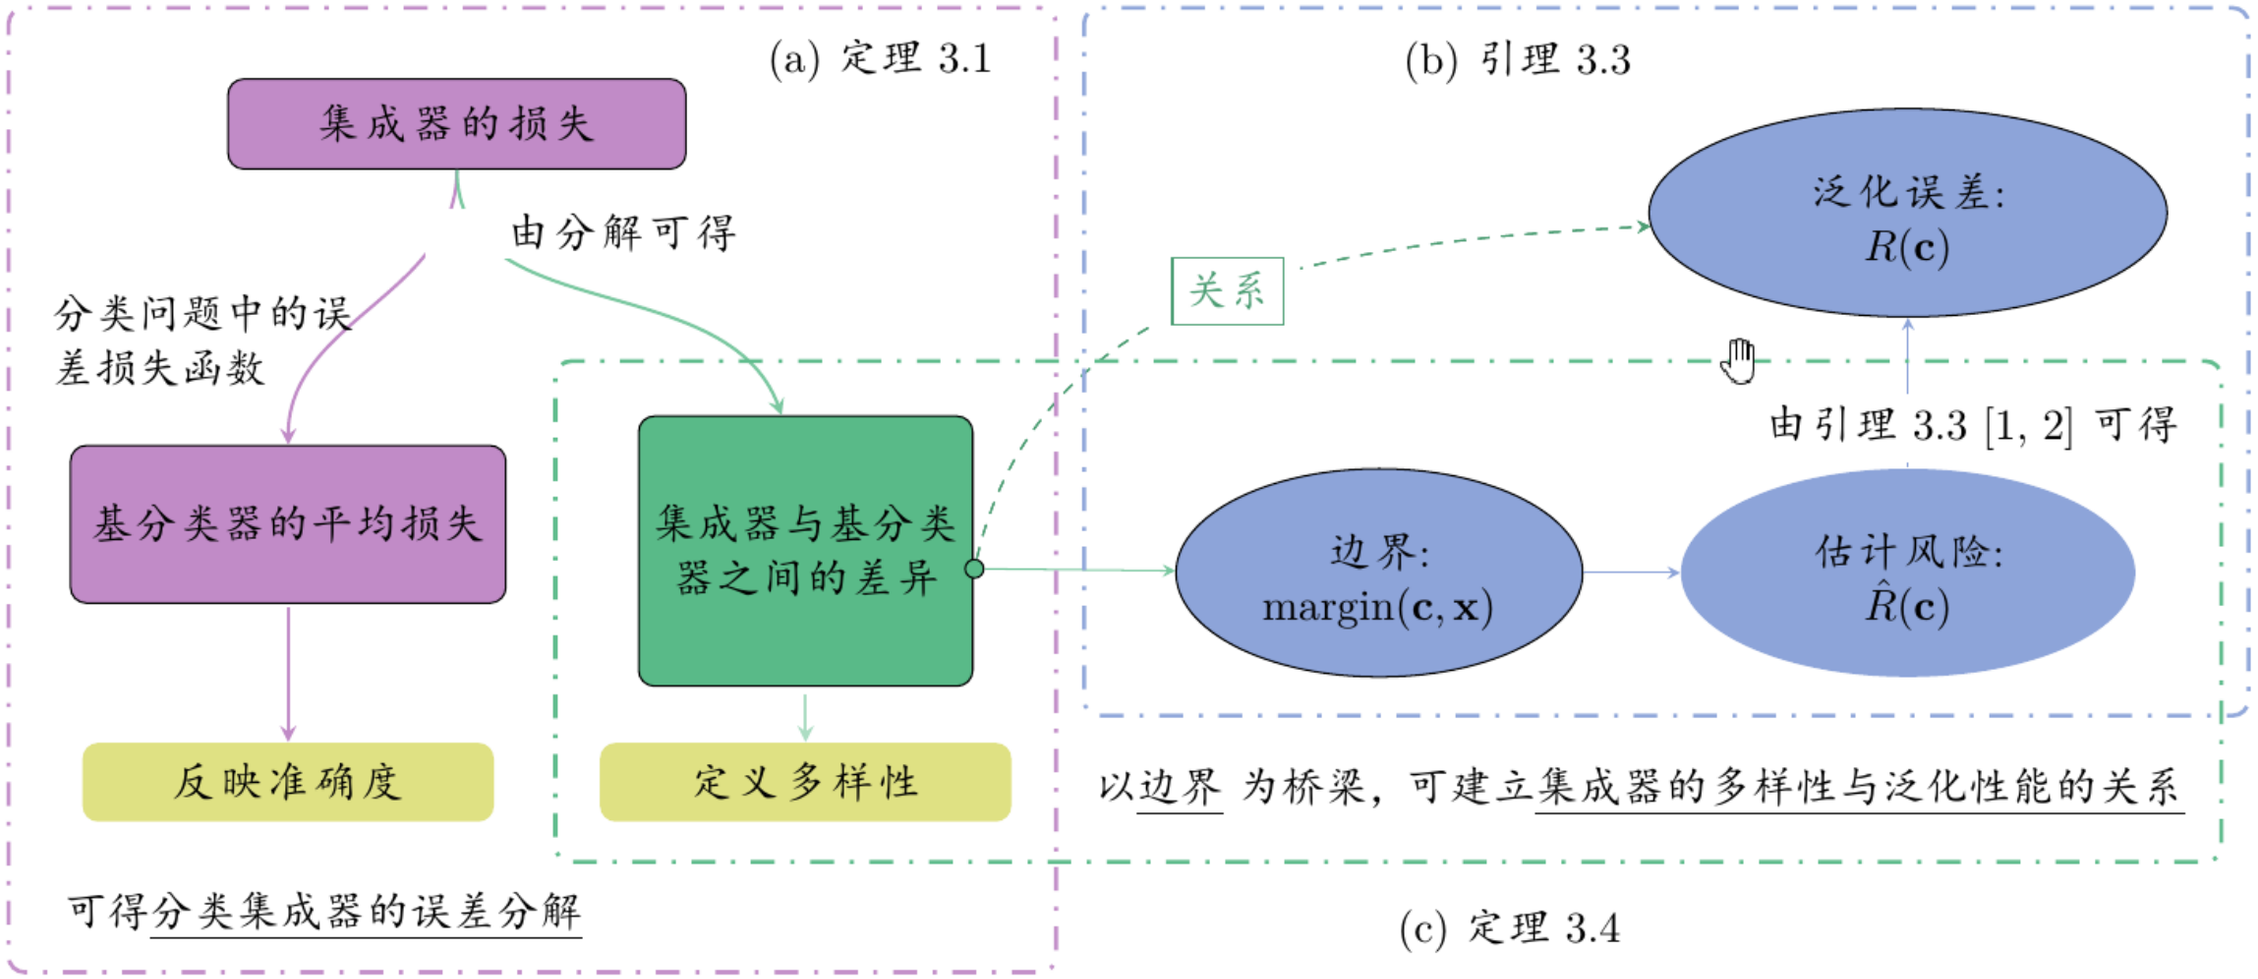


Figure 2: 所提出方法的概要图。(a) 分类问题中误差分解的动机说明。(b) 引理 3.3 [2, 3] 的说明。(c) 集成器的多样性与泛化性能关系的动机说明。

集成器的误差分解及其多样性度量

训练样本集

$$\mathcal{D} = \{(\boldsymbol{x}_1, y_1), ..., (\boldsymbol{x}_m, y_m)\} \tag{1}$$

一组已训练好的基分类器

$$\mathcal{H} = \{h_1(\cdot), ..., h_n(\cdot)\} \tag{2}$$

带权投票法的分类集成器

$$h_{ens}(\boldsymbol{x}) = \text{sign}\left(\sum_{i=1}^{n} w_i h_i(\boldsymbol{x})\right) \tag{3}$$

集成器的误差分解及其多样性度量

损失函数

$$\mathrm{Err}\left(h(\boldsymbol{x})\right) = \begin{cases} 1\,, & \text{若} h(\boldsymbol{x})y = -1\,; \\ 0.5\,, & \text{若} h(\boldsymbol{x})y = 0\,; \\ 0\,, & \text{若} h(\boldsymbol{x})y = 1 \end{cases} \tag{4}$$

边界

$$\mathrm{margin}(h, \boldsymbol{x}) = h(\boldsymbol{x})y \tag{5}$$

集成器的误差分解及其多样性度量

Theorem（定理 3.1：分类集成器的误差分解）

给定一组已训练好的基分类器 $\mathcal{H} = \{h_1(\cdot), .., h_n(\cdot)\}$，它们构成带权投票法的集成器如式 (3) 所示，其中权重满足 $\sum_i w_i = 1$ 和 $w_i \geqslant 0$. 则集成器的 0/1 损失可以被分解为两项，即

$$\begin{aligned} \operatorname{Err}\left(h_{ens}(\boldsymbol{x})y\right) = & \sum_{i=1}^{n} w_i \operatorname{Err}\left(h_i(\mathbf{x})y\right) \\ & -\frac{1}{2}\left(\operatorname{margin}(h_{ens}, \boldsymbol{x}) - \sum_{i=1}^{n} w_i \cdot \operatorname{margin}(h_i, \boldsymbol{x})\right) . \end{aligned} \tag{6}$$

利用

$$\operatorname{Err}(h(\mathbf{x})y) = -\tfrac{1}{2}\big(h(\mathbf{x})y - 1\big) \tag{7}$$

集成器的误差分解及其多样性度量

- 集成器的损失

$$\operatorname{Err}\left(h_{ens}(\boldsymbol{x})y\right) - \sum_{i=1}^{n} w_i \operatorname{Err}\left(h_i(\boldsymbol{x})y\right)$$

$$= -\boxed{\frac{1}{2}\left(h_{ens}(\boldsymbol{x}) - \sum_{i=1}^{n} w_i h_i(\boldsymbol{x})\right) y}$$

集成器的误差分解及其多样性度量

- 集成器的损失
-

基分类器的平均损失

$$\mathrm{Err}\left(h_{ens}(\boldsymbol{x})y\right) - \sum_{i=1}^{n} w_i \,\mathrm{Err}\left(h_i(\boldsymbol{x})y\right)$$

$$= -\boxed{\frac{1}{2}\left(h_{ens}(\boldsymbol{x}) - \sum_{i=1}^{n} w_i h_i(\boldsymbol{x})\right) y}$$

集成器的误差分解及其多样性度量

- 集成器的损失
-

基分类器的平均损失

$$\mathrm{Err}\left(h_{ens}(\boldsymbol{x})y\right) - \sum_{i=1}^{n} w_i \,\mathrm{Err}\left(h_i(\boldsymbol{x})y\right)$$

$$= -\boxed{\frac{1}{2}\left(h_{ens}(\boldsymbol{x}) - \sum_{i=1}^{n} w_i h_i(\boldsymbol{x})\right) y}$$

- 集成器与基分类器之间的差异

集成器的误差分解及其多样性度量

- 集成器的损失
-

基分类器的平均损失

$$\underbrace{\mathrm{Err}\left(h_{ens}(\boldsymbol{x})y\right)}_{\text{集成器的损失}} - \underbrace{\sum_{i=1}^{n} w_i \,\mathrm{Err}\left(h_i(\boldsymbol{x})y\right)}_{\text{基分类器的平均损失}}$$

$$= -\boxed{\frac{1}{2}\left(h_{ens}(\boldsymbol{x}) - \sum_{i=1}^{n} w_i h_i(\boldsymbol{x})\right) y}$$

- 集成器与基分类器之间的差异
-

$$\mathrm{div}(h_{ens}, \mathbf{x}) = \frac{1}{2}\,\mathrm{margin}(h_{ens}, \boldsymbol{x}) - \frac{1}{2}\sum_{i=1}^{n} w_i \cdot \mathrm{margin}(h_i, \boldsymbol{x}) \tag{8}$$

集成器的误差分解及其多样性度量

- 集成器的损失
-

基分类器的平均损失

$$\underbrace{\mathrm{Err}\left(h_{ens}(\boldsymbol{x})y\right)}_{\text{集成器的损失}} - \underbrace{\sum_{i=1}^{n} w_i \,\mathrm{Err}\left(h_i(\boldsymbol{x})y\right)}_{\text{基分类器的平均损失}}$$

$$= -\boxed{\frac{1}{2}\left(h_{ens}(\boldsymbol{x}) - \sum_{i=1}^{n} w_i h_i(\boldsymbol{x})\right) y}$$

- 集成器与基分类器之间的差异
-

$$\mathrm{div}(h_{ens}, \mathbf{x}) = \frac{1}{2}\,\mathrm{margin}(h_{ens}, \boldsymbol{x}) - \frac{1}{2}\sum_{i=1}^{n} w_i \cdot \mathrm{margin}(h_i, \boldsymbol{x}) \tag{8}$$

- 单个样本的多样性

集成器的误差分解及其多样性度量

Theorem (定理 3.1：分类集成器的误差分解 (续.))

通过计算各项在样本空间中的期望，可得集成器的泛化误差分解为

$$\bar{G} = \bar{A} - \bar{D}, \tag{9}$$

其中，

$$\bar{G} = \mathbb{E}_{\mathcal{D}}\big(\operatorname{Err}\left(h_{ens}(\boldsymbol{x})y\right)\big), \tag{10a}$$

$$\bar{A} = \sum_{i=1}^{n} c_i \mathbb{E}_{\mathcal{D}}\big(\operatorname{Err}\left(h_i(\boldsymbol{x})y\right)\big), \tag{10b}$$

$$\bar{D} = \frac{1}{2}\mathbb{E}_{\mathcal{D}}\big(\operatorname{margin}(h_{ens}, \boldsymbol{x})\big) - \frac{1}{2}\sum_{i=1}^{n} w_i \mathbb{E}_{\mathcal{D}}\big(\operatorname{margin}(h_i, \boldsymbol{x})\big), \tag{10c}$$

且 $\mathbb{E}_{\mathcal{D}}(\cdot)$ 代表在样本空间上的期望。

集成器的误差分解及其多样性度量

- 单个分类器 $h(\cdot)$ 的损失误差

$$\begin{aligned}\mathrm{Err}\left(h(\boldsymbol{x})y\right) &= -\frac{1}{2}\big(h(\boldsymbol{x})y - 1\big) \\ &= \frac{1}{2}\big(1 - \mathrm{margin}(h, \boldsymbol{x})\big)\end{aligned} \tag{11}$$

- 代入式 (10) 可得

$$\bar{G} = \tfrac{1}{2}\Big(1 - \mathbb{E}_{\mathcal{D}}\big(\boxed{\mathrm{sign}(\clubsuit)}\big)\Big)$$

$$\bar{A} = \tfrac{1}{2}\Big(1 - \mathbb{E}_{\mathcal{D}}\big(\boxed{\clubsuit}\big)\Big)$$

$$\bar{D} = \tfrac{1}{2}\mathbb{E}_{\mathcal{D}}\big(\boxed{\mathrm{sign}(\clubsuit) - \clubsuit}\big)$$

$$\clubsuit \overset{\mathrm{def}}{=} \sum_{i=1}^{n} w_i \cdot \mathrm{margin}(h_i, \boldsymbol{x})$$

集成器的误差分解及其多样性度量

- 单个分类器 $h(\cdot)$ 的损失误差
- 代入式 (10) 可得

$$\bar{G} = \frac{1}{2}\Big(1 - \mathbb{E}_{\mathcal{D}}\big(\boxed{\operatorname{sign}(\clubsuit)}\big)\Big)$$

$$\bar{A} = \frac{1}{2}\Big(1 - \mathbb{E}_{\mathcal{D}}\big(\boxed{\clubsuit}\big)\Big)$$

$$\bar{D} = \frac{1}{2}\mathbb{E}_{\mathcal{D}}\big(\boxed{\operatorname{sign}(\clubsuit) - \clubsuit}\big)$$

$$\clubsuit \overset{\text{def}}{=} \sum_{i=1}^{n} w_i \cdot \operatorname{margin}(h_i, \boldsymbol{x})$$

↓ 代换

$$\operatorname{div}(h_{ens}, \boldsymbol{x}) = \frac{1}{2}\big(\operatorname{sign}(\clubsuit) - \clubsuit\big)$$

$$\clubsuit = \lambda - 2\operatorname{div}(h_{ens}, \boldsymbol{x})$$

集成器的误差分解及其多样性度量

Corollary (推论 3.2: $\bar{G}, \bar{A}$ 和 $\bar{D}$ 都只依赖于 $\mathrm{div}(h_{ens}, \boldsymbol{x})$)

考虑二分类问题。给定一组已训练好的基分类器 $\mathcal{H} = \{h_1(\cdot), h_2(\cdot), ..., h_n(\cdot)\}$，所构成的使用带权投票法的集成器如式 (3) 所示，其中权重满足 $\sum_{i=1}^{n} w_i = 1$. 那么该集成器的泛化误差 $\bar{G}$、准确度 $\bar{A}$ 和多样性 $\bar{D}$ 都依赖于且只依赖于 $\mathrm{div}(h_{ens}, \boldsymbol{x})$，即

$$\bar{G} = \frac{1}{2}\Big(1 - \mathbb{E}_{\mathcal{D}}\big(\mathrm{sign}\left(\lambda - 2\,\mathrm{div}(h_{ens}, \boldsymbol{x})\right)\big)\Big), \tag{12a}$$

$$\bar{A} = \frac{1}{2}\Big(1 - \mathbb{E}_{\mathcal{D}}\big(\lambda - 2\,\mathrm{div}(h_{ens}, \boldsymbol{x})\big)\Big), \tag{12b}$$

$$\bar{D} = \mathbb{E}_{\mathcal{D}}\big(\mathrm{div}(h_{ens}, \boldsymbol{x})\big), \tag{12c}$$

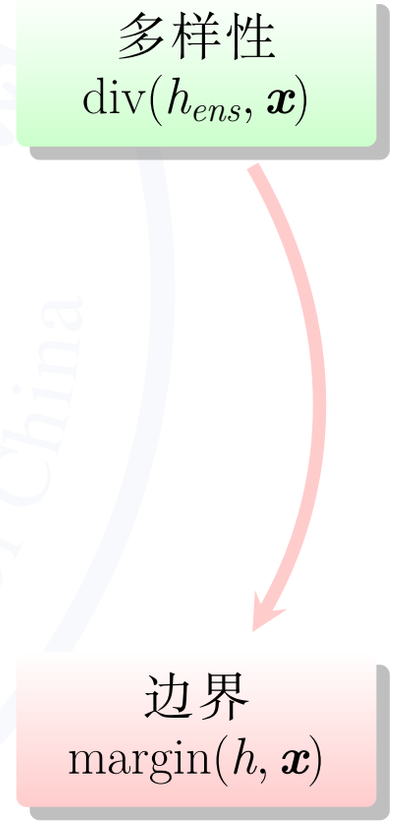
其中，

$$\lambda = \begin{cases} 1, & \text{若 } \mathrm{div}(h_{ens}, \boldsymbol{x}) \in (0, \frac{1}{2}); \\ 0, & \text{若 } \mathrm{div}(h_{ens}, \boldsymbol{x}) = 0; \\ -1, & \text{若 } \mathrm{div}(h_{ens}, \boldsymbol{x}) \in (-\frac{1}{2}, 0). \end{cases} \tag{13}$$

集成器的多样性与泛化性能的关系

margin$(h, \boldsymbol{x})$

Herbrich and Graepel [2, 3] 量化了线性分类器的泛化误差风险与边界之间的关系



集成器的多样性与泛化性能的关系

样本集合

$$\mathcal{D} = \{(\boldsymbol{x}_i, y_i) \sim \mathbf{P}_{\mathsf{XY}} \,|\, i = 1, ..., m\} \tag{14}$$

一组基分类器

$$\mathcal{H} = \{h_1(\cdot), ..., h_n(\cdot)\}$$

集成器的多样性与泛化性能的关系

带权投票法的分类集成器，同式 (3)，即

$$\mathcal{F} = \left\{ h_{\mathbf{w}} : \boldsymbol{x} \mapsto \operatorname{sign}(\langle \mathbf{w}, \phi(\boldsymbol{x}) \rangle) \,\middle|\, \mathbf{w} \in \mathcal{W} \right\} \tag{15}$$

$$s.t.$$

$$\phi(\boldsymbol{x}) = [h_1(\boldsymbol{x}), ..., h_n(\boldsymbol{x})]^{\mathsf{T}}$$

$$\mathbf{w} = [w_1, ..., w_n]^{\mathsf{T}}$$

集成器的多样性与泛化性能的关系

带权投票法的分类集成器，同式 (3)，即

$$\mathcal{F} = \left\{ h_{\mathbf{w}} : \boldsymbol{x} \mapsto \operatorname{sign}(\langle \mathbf{w}, \phi(\boldsymbol{x}) \rangle) \,\middle|\, \mathbf{w} \in \mathcal{W} \right\} \tag{15}$$

- $h(\cdot) \Leftrightarrow \mathbf{w}$ 一一映射

$$\mathcal{W} = \left\{ \mathbf{w} \,\middle|\, \sum_{i=1}^{n} w_i = 1 \right\})$$

集成器的多样性与泛化性能的关系

假设存在 $\mathbf{w}^* \in \mathcal{W}$，使得

$$\mathbf{P}_{\mathsf{Y}|\mathsf{X}=\boldsymbol{x}}(y) = \mathbb{I}(y = \operatorname{sign}(\langle \mathbf{w}^*, \phi(\boldsymbol{x}) \rangle)) \tag{16}$$

则存在一个版本空间 (version space)

$$V(\mathcal{D}) = \{\mathbf{w} \in \mathcal{W} \,|\, \forall (\boldsymbol{x}, y) \in \mathcal{D}, \operatorname{sign}(\langle \mathbf{w}, \phi(\boldsymbol{x}) \rangle) = y\} \tag{17}$$

集成器的多样性与泛化性能的关系

任意 $\mathbf{w} \in V(\mathcal{D})$, 其真实误差风险

$$R(\mathbf{w}) = \mathbb{E}_{\mathsf{XY}}[\mathbb{I}(\text{sign}(\langle \mathbf{w}, \phi(\mathsf{X}) \rangle) \neq \mathsf{Y})] \tag{18}$$

集成器 $\mathbf{w}$ 的边界

$$\gamma(\mathbf{w}) = \min_{(\boldsymbol{x},y)\in\mathcal{D}} y\langle \mathbf{w}, \phi(\boldsymbol{x}) \rangle \tag{19}$$

集成器的多样性与泛化性能的关系

Lemma (引理 3.3: 集成器的泛化误差与其边界之间的关系 [3])

对于任意概率分布 $\mathbf{P}_{\mathsf{X}}$，如 $\mathbf{P}_{\mathsf{X}}(\|\phi(\boldsymbol{x})\| \leqslant \delta) = 1$，以及对于任意小数 $\xi \in (0, 1]$，以至少 $(1-\xi)$ 的概率从训练样本集 $\mathcal{D} \in (\mathcal{X}, \mathcal{Y})^m$ 中随机抽取，那么对于任意一致的分类集成器 $\mathbf{w} \in V(\mathcal{D})$，且满足存在正边界 $\gamma(\mathbf{w}) > \sqrt{32\delta^2/m}$，其泛化误差风险 $R(\mathbf{w})$ 可由下式所界定，即

$$R(\mathbf{w}) \leqslant \frac{2}{m}\left(\kappa(\mathbf{w}) \log_2\left(\frac{8em}{\kappa(\mathbf{w})}\right) \log_2(32m) + \log_2\left(\frac{2m}{\xi}\right)\right), \tag{20}$$

其中 $\kappa(\mathbf{w}) = \left\lceil \left(\frac{8\delta}{\gamma(\mathbf{w})}\right)^2 \right\rceil$.

集成器的多样性与泛化性能的关系

Theorem（定理 3.4：集成器的多样性与其泛化性能之间的关系）

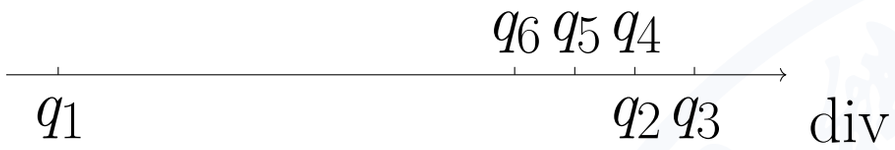
对于任意概率分布 $\mathbf{P}_{\mathsf{X}}$，如 $\mathbf{P}_{\mathsf{X}}(\|\phi(\boldsymbol{x})\| \leqslant \delta) = 1$，以及对于任意小数 $\xi \in (0, 1]$，以至少 $(1 - \xi)$ 的概率从训练样本集 $\mathcal{D} \in (\mathcal{X}, \mathcal{Y})^m$ 中随机抽取，且抽取过程以 ε 的概率受噪声影响。那么，对于任意一致的分类集成器 $\mathbf{w} \in V(\mathcal{D})$，其泛化误差 $R(\mathbf{w})$ 的上界的变化趋势与其估计值 $\hat{R}(\mathbf{w})$ 相同，即

$$\hat{R}(\mathbf{w}) = \left(\frac{8\delta}{\gamma(\mathbf{w})}\right)^2 \log_2\left(8em\left(\frac{\gamma(\mathbf{w})}{8\delta}\right)^2\right), \tag{21}$$

$$\gamma(\mathbf{w}) = \min_{(\boldsymbol{x}, y) \in \mathcal{D}} (1 - 2\varepsilon)(\lambda - 2\,\mathrm{div}(h_{ens}, \boldsymbol{x})), \tag{22}$$

其中 λ 的定义如式 (13) 所示。

集成器的多样性与泛化性能的关系



$$\hat{R}(\mathrm{div}(h_{ens}, \mathbf{x}))$$
$$\hat{R}'(q_2) = \hat{R}'(q_4) = 0$$
$$\hat{R}''(q_5) = 0$$
$$\hat{R}'''(q_6) = 0$$

集成器的多样性与泛化性能的关系



$$\hat{R}(\mathrm{div}(h_{ens}, \mathbf{x}))$$
$$\hat{R}'(q_2) = \hat{R}'(q_4) = 0$$
$$\hat{R}''(q_5) = 0$$
$$\hat{R}'''(q_6) = 0$$

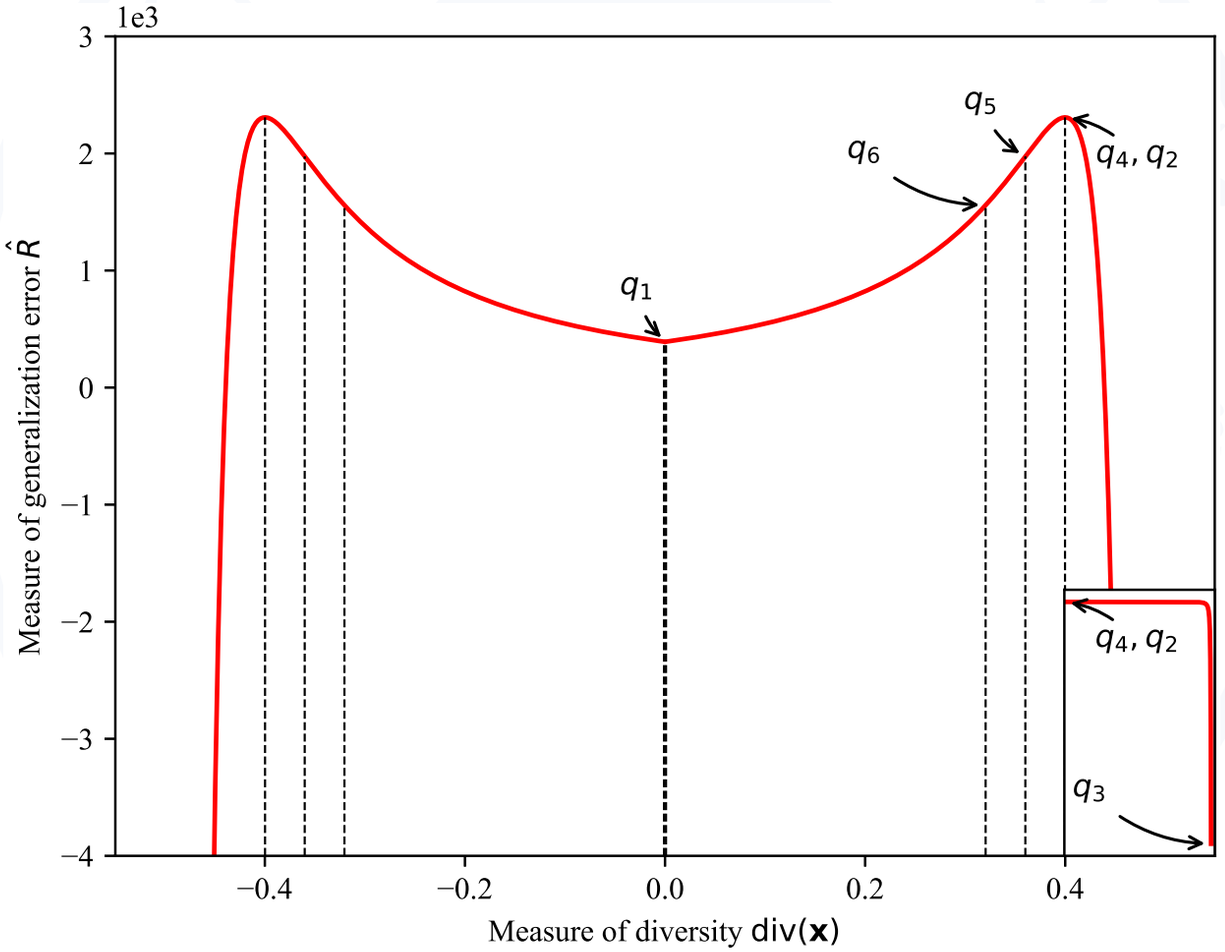
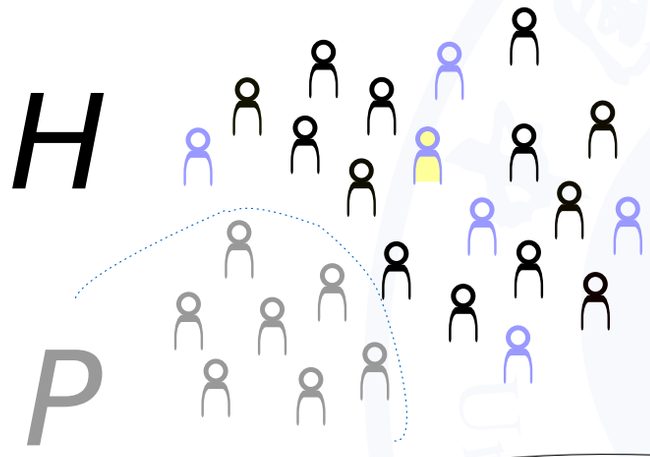


Figure 3: 集成器的多样性与其泛化误差风险的关系，自变量是多样性。实际上，图中的端点 (如 q_4, q_5 和 q_6 等) 均指横轴上的对应位置。在此图示中，所用到的参数是：$\delta = 1,\ \varepsilon = 0.01,\ m = 200$.

基于多样性的集成剪枝方法及框架



边界最小

准确度高

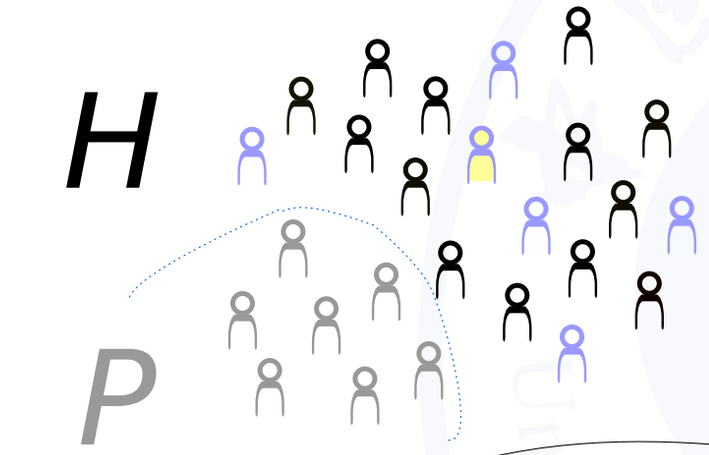
算法 1：基于多样性的集成剪枝方法 (*EPBD*)

Input: 训练数据集 $\mathcal{D} = \{(\boldsymbol{x}_1, y_1), ..., (\boldsymbol{x}_m, y_m)\}$; 原始集成器 $\mathcal{H} = \{h_1(\cdot), ..., h_n(\cdot)\}$; 剪枝比例 ρ; 平衡因子 λ.

Output: 剪枝后的子集成器 $\mathcal{P}$, 满足 $\mathcal{P} \subset \mathcal{H}$.

1: $\mathcal{H} = \emptyset$;
2: **repeat**
3: 搜索 满足式 (20) 的样本点，记为 $(\boldsymbol{x}, y)$;
4: 将 $\mathcal{H}$ 中能够 正确分类该样本 $(\boldsymbol{x}, y)$ 的基分类器 按 性能递减 的顺序排序;
5: 选择上一步中 最好的基分类器 $h(\cdot)$，将其从 $\mathcal{H}$ 中移入 $\mathcal{P}$;
6: **until** 终止条件满足.

基于多样性的集成剪枝方法及框架



多样性高

准确度高

算法 2：利用准确度和多样性之间平衡的集成剪枝框架 (*FTAD*)

Input: 训练数据集 $\mathcal{D} = \{(\boldsymbol{x}_1, y_1), ..., (\boldsymbol{x}_m, y_m)\}$; 原始集成器 $\mathcal{H} = \{h_1(\cdot), ..., h_n(\cdot)\}$; 剪枝比例 ρ; 平衡因子 λ.

Output: 剪枝后的子集成器 $\mathcal{P}$, 满足 $\mathcal{P} \subset \mathcal{H}$.

1: $\mathcal{H} = \emptyset$;
2: **repeat**
3: 使用 某种多样性度量方法 来计算训练集上各样本点的多样性，选择 其中多样性最大的一点 记为 $(\boldsymbol{x}, y)$;
4: 将 $\mathcal{H}$ 中能够 正确分类该样本 $(\boldsymbol{x}, y)$ 的基分类器 按 性能递增 的顺序排序;
5: 选择上一步中 最好的基分类器 $h(\cdot)$，将其从 $\mathcal{H}$ 中移入 $\mathcal{P}$;
6: **until** 终止条件满足.

验证分类集成器的误差分解

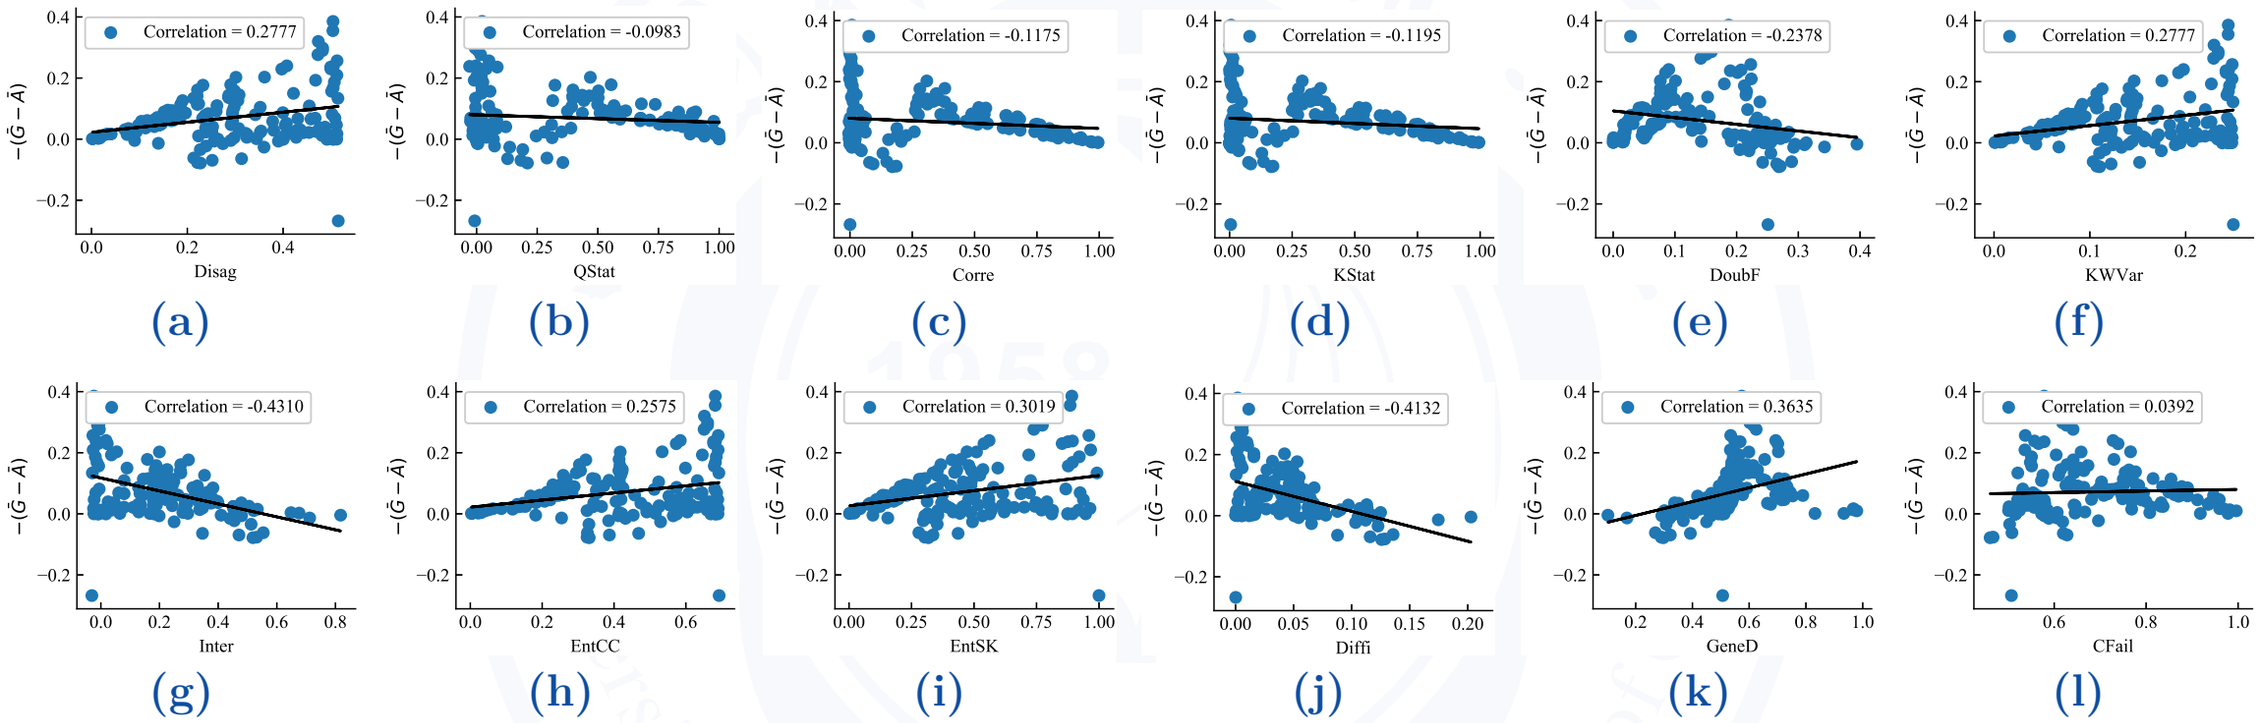


Figure 4: 式 (9) 中的损失差 $-(\bar{G}-\bar{A})$ 与不同多样性度量之间的关系，使用多层感知机作为基分类器和自助法来构造集成器

验证分类集成器的误差分解

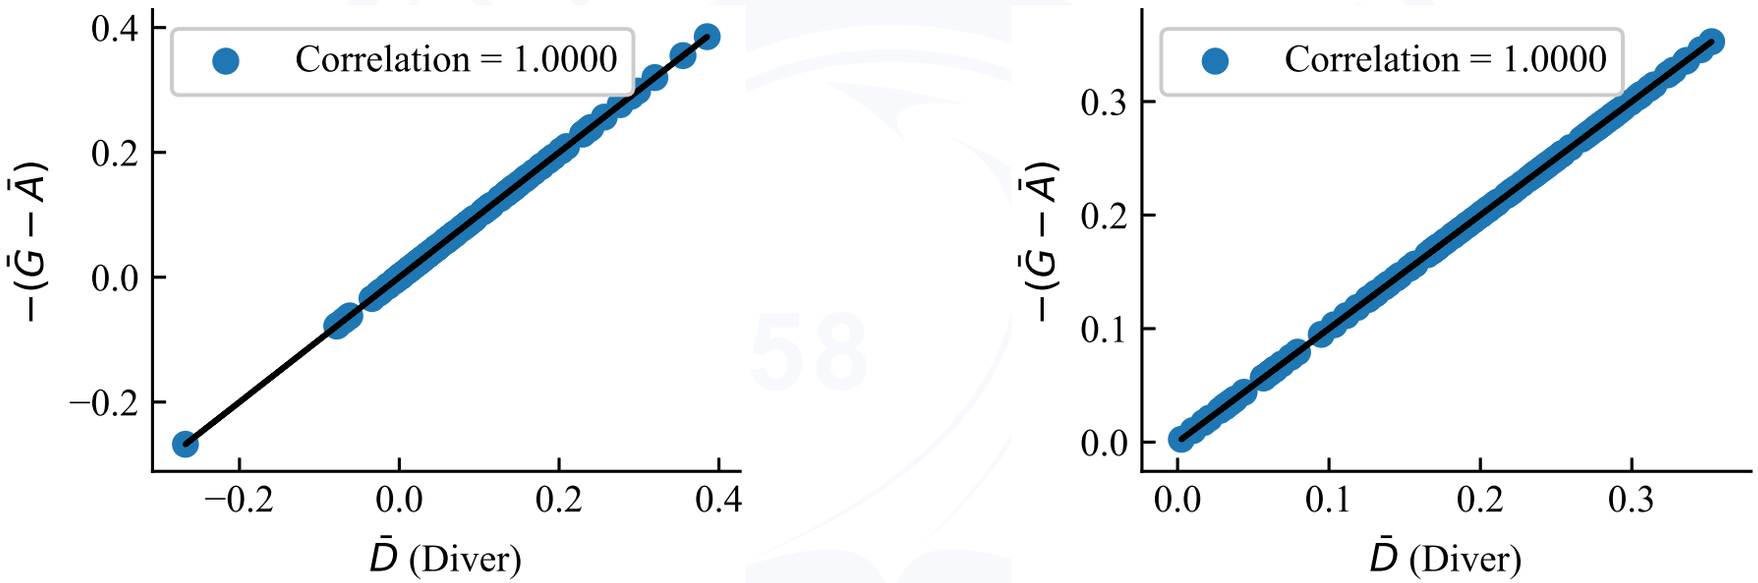


Figure 4: 式 (9) 中的损失差 $-(\bar{G}-\bar{A})$ 与式 (10) 中所提出的多样性度量之间的关系，使用多层感知机作为基分类器。(a) 使用自助法来构造集成器；(b) 使用自适应增强法来构造集成器。

验证分类集成器的误差分解

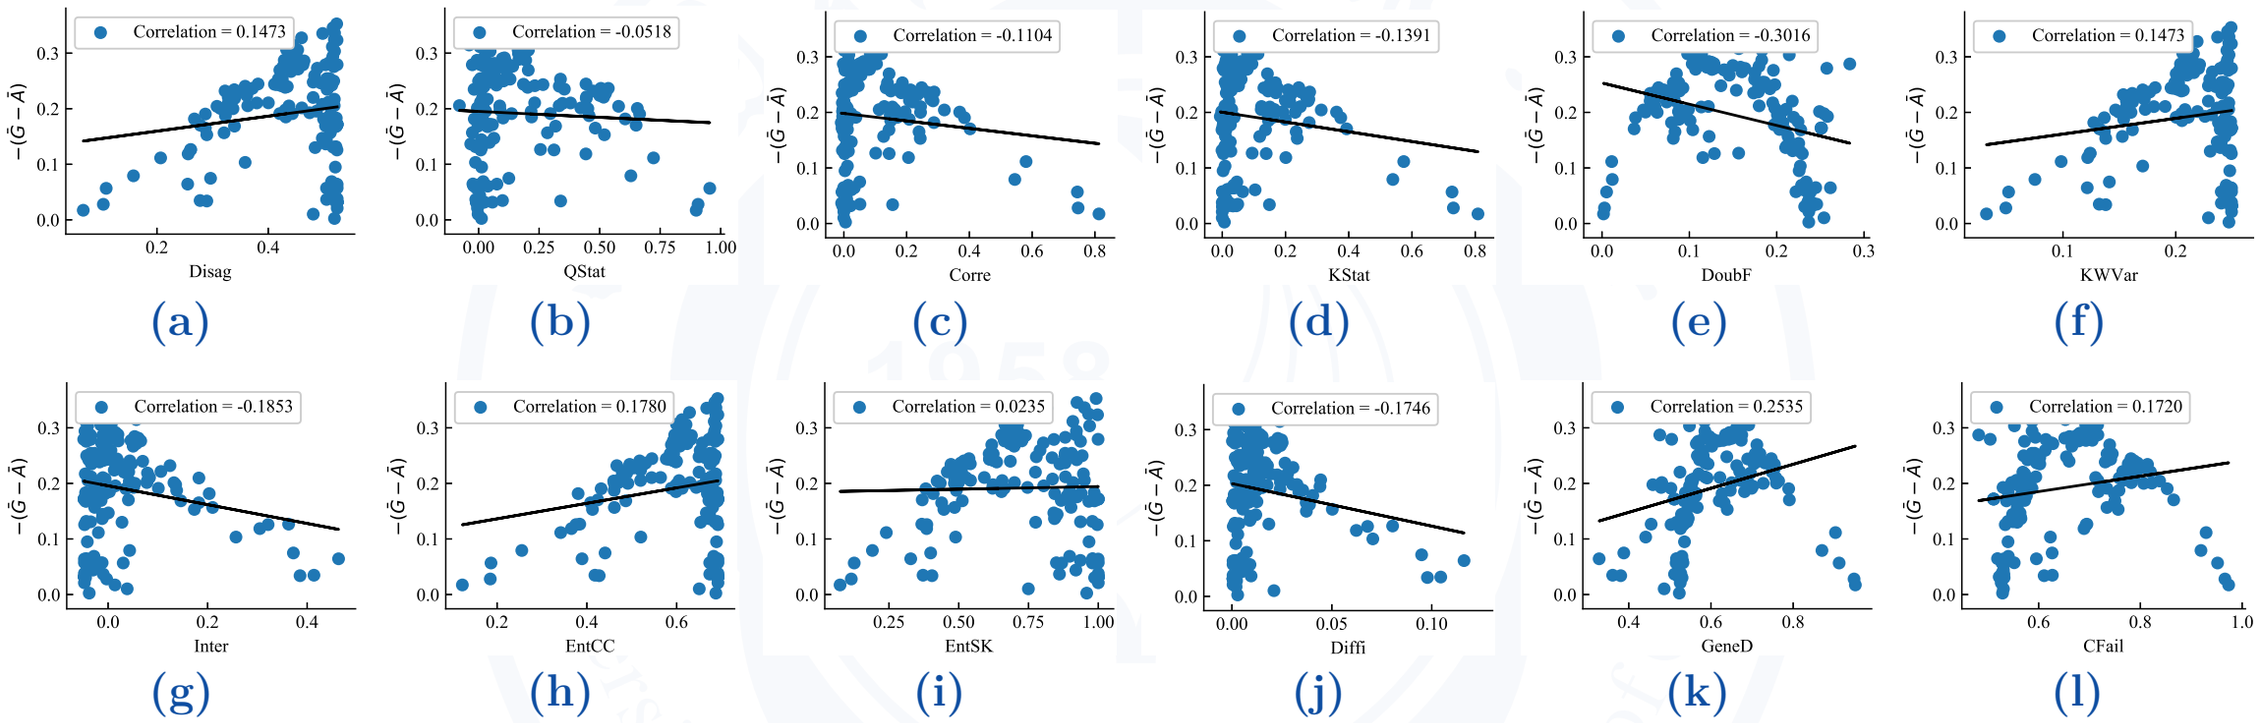
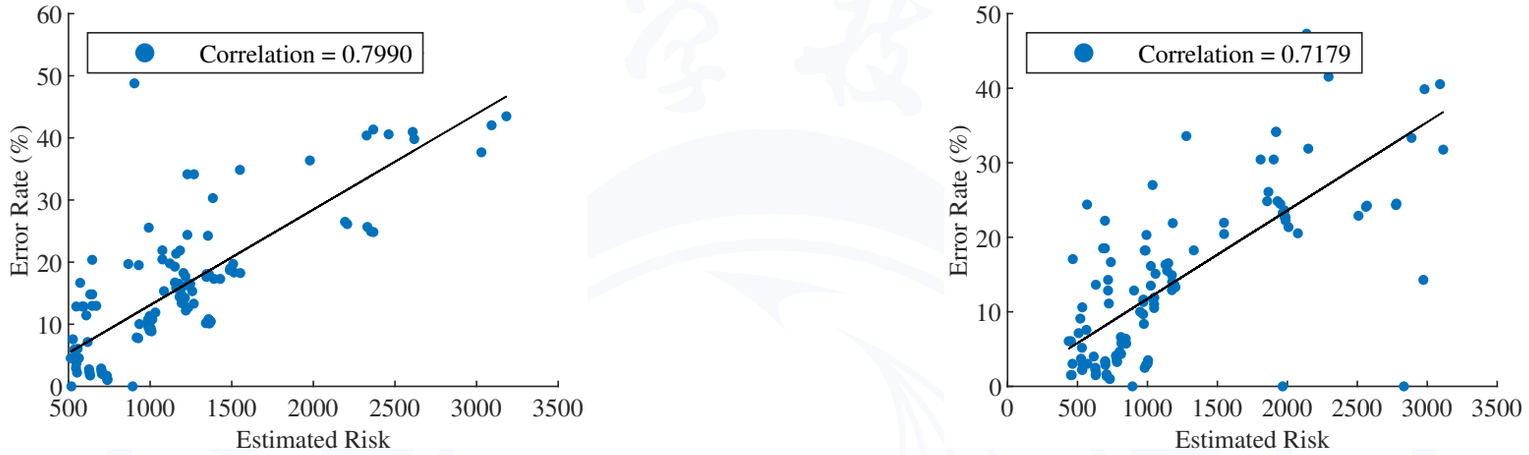


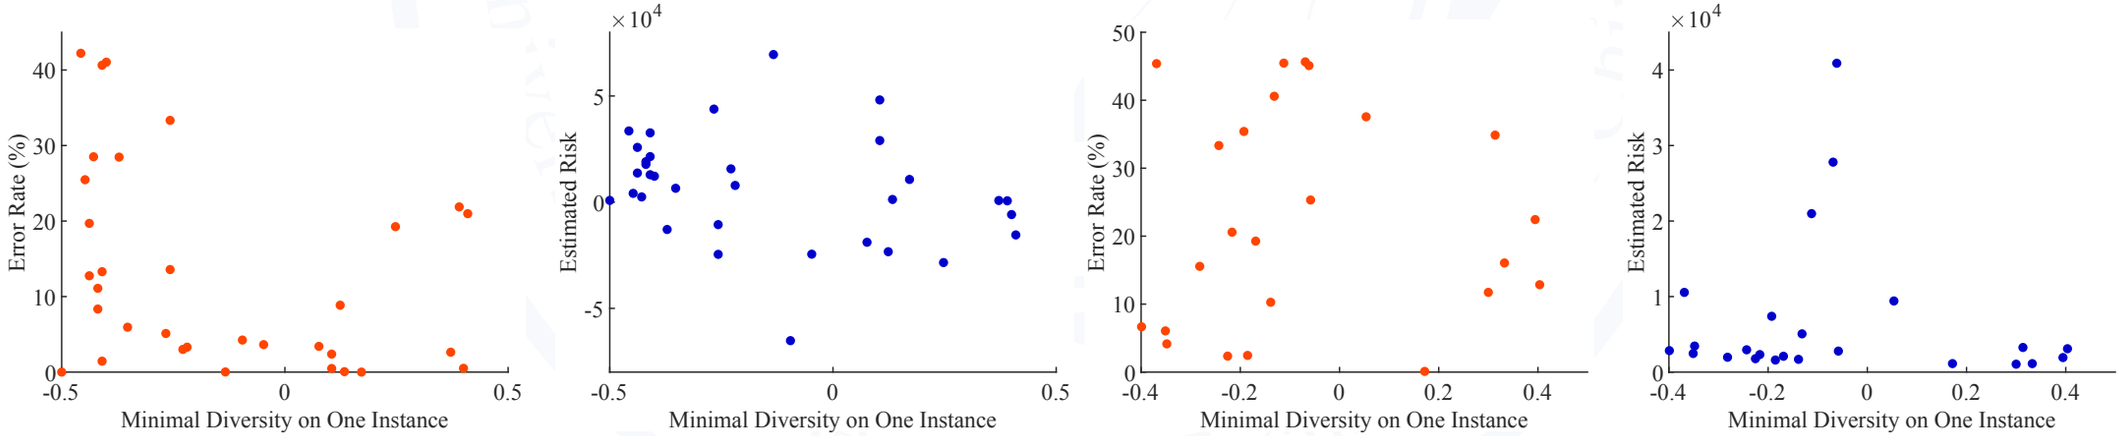
Figure 4: 式 (9) 中的损失差 $-(\bar{G}-\bar{A})$ 与不同多样性度量之间的关系，使用多层感知机作为基分类器和自适应增强法来构造集成器

验证集成器中多样性与泛化性能的关系



(a) (b)

Figure 5: 二分类问题中的集成器的泛化误差与其风险估计值之间的关系，其中风险估计值如式 (21) 中所示。注：集成器由自助法构建而得，分别使用朴素贝叶斯分类器和线性模型作为基分类器。



(a) (b) (c) (d)

Figure 6: 在二分类问题场景下，定理 3.4 中集成器的多样性与其泛化性能之间的关系。(a–b) 使用决策树作为基分类器和自助法来构建集成器; (c–d) 使用线性模型作为基分类器和自适应增强法来构建集成器.

评估 *EPBD*

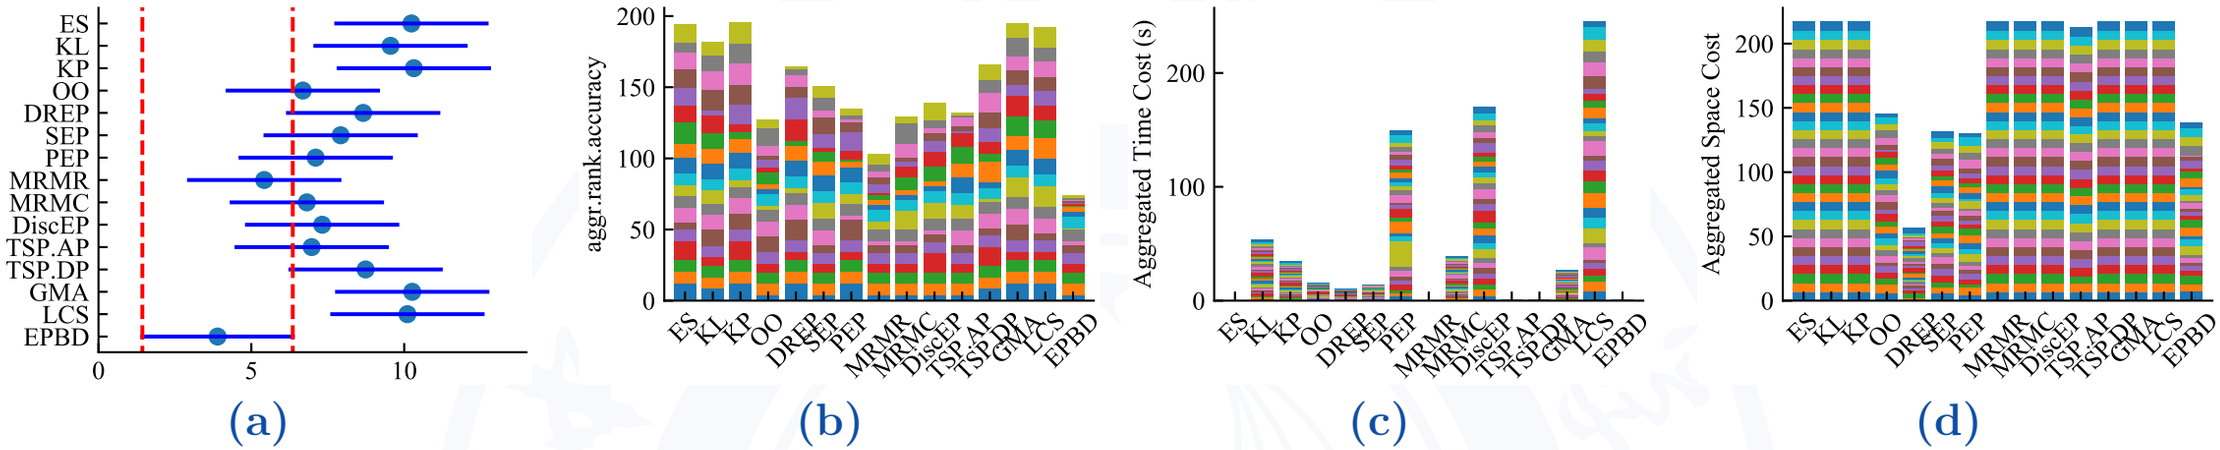


Figure 7: *EPBD* 与对比算法在测试准确度上的对比图，使用自助法来构造同质集成器。(a) Friedman 检验图 [4]；(b) 总计序值图 [5]；(c–d) 总计时间/空间代价。

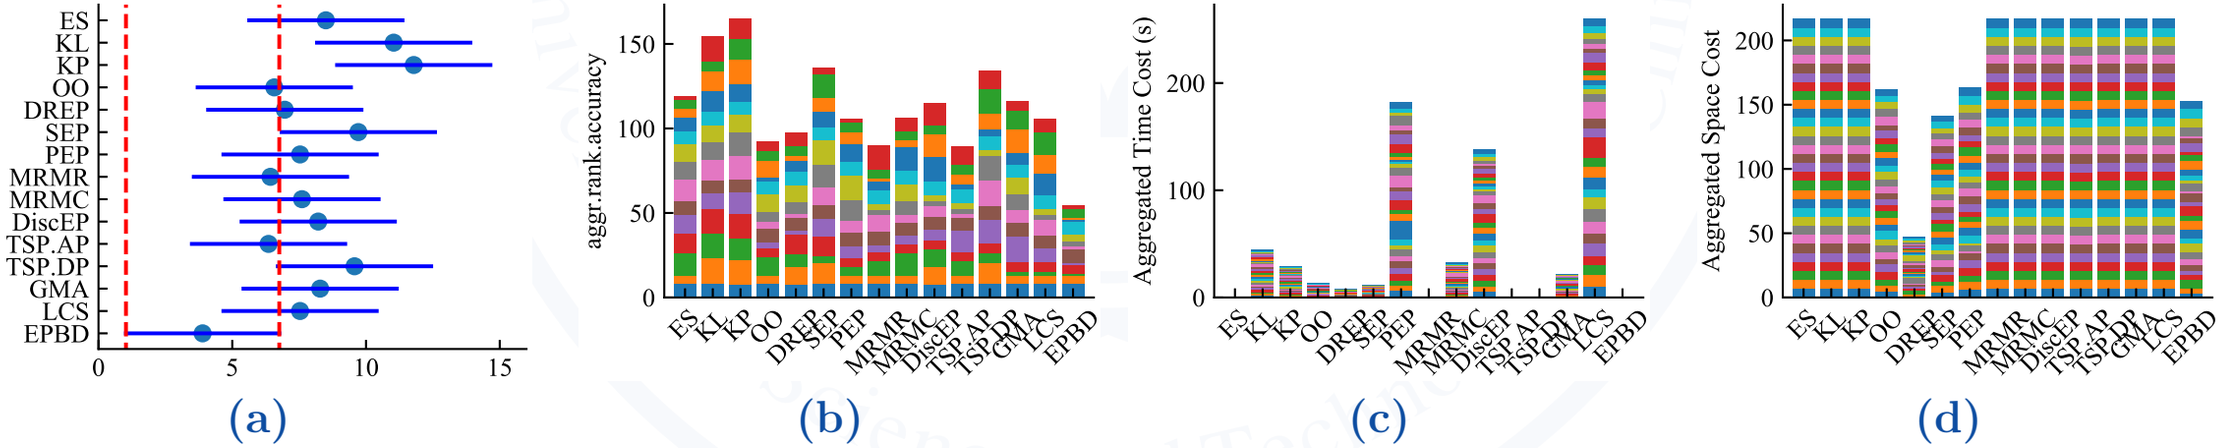


Figure 8: *EPBD* 与对比算法在测试准确度上的对比图，使用自适应增强法来构造同质集成器。(a) Friedman 检验图 [4]；(b) 总计序值图 [5]；(c–d) 总计时间/空间代价。

评估 *FTAD*

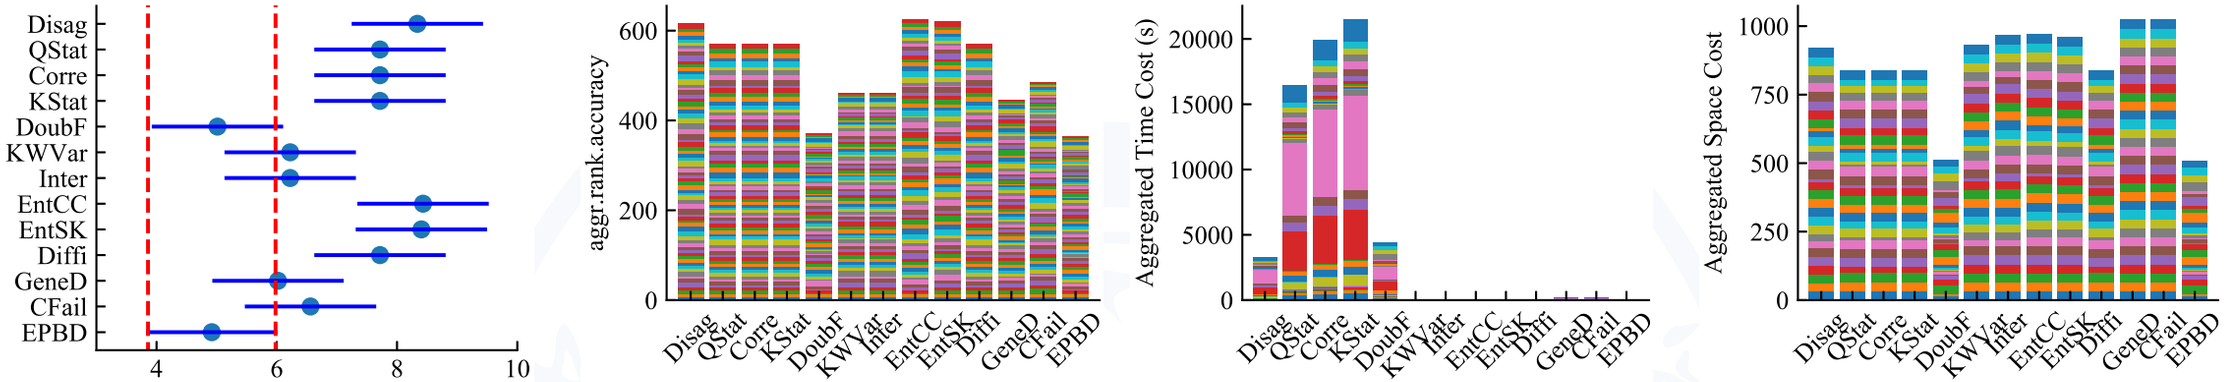


Figure 9: *EPBD* 与使用其他多样性度量的 *FTAD* 在测试准确度上的对比图，使用自助法来构造同质集成器。(a) Friedman 检验图 [4]；(b) 总计序值图 [5]；(c–d) 总计时间/空间代价。

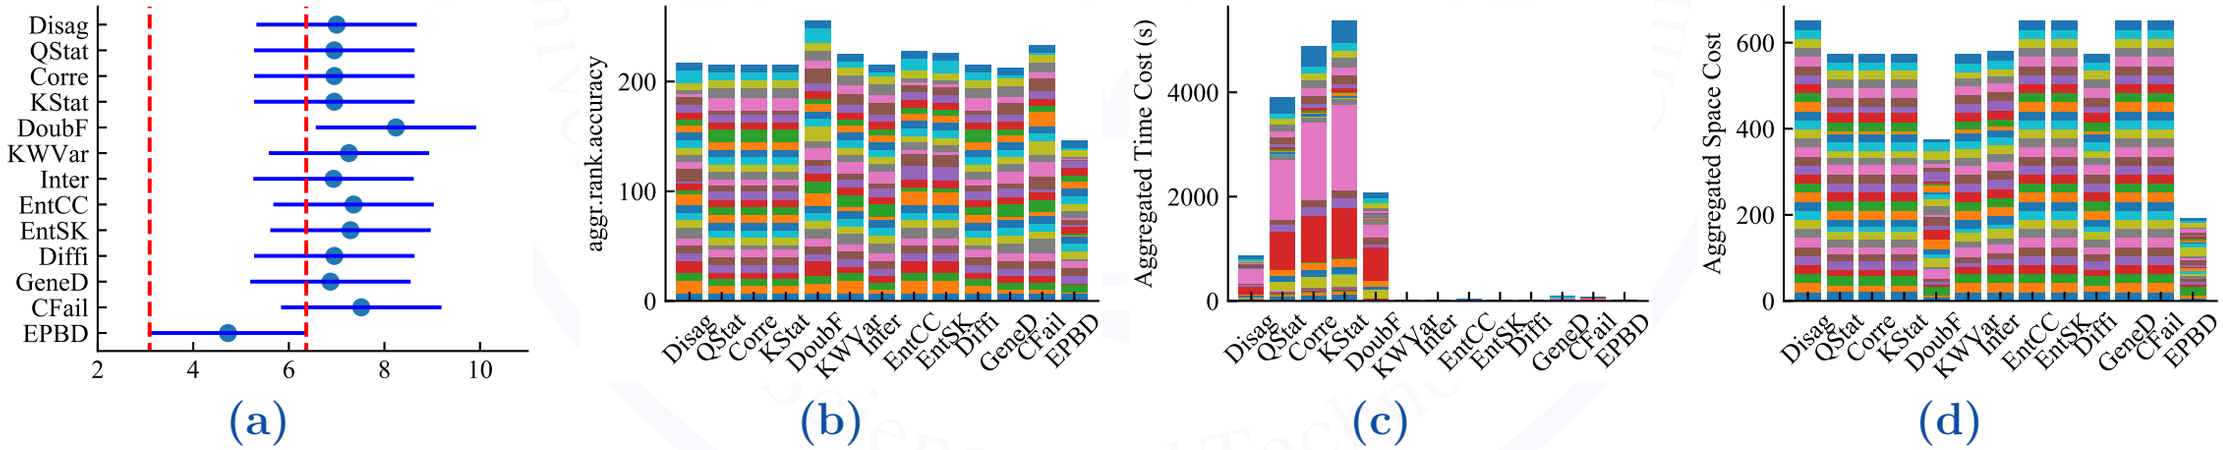
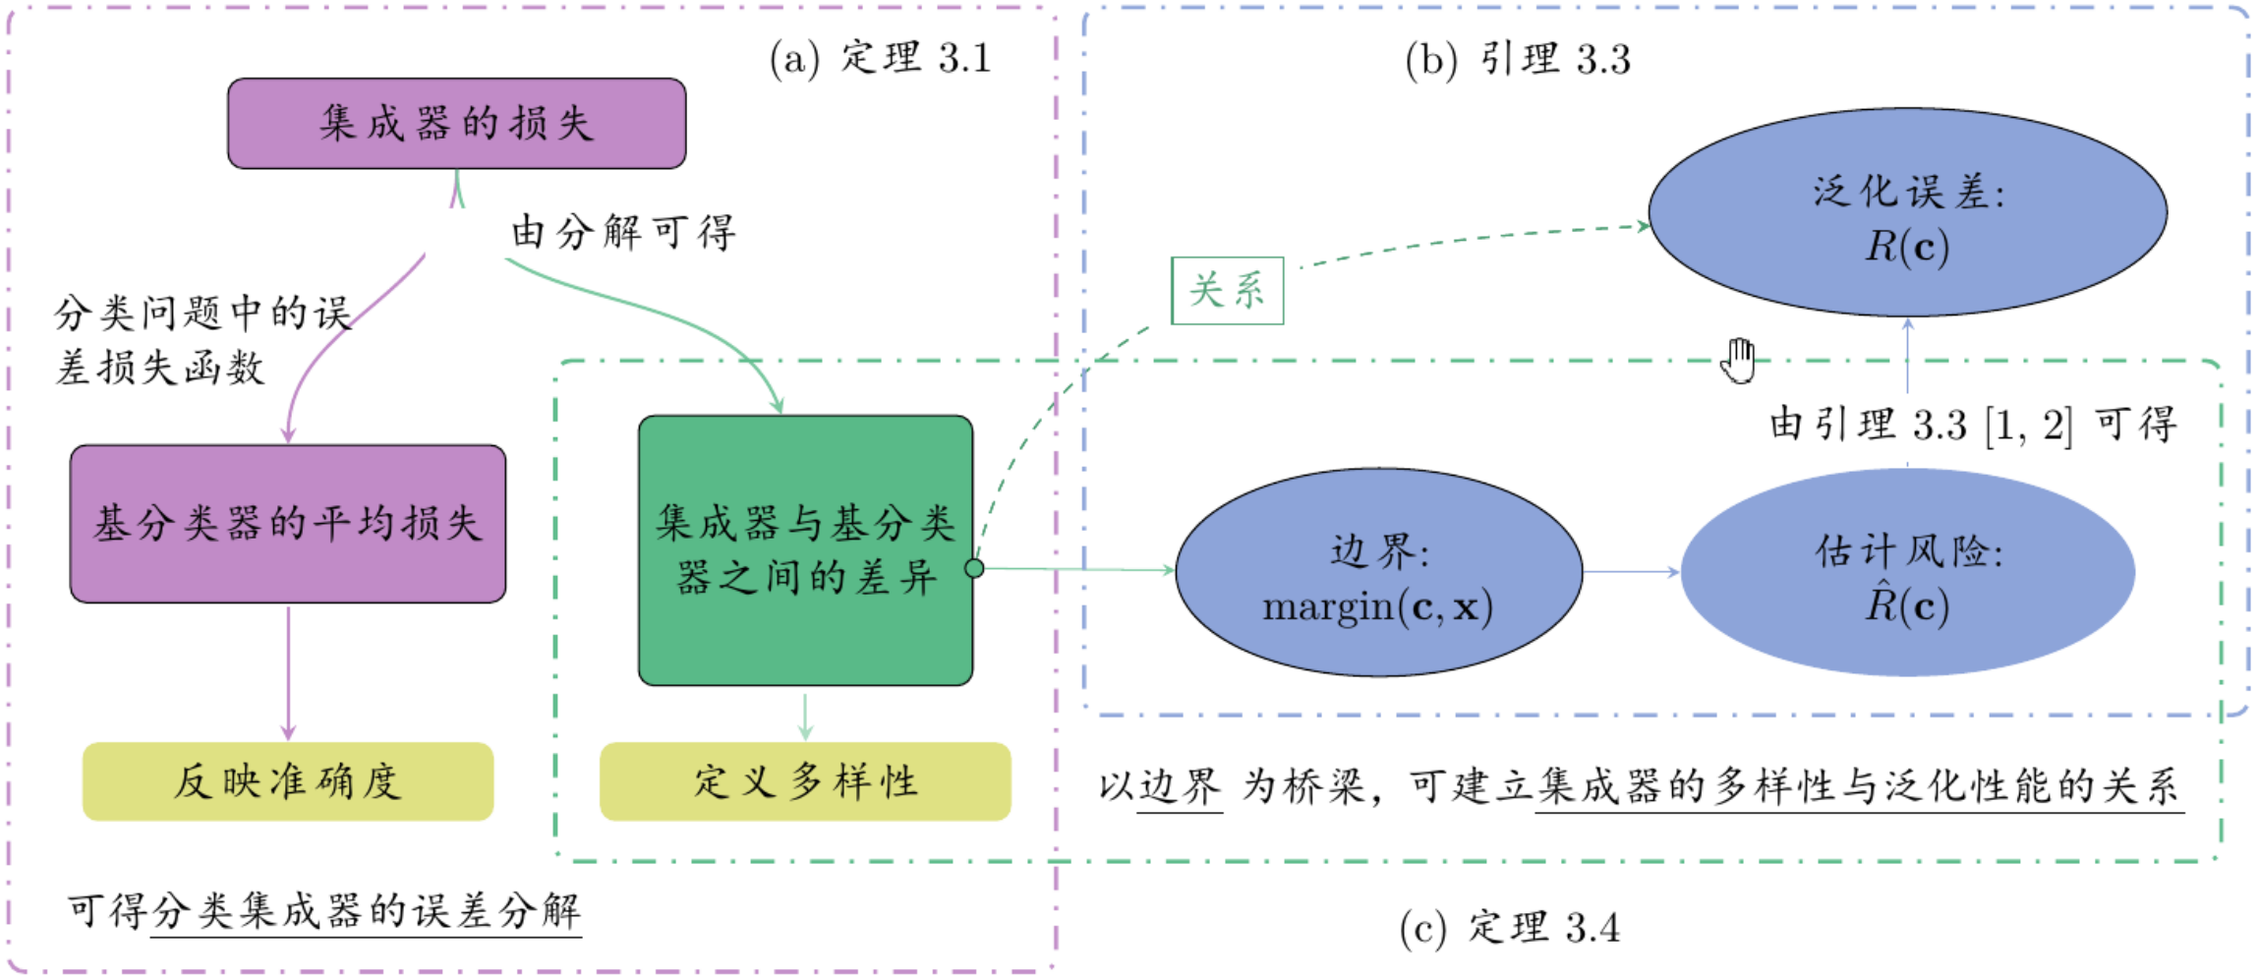


Figure 10: *EPBD* 与使用其他多样性度量的 *FTAD* 在测试准确度上的对比图，使用自适应增强法来构造同质集成器。(a) Friedman 检验图 [4]；(b) 总计序值图 [5]；(c–d) 总计时间/空间代价。

本章小结



- 利用集成器的多样性与泛化性能的关系
  - 基于多样性的集成剪枝方法 (*EPBD*)
  - 利用准确度和多样性之间平衡的集成剪枝框架 (*FTAD*)

大纲

1 研究意义

2 分类问题中集成器的多样性与泛化性能的关系

3 基于信息熵的集成剪枝方法及其通用并行框架
- 背景意义
- 方法介绍
- 实验评估
- 本章小结

4 神经架构搜索中的集成子结构剪枝

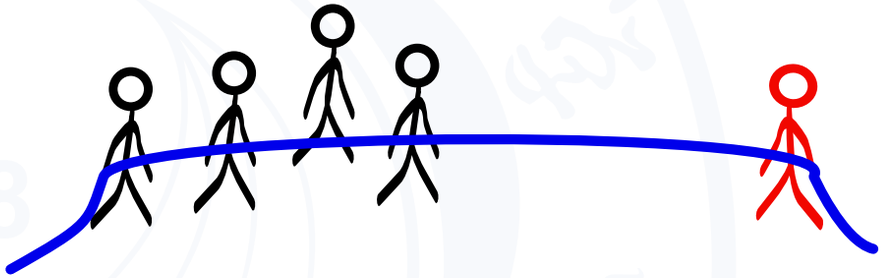
5 总结与展望

6 附录

背景意义



准确 vs. 多样



集中式

形式化集成剪枝任务为目标最大化问题

任意两个基分类器	$h_i, h_j \in \mathcal{H}$
在数据集 $\mathcal{D}$ 上获得的分类向量	$\mathbf{h}_i, \mathbf{h}_j$
数据集的 $\mathcal{D}$ 的标签向量	$\mathbf{y}$

形式化集成剪枝任务为目标最大化问题

利用两个离散随机变量 X 和 Y 的

- 熵函数 $\mathrm{H}(\cdot)$ 和联合熵函数 $\mathrm{H}(\cdot,\cdot)$
- 共有信息 [6]
- 标准共有信息 [7]
- 标准信息变异 [7]

$$\mathrm{I}(\mathsf{X};\mathsf{Y}) = \mathrm{H}(\mathsf{X}) - \mathrm{H}(\mathsf{X}|\mathsf{Y})$$

$$\mathrm{MI}(\mathsf{X},\mathsf{Y}) = \frac{\mathrm{I}(\mathsf{X};\mathsf{Y})}{\sqrt{\mathrm{H}(\mathsf{X})\mathrm{H}(\mathsf{Y})}}$$

$$\mathrm{VI}(\mathsf{X},\mathsf{Y}) = 1 - \frac{\mathrm{I}(\mathsf{X};\mathsf{Y})}{\mathrm{H}(\mathsf{X},\mathsf{Y})}$$

形式化集成剪枝任务为目标最大化问题

- 平衡两个基分类器之间的多样性和准确度
  - 两个基分类器之间的冗余度

$$\mathrm{TDAC}(h_i, h_j) = \begin{cases} \lambda\, \mathrm{VI}(\mathbf{h}_i, \mathbf{h}_j) + (1-\lambda)\dfrac{\mathrm{MI}(\mathbf{h}_i, \mathbf{y}) + \mathrm{MI}(\mathbf{h}_j, \mathbf{y})}{2}, & \text{若 } h_i \neq h_j; \\ 0\,, & \text{否则} \end{cases} \tag{23}$$

形式化集成剪枝任务为目标最大化问题

- 平衡两个基分类器之间的多样性和准确度
  - 两个基分类器之间的冗余度
  -

基分类器与标签向量之间的相关性

$$\mathrm{TDAC}(h_i, h_j) = \begin{cases} \lambda \, \mathrm{VI}(\mathbf{h}_i, \mathbf{h}_j) + (1-\lambda)\dfrac{\mathrm{MI}(\mathbf{h}_i, \mathbf{y}) + \mathrm{MI}(\mathbf{h}_j, \mathbf{y})}{2}, & \text{若 } h_i \neq h_j; \\ 0, & \text{否则} \end{cases} \tag{23}$$

形式化集成剪枝任务为目标最大化问题

- 平衡两个基分类器之间的多样性和准确度
  - 两个基分类器之间的冗余度
  -

基分类器与标签向量之间的相关性

$$\mathrm{TDAC}(h_i, h_j) = \begin{cases} \lambda\, \mathrm{VI}(\mathbf{h}_i, \mathbf{h}_j) + (1-\lambda)\dfrac{\mathrm{MI}(\mathbf{h}_i, \mathbf{y}) + \mathrm{MI}(\mathbf{h}_j, \mathbf{y})}{2}, & \text{若 } h_i \neq h_j; \\ 0\,, & \text{否则} \end{cases} \tag{23}$$

- 平衡整个集成器的多样性与准确度

$$\mathrm{TDAS}(\mathcal{H}) = \frac{1}{2} \sum_{h_i \in \mathcal{H}} \sum_{h_j \in \mathcal{H}} \mathrm{TDAC}(h_i, h_j) \tag{24}$$

形式化集成剪枝任务为目标最大化问题

- 集成剪枝 $\leftrightarrow$ 目标函数最大化

$$\max_{\mathcal{P}\subset\mathcal{H},|\mathcal{P}|=k} \text{TDAS}(\mathcal{P}) \tag{25}$$

形式化集成剪枝任务为目标最大化问题

- 集成剪枝 $\leftrightarrow$ 目标函数最大化

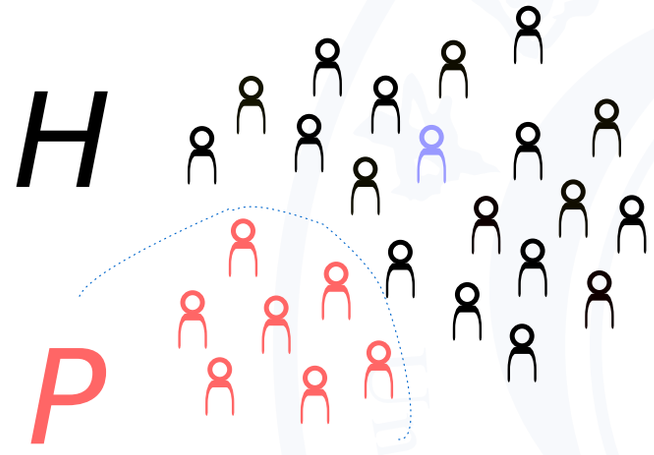
$$\max_{\mathcal{P}\subset\mathcal{H},|\mathcal{P}|=k} \text{TDAS}(\mathcal{P}) \tag{25}$$

- 目标

$$\operatorname{argmax}_{\mathcal{P}\subset\mathcal{H},|\mathcal{P}|=k} \text{TDAS}(\mathcal{P}) \tag{26}$$

即求 $\mathcal{P}$ 使之满足 $\mathcal{P} \subset \mathcal{H}, |\mathcal{P}| = k$.

集中式的基于目标最大化的集成剪枝算法



$$\underset{h_i \in \mathcal{H} \setminus \mathcal{P}}{\operatorname{argmax}} \sum_{h_j \in \mathcal{P}} \mathrm{TDAC}(h_i, h_j)$$

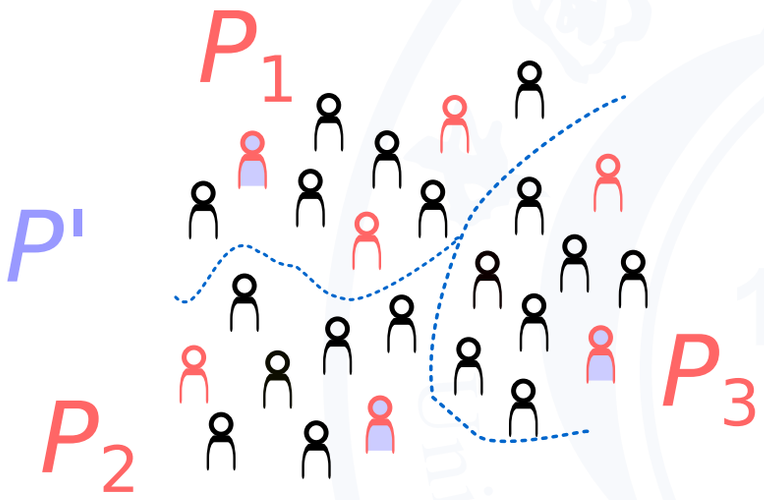
算法 3：集中式的基于目标最大化的集成剪枝算法 (*COMEP*)

Input: 原始集成器集合 $\mathcal{H}$, 代表剪枝后子集成器规模的阈值 k

Output: 剪枝后的子集成器集合 $\mathcal{P}$ (满足 $\mathcal{P} \subset \mathcal{H}$ 和 $|\mathcal{P}| \leqslant k$)

1: $\mathcal{P} \leftarrow$ 从 $\mathcal{H}$ 中选择任意一个基分类器 h_i
2: **for** $2 \leqslant i \leqslant k$ **do**
3: $\quad h^* \leftarrow$
4: $\quad$ 将 h^* 从 $\mathcal{H}$ 中移入 $\mathcal{P}$
5: **end for**

分布式的基于目标最大化的集成剪枝算法



$$\underset{\mathcal{T}\in\{\mathcal{P}_1,\ldots,\mathcal{P}_m,\mathcal{P}'\}}{\operatorname{argmax}} \ \mathrm{TDAS}(\mathcal{T})$$

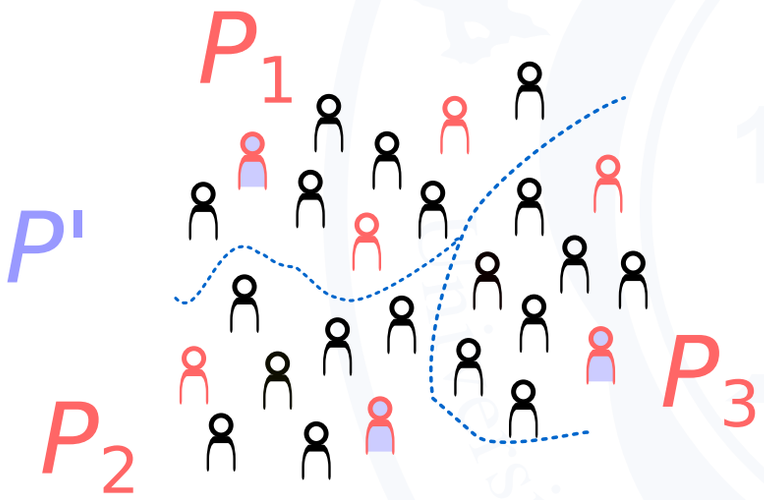
算法 4：分布式的基于目标最大化的集成剪枝算法 (*DOMEP*)

Input: 原始集成器集合 $\mathcal{H}$, 代表剪枝后子集成器规模的阈值 k, 可并行执行的机器数 m

Output: 剪枝后的子集成器集合 $\mathcal{P}$ (满足 $\mathcal{P} \subset \mathcal{H}$ 和 $|\mathcal{P}| \leqslant k$)

1: 将 $\mathcal{H}$ 随机均匀划分成 m 组，即 $\mathcal{H}_1, \mathcal{H}_2, ..., \mathcal{H}_m$
2: **for** $1 \leqslant i \leqslant m$ **do**
3: $\quad \mathcal{P}_i \leftarrow COMEP\ (\mathcal{H}_i, k)$
4: **end for**
5: $\mathcal{P}' \leftarrow COMEP\ (\cup_{i=1}^{m} \mathcal{P}_i, k)$
6: $\mathcal{P} \leftarrow$

可通用的分布式集成剪枝框架



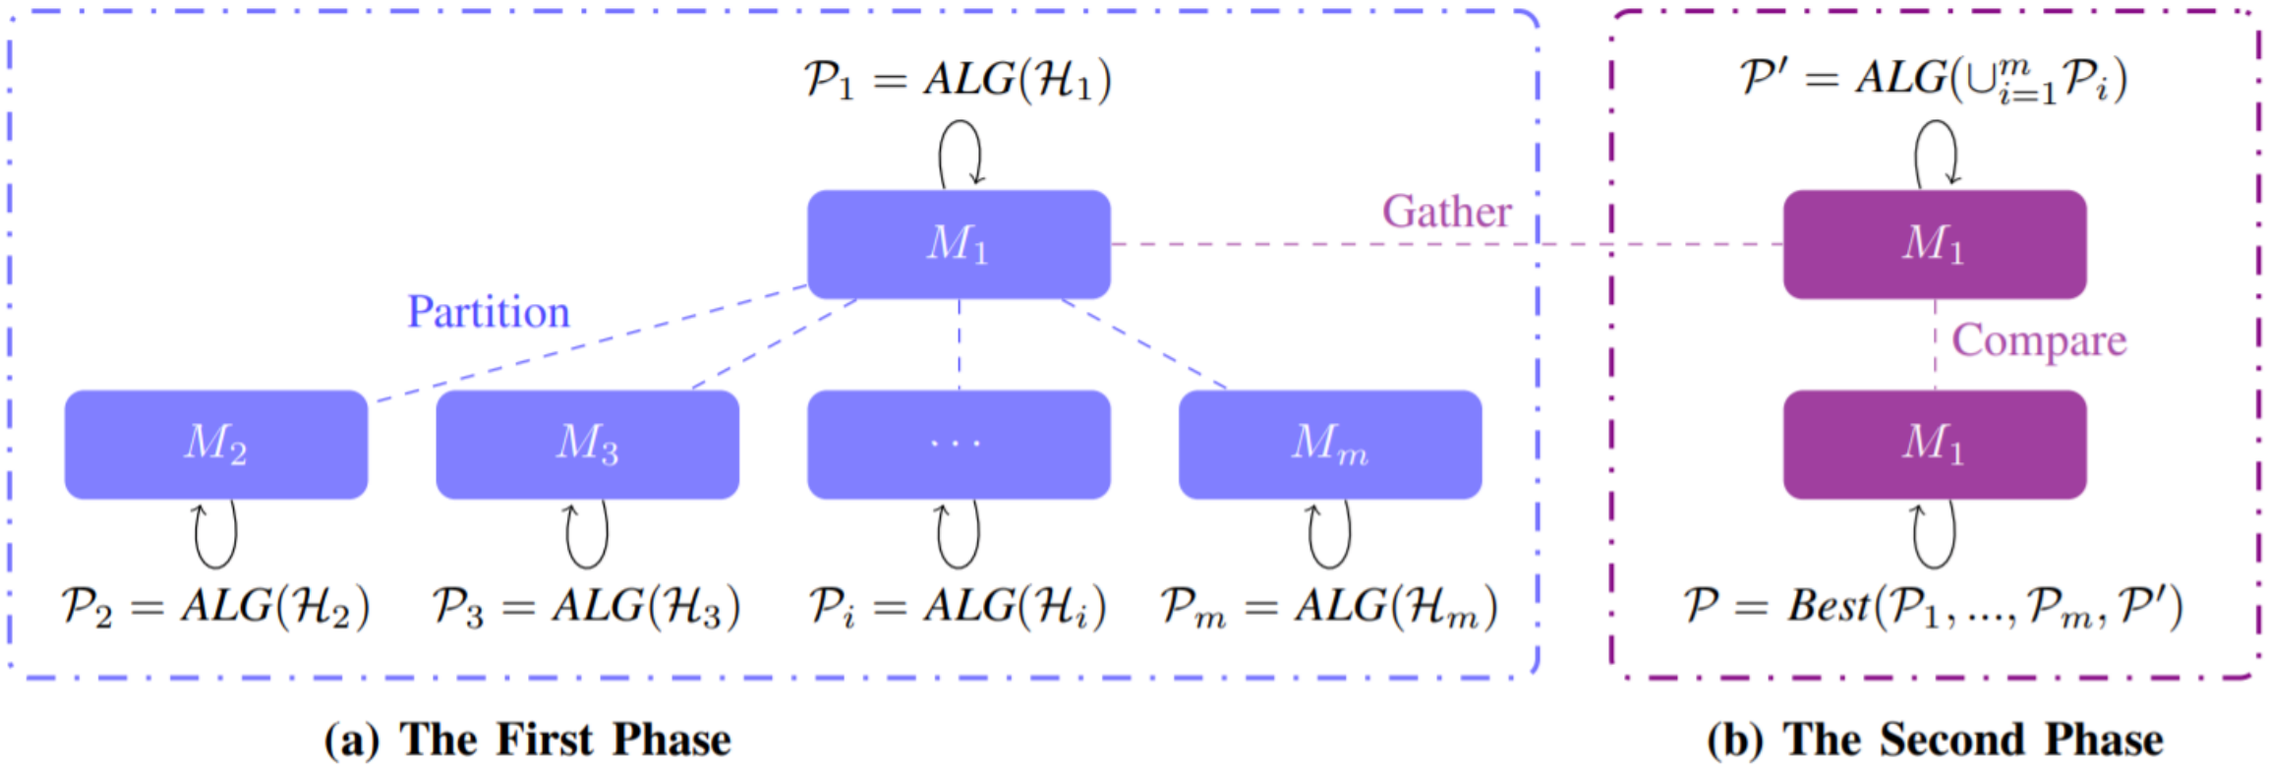
算法 5：可通用的分布式集成剪枝框架 ($EPFD$)

Input: 原始集成器集合 $\mathcal{H}$, 可并行执行的机器数 m, 任意一种集成剪枝方法 ALG

Output: 剪枝后的子集成器集合 $\mathcal{P}$ (满足 $\mathcal{P} \subset \mathcal{H}$)

1: 将 $\mathcal{H}$ 随机均匀划分成 m 组，即 $\{\mathcal{H}_i\}_{i=1}^{m}$
2: **for** $1 \leqslant i \leqslant m$ **do**
3: $\quad \mathcal{P}_i \leftarrow$ 任意剪枝算法 ALG 在集成器 $\mathcal{H}_i$ 上的输出
4: **end for**
5: $\mathcal{P}' \leftarrow$ 任意剪枝算法 ALG 在集成器 $\cup_{i=1}^{m}\mathcal{P}_i$ 上的输出
6: $\mathcal{P} \leftarrow$ 根据某些准则，选出 $\mathcal{P}_1, ..., \mathcal{P}_m$ 与 $\mathcal{P}'$ 中最好的一个，其中比较准则可以自定，如根据准确度比较

技术方案



(a) The First Phase **(b) The Second Phase**

Figure 11: 算法 5 的示意图：可通用的分布式集成剪枝框架 (Ensemble Pruning Framework in a Distributed Setting, *EPFD*)。注意：(1) *ALG* 可以是现有剪枝方法中的任意一个，包括 *COMEP*。(2) 最终的输出结果 $\mathcal{P}$ 是根据某种准则对比 $\mathcal{P}_1, ..., \mathcal{P}_m$ 和 $\mathcal{P}'$ 而得到的，这种准则可以是准确度，也可以是 *DOMEP* 中的 TDAS(·).

评估 *COMEP*: 剪枝算法对比

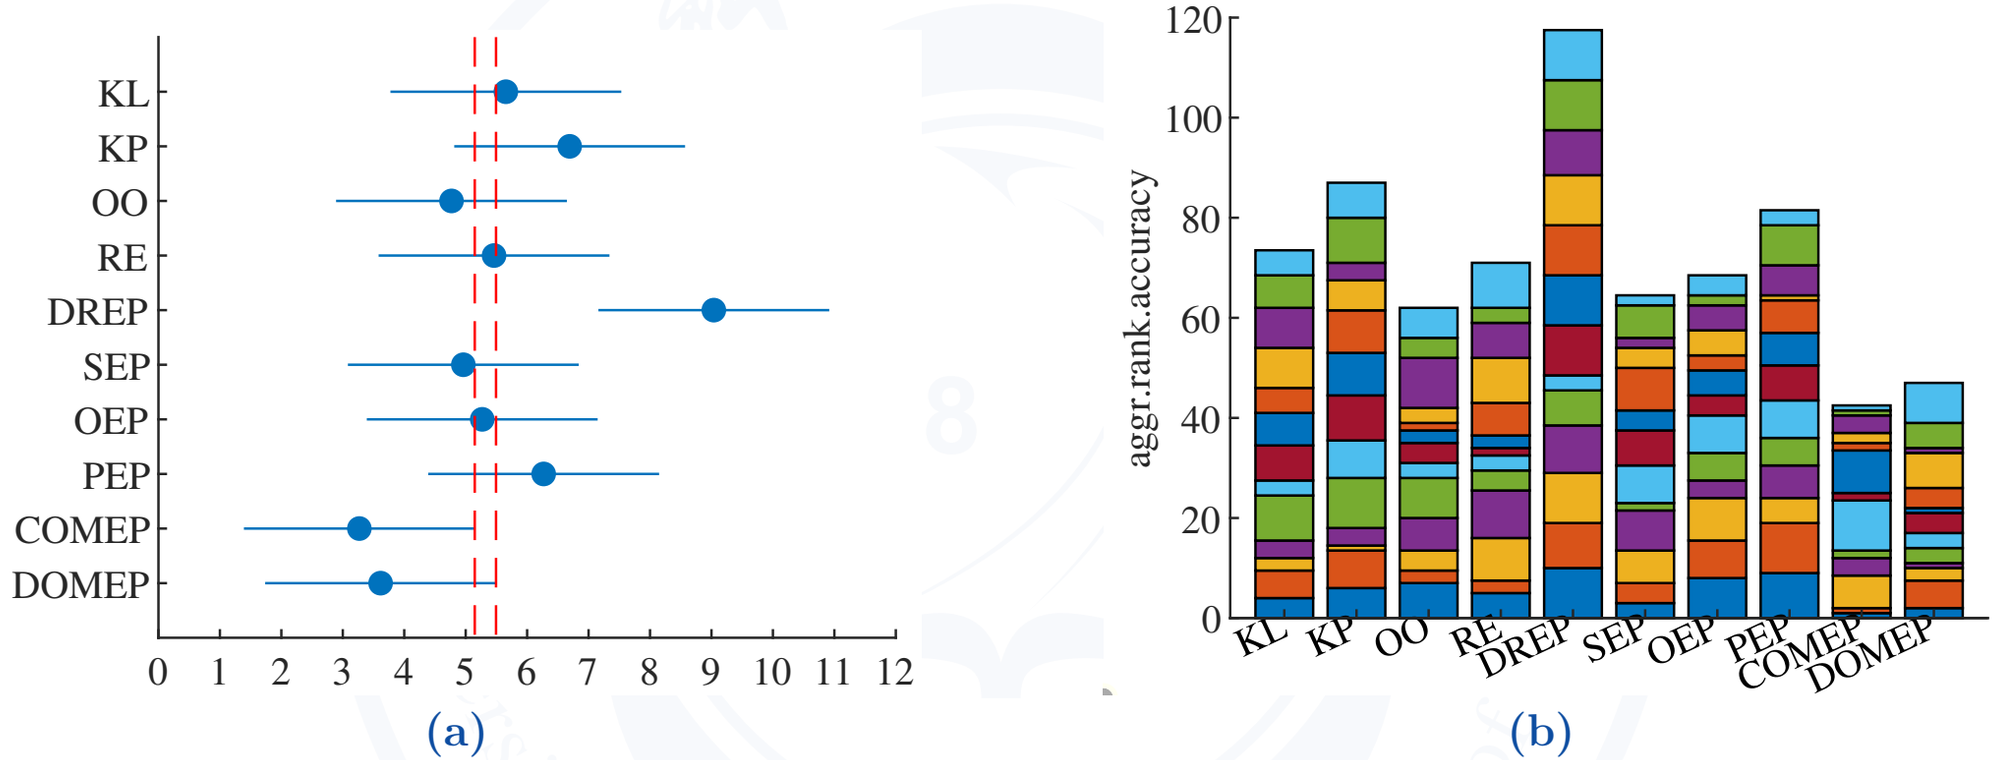


Figure 12: 基准剪枝算法和 *COMEP*、*DOMEP* 在测试准确度上的对比图。(a) Friedman 检验图 (两种方法间若没有重叠则代表着有显著差异) [4]；(b) 每种剪枝方法根据测试准确度排序的总计序值图 (序值越小，则该方法越优) [5]。

评估 *DOMEP*: *DOMEP* vs. *COMEP*

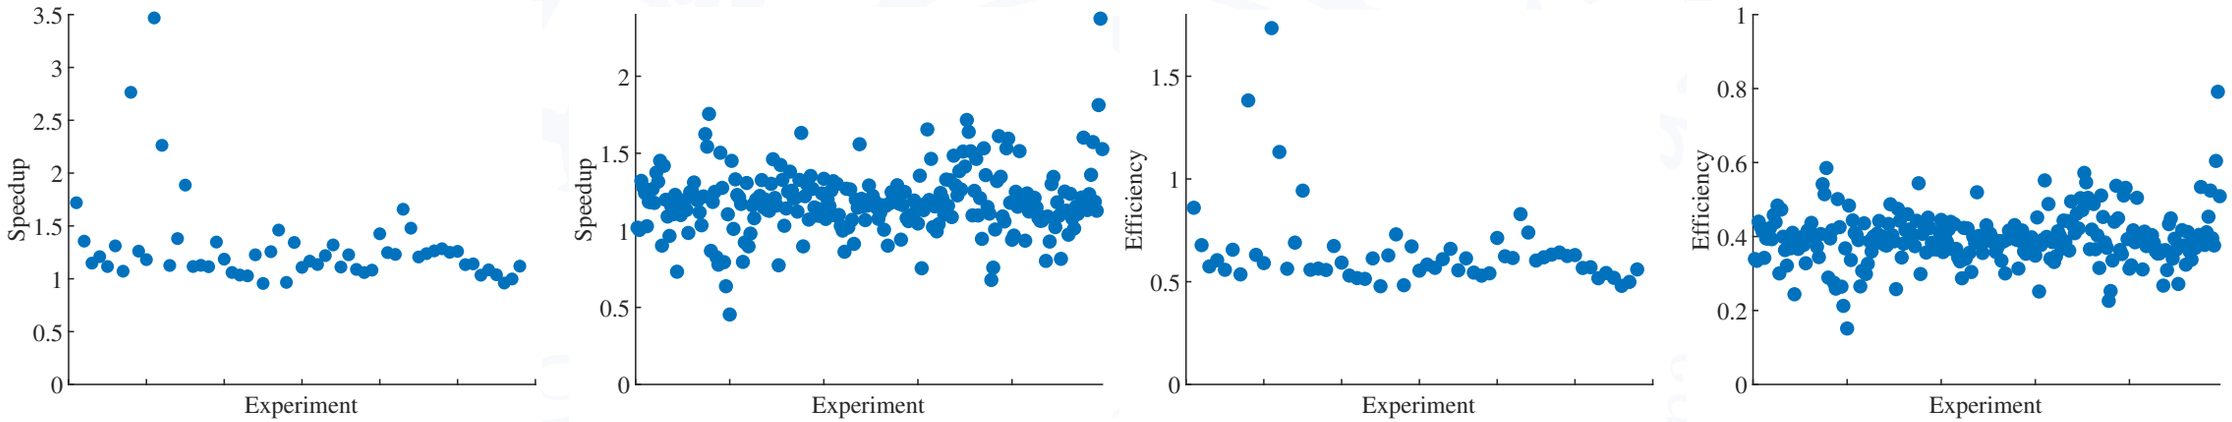


Figure 13: 算法 *COMEP* 与 *DOMEP* 的加速比和效率对比。(a) 使用两台机器的加速比。(b) 使用三台机器的加速比。(c) 使用两台机器的效率。(d) 使用三台机器的效率。

评估 *EPFD*: 应用到基准算法

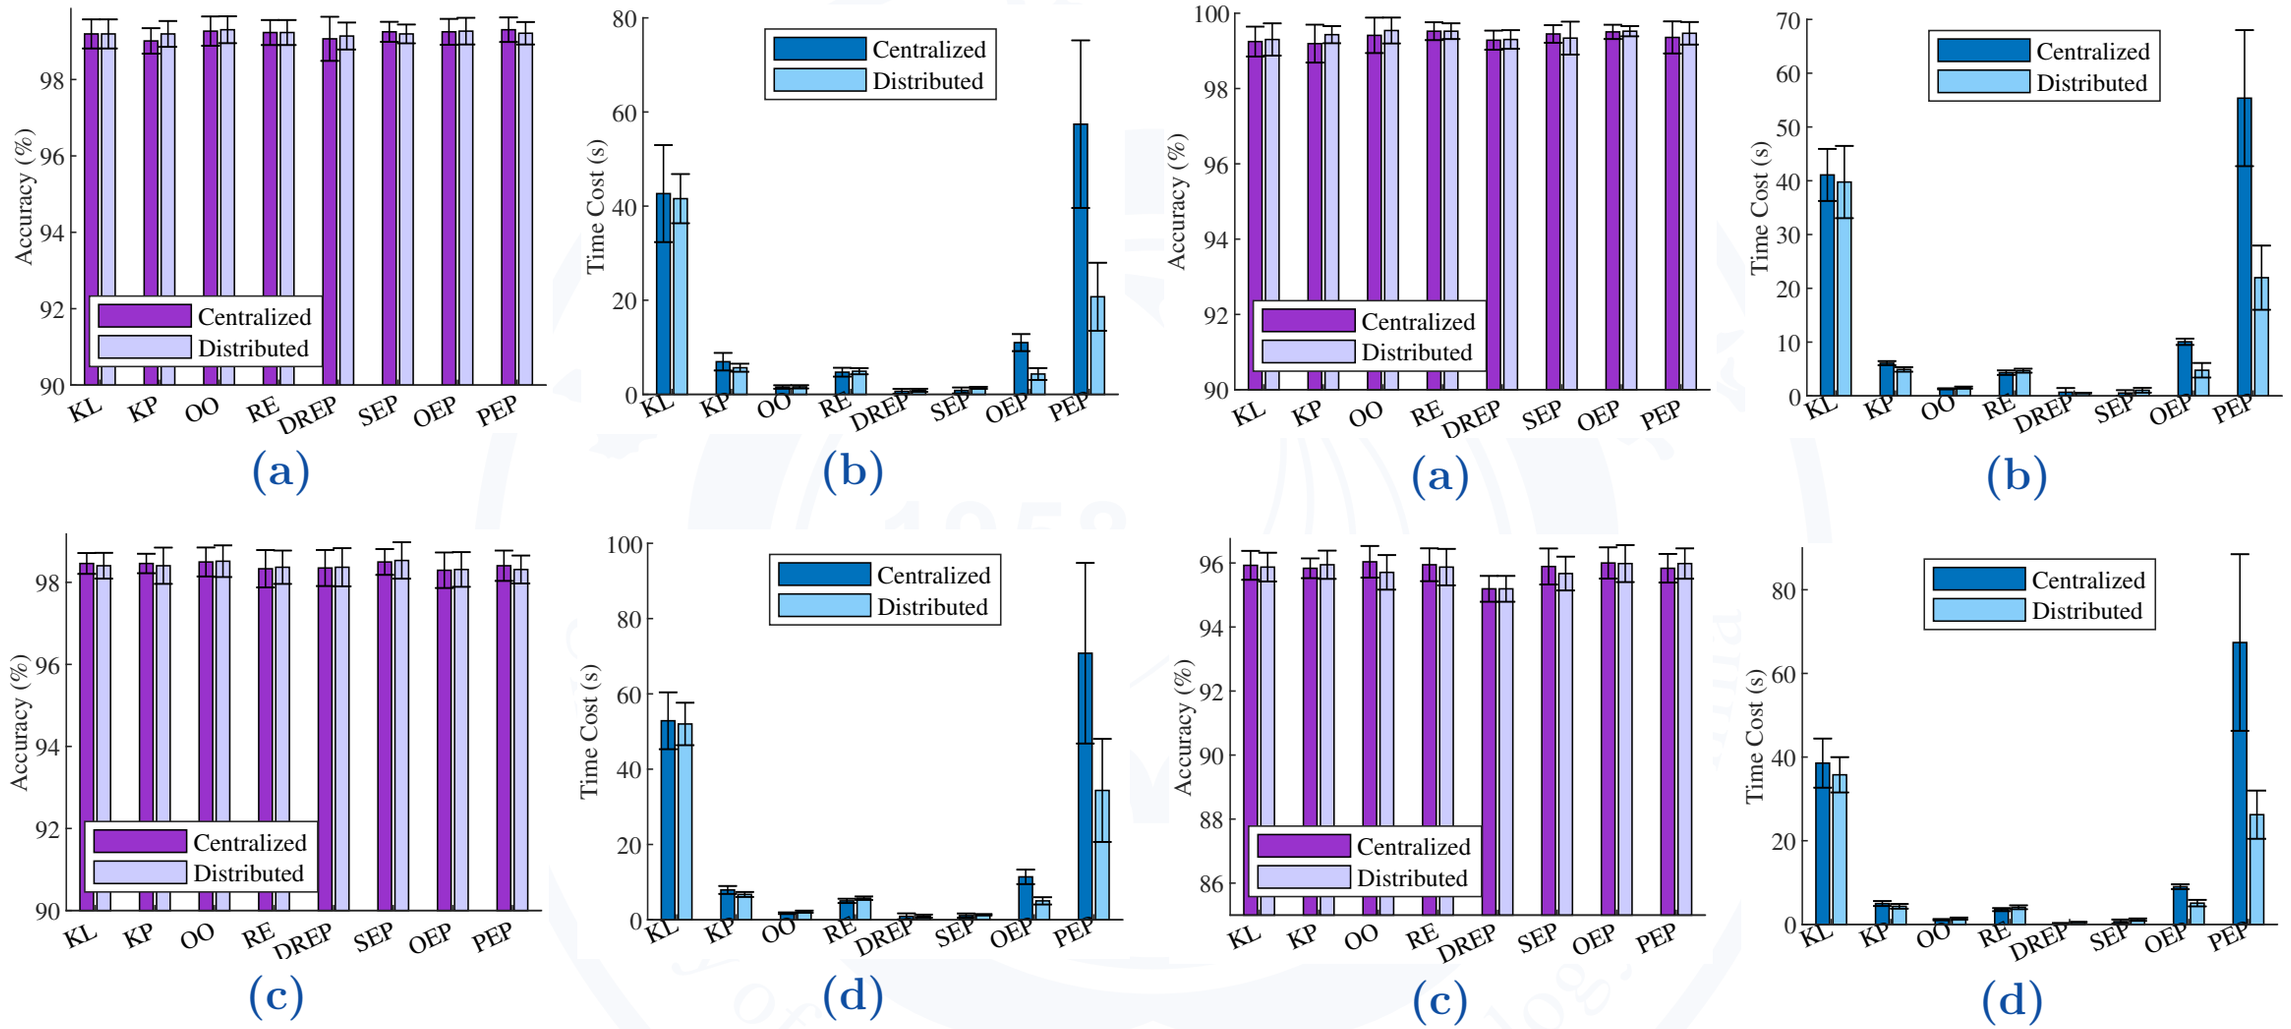


Figure 14: 现有剪枝方法与其分布式版本在 Sensor-Readings 数据集上的实验结果对比 (即测试准确度/时间代价)，使用自助法来解决二分类问题。(a–b) 使用决策树作为基分类器; (c–d) 使用 k-近邻分类器作为基分类器。

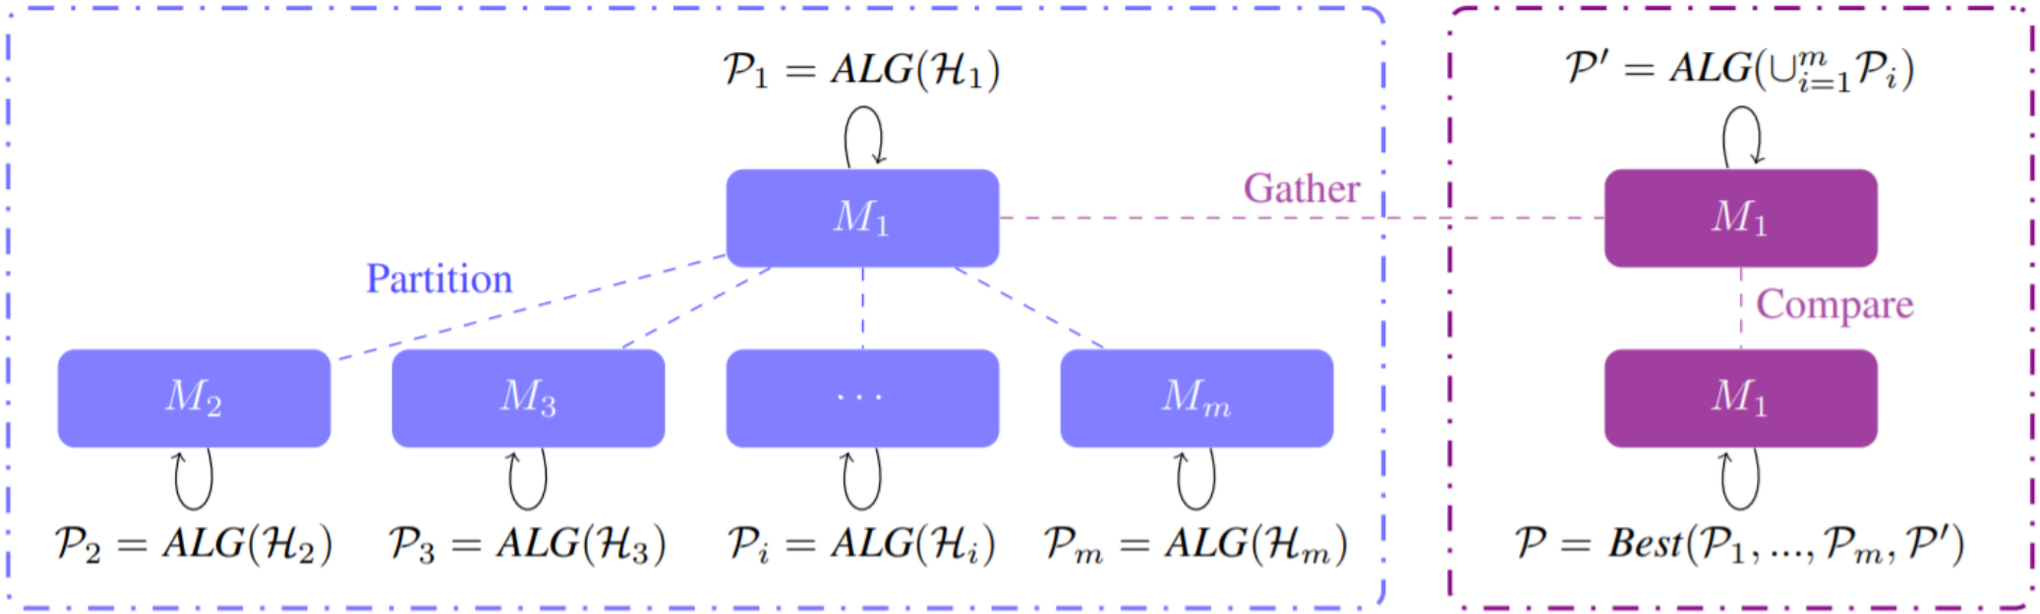
Figure 15: 现有剪枝方法与其分布式版本在 Sensor-Readings 数据集上的实验结果对比 (即测试准确度/时间代价)，使用自助法来解决多分类问题。(a–b) 使用决策树作为基分类器; (c–d) 使用 k-近邻分类器作为基分类器。

本章小结

- 利用信息熵来平衡准确度和多样性
  - 集中式的 基于目标最大化的集成剪枝算法 (*COMEP*)
  - 分布式的 基于目标最大化的集成剪枝算法 (*DOMEP*)

$$\mathrm{TDAC}(h_i, h_j) = \lambda \mathrm{VI}(\mathbf{h}_i, \mathbf{h}_j) + (1-\lambda)\frac{\mathrm{MI}(\mathbf{h}_i, \mathbf{y}) + \mathrm{MI}(\mathbf{h}_j, \mathbf{y})}{2}$$

- 可通用的分布式集成剪枝框架 (*EPFD*)



(a) The First Phase **(b) The Second Phase**

大纲

1 研究意义

2 分类问题中集成器的多样性与泛化性能的关系

3 基于信息熵的集成剪枝方法及其通用并行框架

4 神经架构搜索中的集成子结构剪枝
- 背景意义
- 方法介绍
- 实验评估
- 本章小结

5 总结与展望

6 附录

深度神经网络

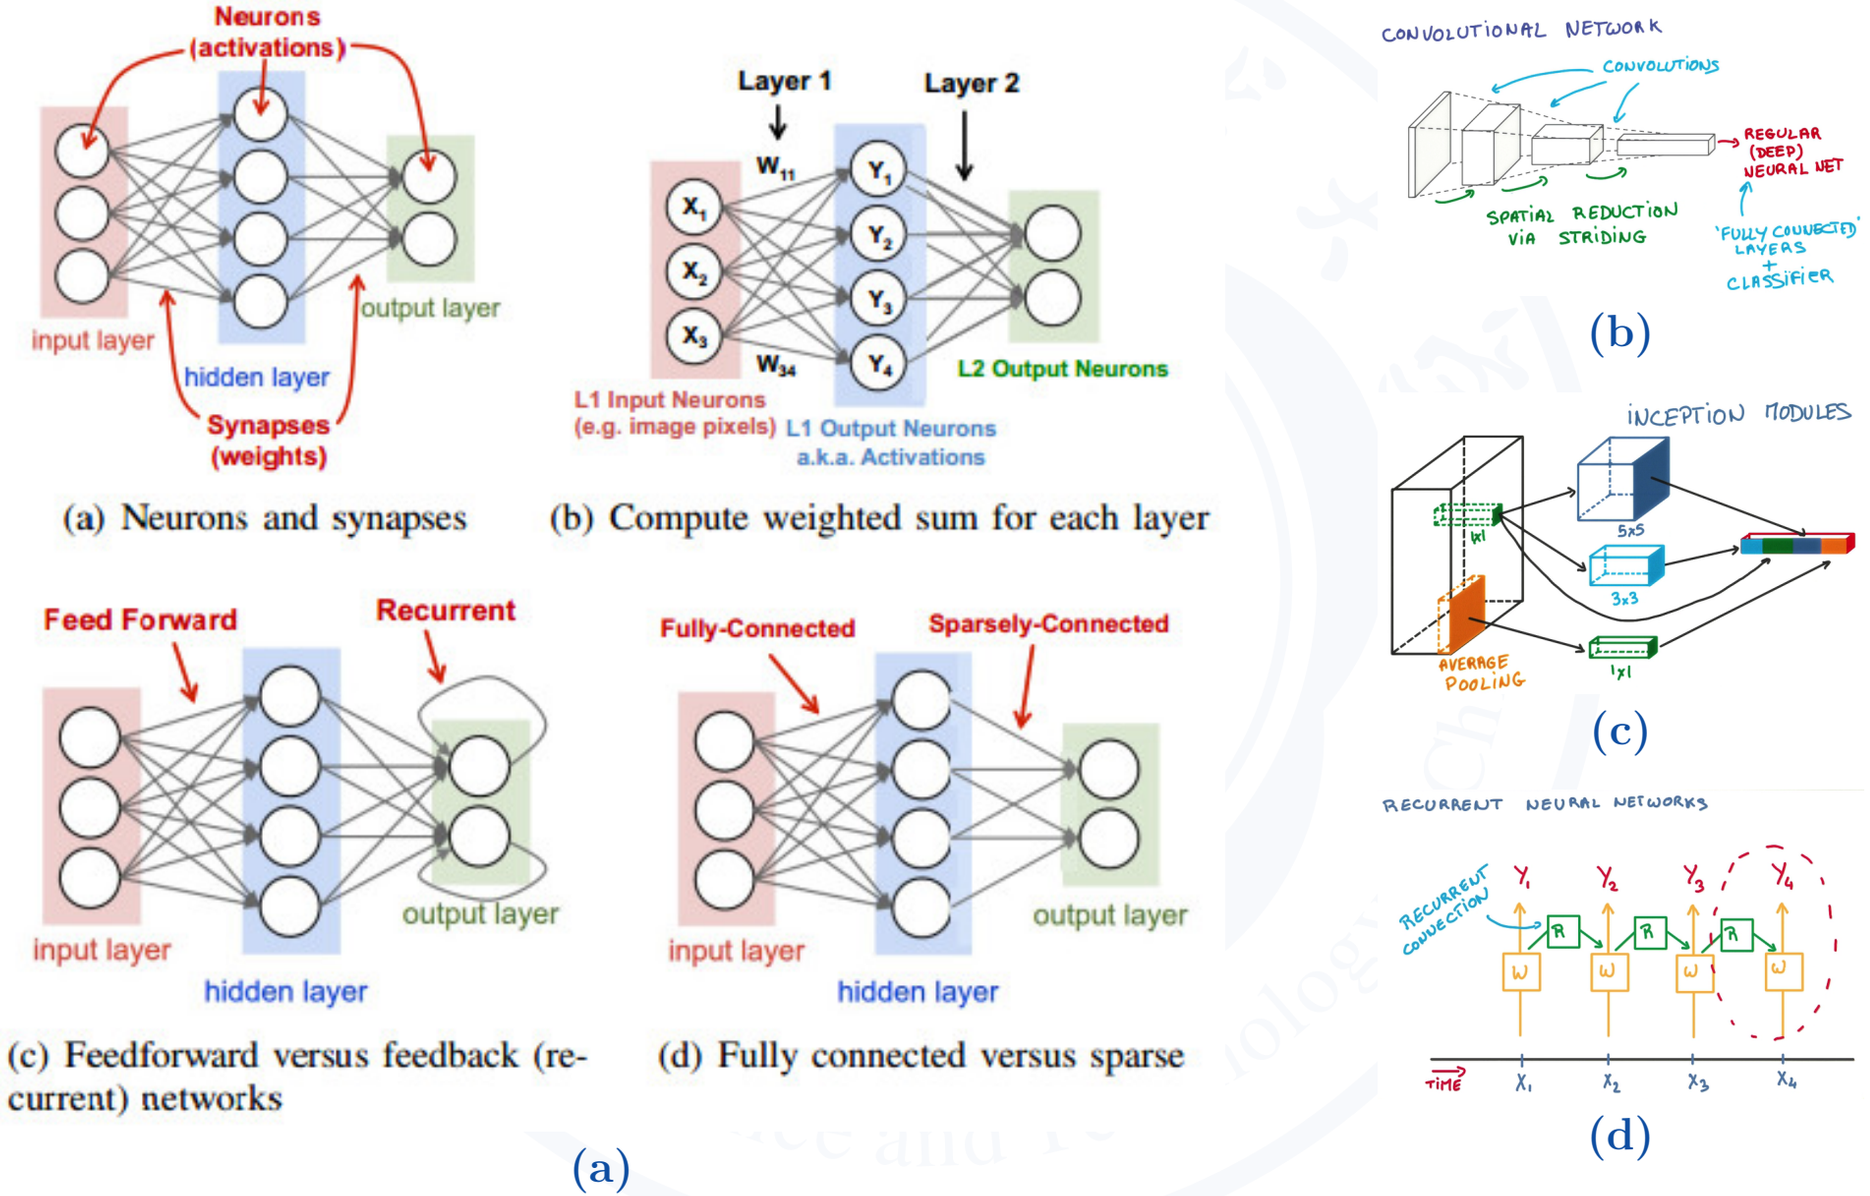


Figure 16: 深度神经网络 (Deep Neural Networks, DNNs)

神经架构搜索

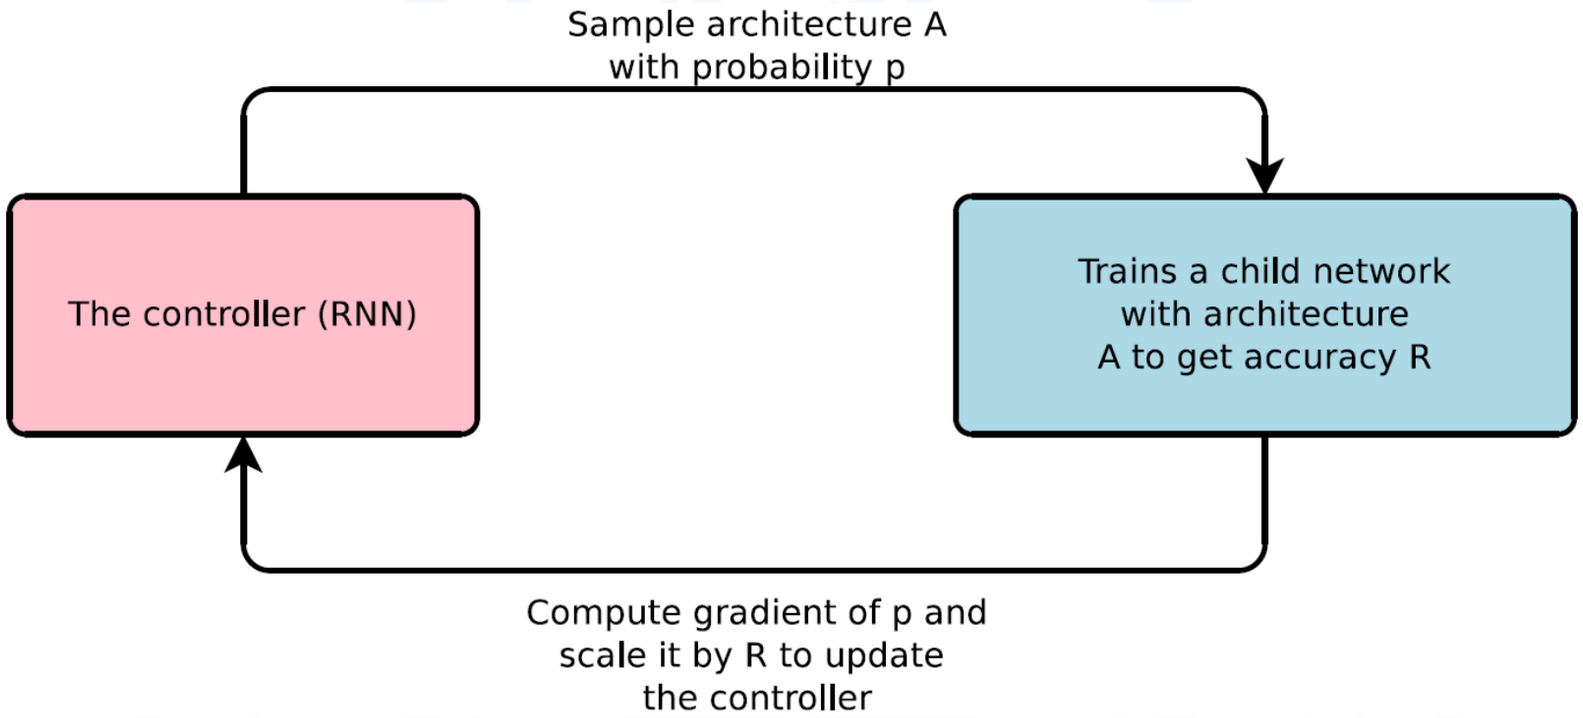


Figure 17: 神经架构搜索 (Neural Architecture Search, NAS)[1]的概况 [8]

- *CIFAR-10*: 800 networks being trained on 800 GPUs concurrently at any time
- *Penn Treebank (PTB)*: 400 networks being trained on 400 GPUs concurrently at any time
- *WMT14 English → German translation*: 12 workers and each one uses 8 GPUs

[1]Zoph et al. [8], "Neural architecture search with reinforcement learning," *ICLR*, 2017.

神经架构搜索 + 集成学习

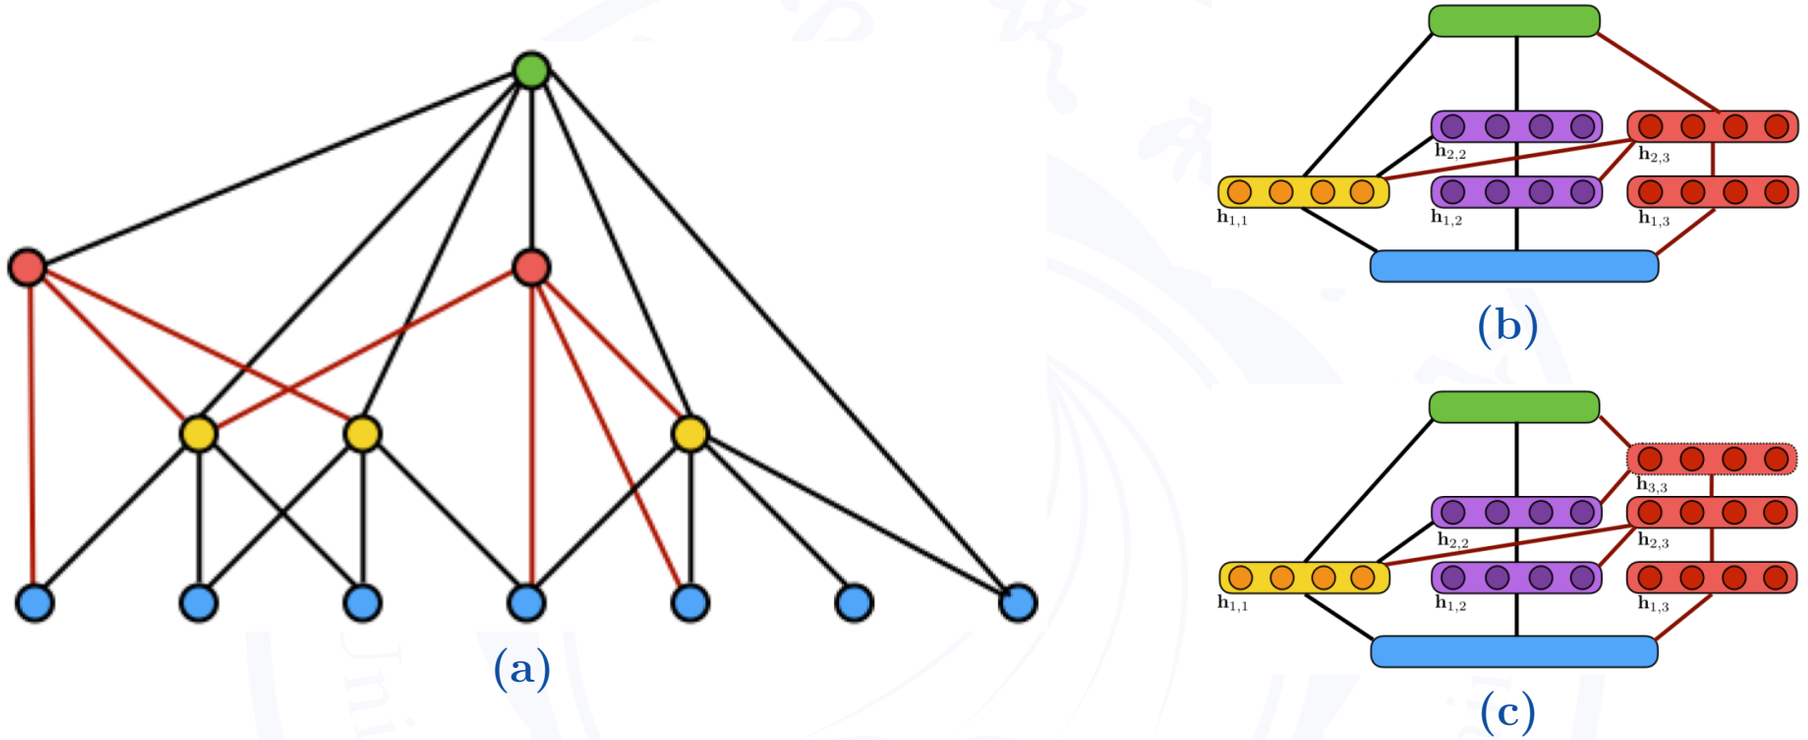


Figure 18: 例 AdaNet[1] [9]; BoostResNet[2]; AdaNAS[3] [10].

注: **AdaNet** (a) 通用网络结构示例; (b–c) 神经网络的增量构建说明.

[1]Cortes et al. [9], "Adanet: Adaptive structural learning of artificial neural networks," *ICML*, 2017: 874–883.

[2]Huang et al. [11], "Learning deep resnet blocks sequentially using boosting theory," *ICML*, 2018.

[3]Macko et al. [10], "Improving neural architecture search image classifiers via ensemble learning," *arXiv preprint arXiv:1903.06236*, 2019.

神经架构搜索 + 集成学习

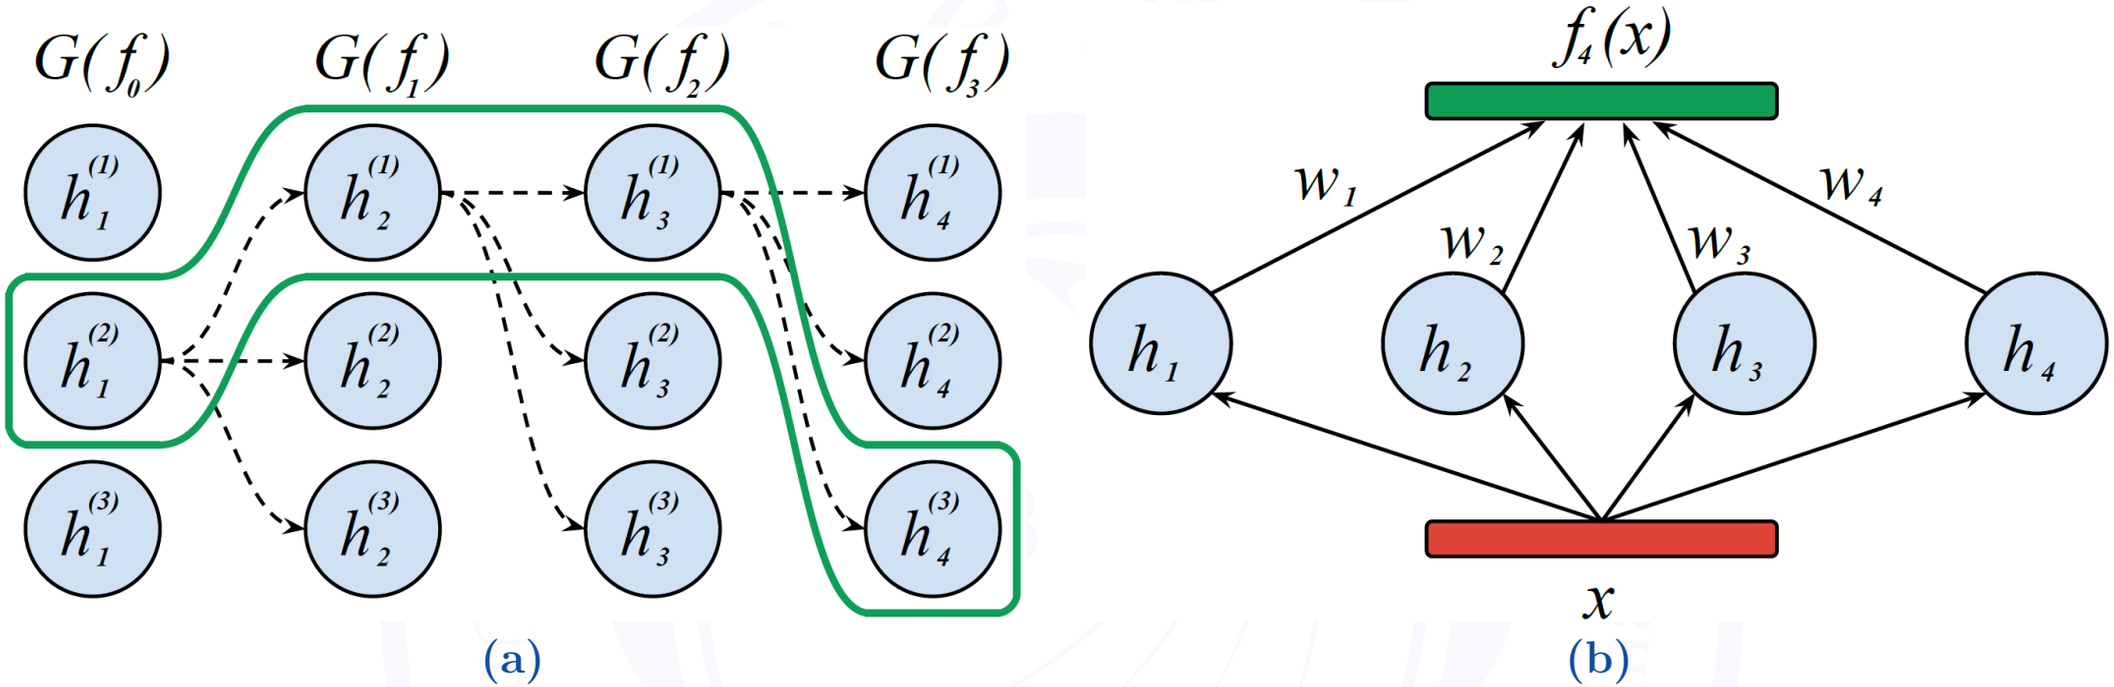


Figure 18: 例 AdaNet[1] [9]; BoostResNet[2]; AdaNAS[3] [10].

注: **AdaNAS** (a) 四个迭代的搜索过程说明; (b) 最终集成器的说明.

[1]Cortes et al. [9], "Adanet: Adaptive structural learning of artificial neural networks," *ICML*, 2017: 874–883.

[2]Huang et al. [11], "Learning deep resnet blocks sequentially using boosting theory," *ICML*, 2018.

[3]Macko et al. [10], "Improving neural architecture search image classifiers via ensemble learning," *arXiv preprint arXiv:1903.06236*, 2019.

基准算法与问题定义

对于任意输入 $\boldsymbol{x} \in \mathcal{X}$，其输出与所有中间层单元相连，即

$$f(\boldsymbol{x}) = \sum_{k=1}^{l} \mathbf{w}_k \cdot \mathbf{h}_k(\boldsymbol{x}) \tag{27}$$

- 其中 $\sum_{k=1}^{l} \|\mathbf{w}_k\| = 1$

基准算法与问题定义

对于任意输入 $\boldsymbol{x} \in \mathcal{X}$，其输出与所有中间层单元相连，即

$$f(\boldsymbol{x}) = \sum_{k=1}^{l} \mathbf{w}_k \cdot \mathbf{h}_k(\boldsymbol{x}) \tag{27}$$

- 其中 $\sum_{k=1}^{l} \|\mathbf{w}_k\| = 1$
- 且 $\mathbf{h}_k = \left[h_{k,1}, \ldots, h_{k,n_k} \right]^{\mathsf{T}}$

基准算法与问题定义

对于任意输入 $\boldsymbol{x} \in \mathcal{X}$，其输出与所有中间层单元相连，即

$$f(\boldsymbol{x}) = \sum_{k=1}^{l} \mathbf{w}_k \cdot \mathbf{h}_k(\boldsymbol{x}) \tag{27}$$

- 其中 $\sum_{k=1}^{l} \|\mathbf{w}_k\| = 1$
- 且 $\mathbf{h}_k = \left[h_{k,1}, ..., h_{k,n_k}\right]^{\mathsf{T}}$
- 令 $h_{k,j}$ 表示第 k^{th} 层的一个神经元所表示的函数

$$h_{k,j}(\boldsymbol{x}) = \sum_{s=0}^{k-1} \mathbf{u}_s \cdot \phi_s\big(\mathbf{h}_s(\boldsymbol{x})\big) \tag{28}$$

注意 $\phi_s(\mathbf{h}_s) = \big(\phi_s(h_{s,1}), ..., \phi_s(h_{s,n_s})\big)$

基准算法与问题定义

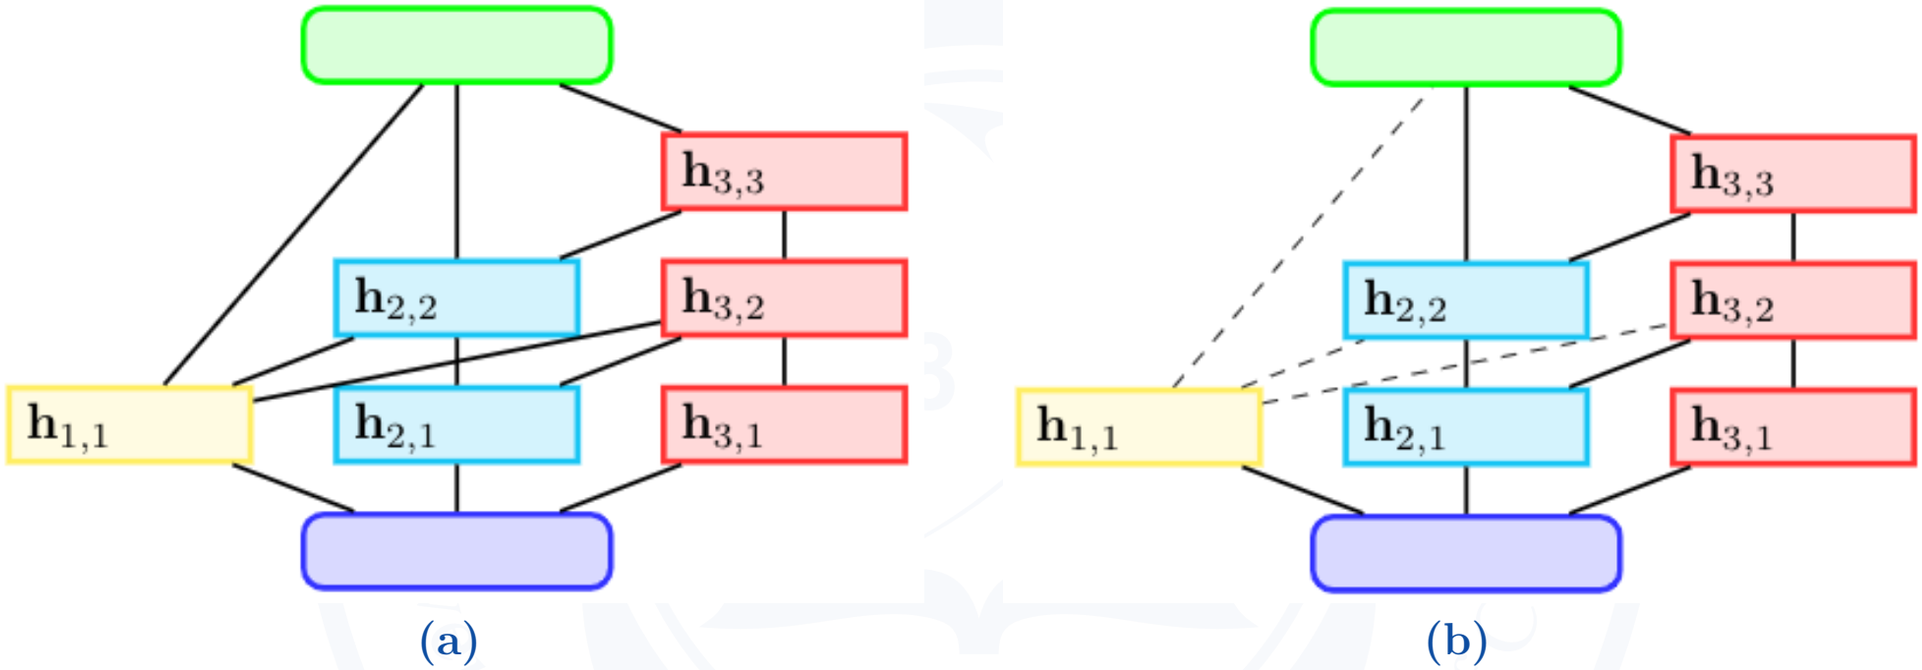
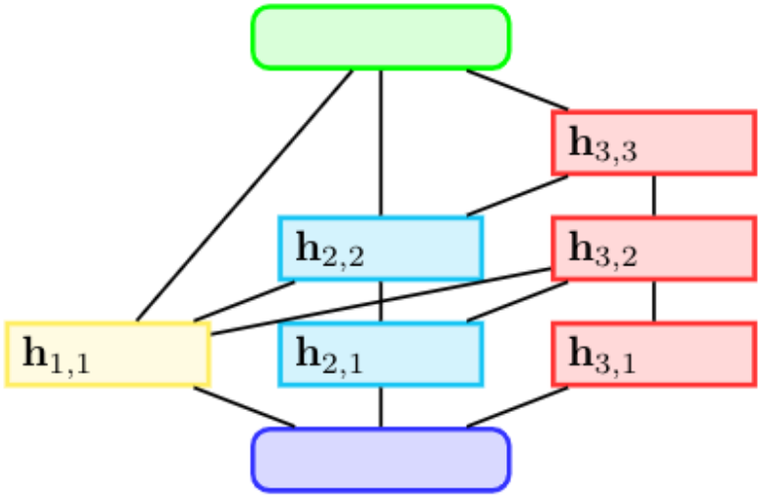


Figure 19: 在神经架构的增量构建过程中，*SAEP* 与 AdaNet 的差异说明图。(a) AdaNet [9]: 在两个神经元块之间的直线表示这些块之间是全连接的。(b) *SAEP*: 只有一些价值较高的神经元块将会被保留在最终的神经网络架构中 (被剪掉的神经元块使用黑色虚线表示)，这也是该算法与 AdaNet 的关键性不同所在。

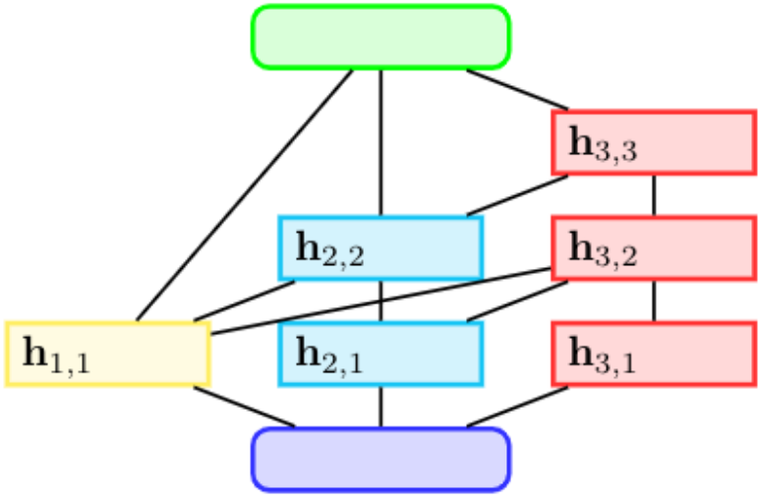
神经架构搜索中的集成子结构剪枝（*SAEP*）



生成新候选子结构的目标函数

$$\mathcal{L}_g(\mathbf{w}) = \hat{R}_{S,\rho}(f) + \Gamma \tag{29}$$

神经架构搜索中的集成子结构剪枝（*SAEP*）



生成新候选子结构的目标函数

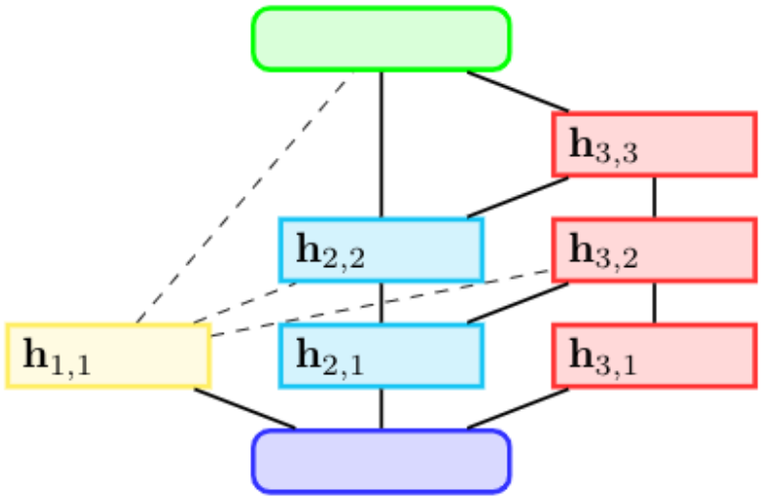
$$\mathcal{L}_g(\mathbf{w}) = \hat{R}_{S,\rho}(f) + \Gamma \tag{29}$$

将二分类扩展为多分类问题

$$g(\boldsymbol{x}, y, f) = 2\mathbb{I}\big(f(\boldsymbol{x}) = y\big) - 1 \tag{30}$$

$$\hat{R}_{S,\rho}(f) = \frac{1}{m}\sum_{i=1}^{m} \mathbb{I}\big(g(\boldsymbol{x}_i, y_i, f) \leqslant \rho\big) \tag{31}$$

神经架构搜索中的集成子结构剪枝 (*SAEP*)



算法 6 ：神经架构搜索中的集成子结构剪枝 (*SAEP*)

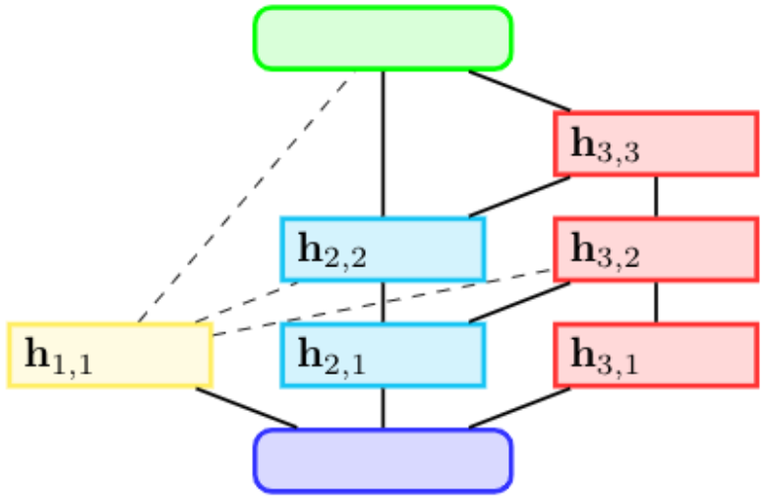
Input: 数据集 $\mathcal{D} = \{(\boldsymbol{x}_i, y_i)\}_{i=1}^{m}$, 迭代次数 T.

Output: 最终的集成网络结构 f.

$f^{(0)} = \mathbf{0}$, and $l^{(0)} = 1$;
for $1 \leqslant t \leqslant T$ **do**
  $\mathbf{w}', \mathbf{h}' = \operatorname{argmin}_{\mathbf{w},\mathbf{h}} \mathcal{L}_g(f^{(t-1)} + \mathbf{w} \cdot \mathbf{h})$
    s.t. $\mathbf{h} \in \mathcal{H}_{l^{(t-1)}}$;
  $\mathbf{w}'', \mathbf{h}'' = \operatorname{argmin}_{\mathbf{w},\mathbf{h}} \mathcal{L}_g(f^{(t-1)} + \mathbf{w} \cdot \mathbf{h})$
    s.t. $\mathbf{h} \in \mathcal{H}_{l^{(t-1)}+1}$;
  if $\mathcal{L}_g(f^{(t-1)} + \mathbf{w}' \cdot \mathbf{h}') \leqslant \mathcal{L}_g(f^{(t-1)} + \mathbf{w}'' \cdot \mathbf{h}'')$ **then**
    $f^{(t)} = f^{(t-1)} + \mathbf{w}' \cdot \mathbf{h}'$;
  else
    $f^{(t)} = f^{(t-1)} + \mathbf{w}'' \cdot \mathbf{h}''$;
  end if
  根据某种特定准则选择出 $\mathbf{w}_p$，如基于随机选择的剪枝、基于准确度性能的剪枝和式 (32) 中的 $\mathcal{L}_d(\mathbf{w})$、或基于信息熵的剪枝和式 (33) 中的 $\mathcal{L}_e(\mathbf{w})$;
  将所选出的 $\mathbf{w}_p$ 设为零;
end for

神经架构搜索中的集成子结构剪枝（*SAEP*）

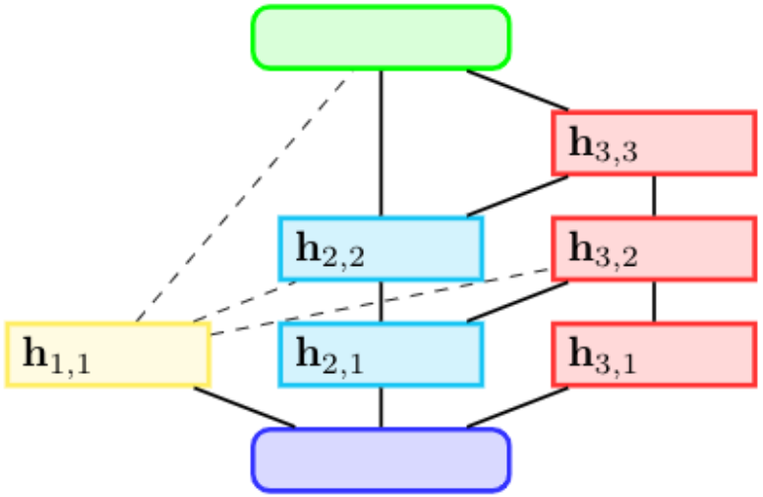
修剪子网络的策略包括三种：



SAEP: 基于随机选择的剪枝 (*PRS*)

修剪子网络的策略包括三种:

- 基于 随机选择 的剪枝 (*PRS*)

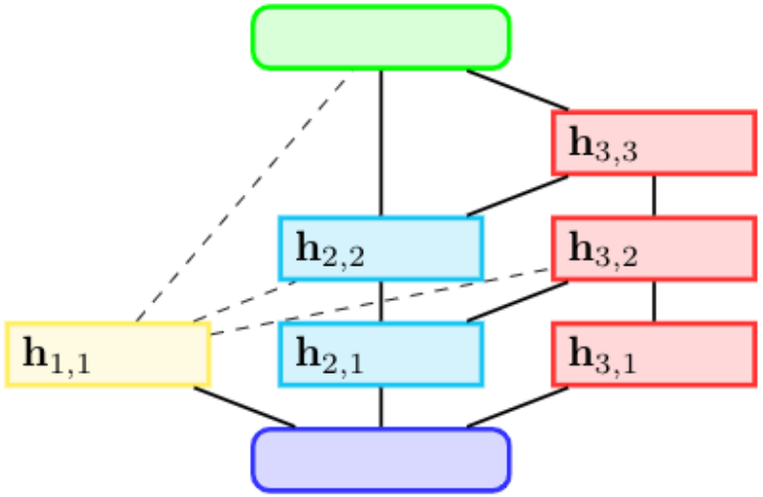


1. 是否剪枝?
2. 如果剪枝，剪掉哪个子结构?

SAEP: 基于准确度性能的剪枝 (PAP)

修剪子网络的策略包括三种:

- 基于随机选择的剪枝 (*PRS*)
- 基于 准确度性能 的剪枝 (*PAP*)



$$\mathcal{L}_d(\mathbf{w}) = \frac{1}{m}\sum_{i=1}^{m}\left[g(\boldsymbol{x}_i, y_i, f) - g(\boldsymbol{x}_i, y_i, f - \mathbf{w}\cdot\mathbf{h})\right] \tag{32}$$

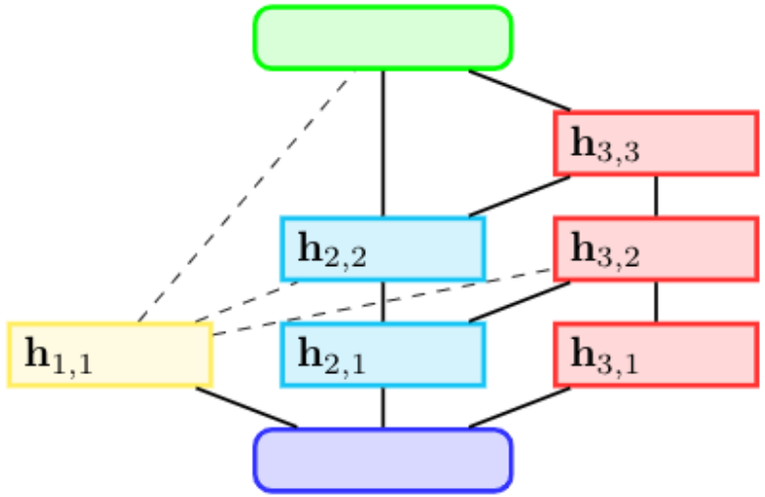
原因

$$\mathbb{E}_{(\boldsymbol{x},y)\sim\mathcal{D}}\left[g(\boldsymbol{x}, y, f) - g(\boldsymbol{x}, y, f - \mathbf{w}_j\cdot\mathbf{h}_j)\right] \leqslant 0$$

SAEP: 基于信息熵的剪枝 (*PIE*)

修剪子网络的策略包括三种:

- 基于随机选择的剪枝 (*PRS*)
- 基于准确度性能的剪枝 (*PAP*)
- 基于 信息熵 的剪枝 (*PIE*)



$$\mathcal{L}_e(\mathbf{w}_i) = \sum_{\mathbf{w}_j \cdot \mathbf{h}_j \in \mathcal{f} \setminus \{\mathbf{w}_i \cdot \mathbf{h}_i\}} \mathcal{L}_p(\mathbf{w}_i, \mathbf{w}_j) \tag{33}$$

其中

$$\mathcal{L}_p(\mathbf{w}_i, \mathbf{w}_j) = (1-\alpha)\,\mathrm{VI}(\boldsymbol{w}_i, \boldsymbol{w}_j) + \alpha \frac{\mathrm{MI}(\boldsymbol{w}_i, \mathbf{y}) + \mathrm{MI}(\boldsymbol{w}_j, \mathbf{y})}{2}$$

评估 *SAEP*

Table 1: 多分类问题中的 (子) 集成网络结构的实验性能结果表

数据集	测试准确度 (%)				子网络的数量 (最终保留/总计生成)			
	AdaNet	*PRS*	*PAP*	*PIE*	AdaNet	*PRS*	*PAP*	*PIE*
MNIST	94.75	94.76	94.72	**94.85**	12/12	5/10	6/13	**3**/12
Fashion-MNIST	83.80	83.83	84.13	**84.17**	9/9	**3**/12	4/9	**3**/8
CIFAR-10	54.12	54.52	54.32	**55.06**	10/10	**2**/9	**2**/10	3/13
	AdaNet.W	*PRS.W*	*PAP.W*	*PIE.W*	AdaNet.W	*PRS.W*	*PAP.W*	*PIE.W*
MNIST	**94.88**	94.63	94.74	94.72	12/12	4/10	5/12	**2**/11
Fashion-MNIST	83.74	83.68	84.11	**84.11**	8/8	5/8	5/11	**3**/9
CIFAR-10	54.11	54.40	54.36	**54.44**	9/9	5/13	**2**/7	3/13

数据集	多样性 (分歧度量)				时间代价 (min)			
	AdaNet	*PRS*	*PAP*	*PIE*	AdaNet	*PRS*	*PAP*	*PIE*
MNIST	0.8885	0.8938	0.9167	**0.9844**	**55.89**	77.01	100.95	85.08
Fashion-MNIST	0.9063	0.7344	0.8919	**0.9688**	41.74	80.48	63.42	**40.78**
CIFAR-10	0.8960	**0.9609**	0.8672	0.6927	**95.38**	149.41	167.46	222.67
	AdaNet.W	*PRS.W*	*PAP.W*	*PIE.W*	AdaNet.W	*PRS.W*	*PAP.W*	*PIE.W*
MNIST	0.9235	0.9648	0.9336	**0.9688**	117.85	211.95	142.95	**97.09**
Fashion-MNIST	0.9202	**0.9586**	0.8984	0.9505	**37.46**	59.93	70.89	61.24
CIFAR-10	0.8624	0.9227	0.5938	**0.9740**	**123.49**	296.71	137.38	338.00

* 注：在 MNIST 和 Fashion-MNIST 的实验中所使用的子网络类型是多层感知机 (MLPs)，而在 CIFAR-10 的实验中所使用的子网络类型是卷积神经网络 (CNNs)。

SAEP 可生成独特的更深层次的子网络结构

Table 2: 在 Fashion-MNIST 数据集里“上衣 v.s. 套头衫”标签对的实验中，剪枝后子集成网络结构所保留的子网络结构的具体情形

	测试准确度 (%)	多样性 (分歧度量)	规模 (保留/生成)	索引
AdaNet	96.45	0.9119	9 / 9	[0,1,2,3,4,5,6,7,8]
PRS	96.55	0.8073	4 / 12	[8,9,11,12]
PAP	96.80	1.0000	2 / 8	[6,8]
PIE (α=0.5)	96.65	0.7758	5 / 11	[1,3,5,10,11]
PIE (α=0.4)	96.85	0.9844	3 / 5	[0,2,5]
PIE (α=0.1)	97.00	1.0000	2 / 6	[1,6]

* 注：在本次实验中所使用的子网络结构类型是多层感知机。

参数 α 值的影响

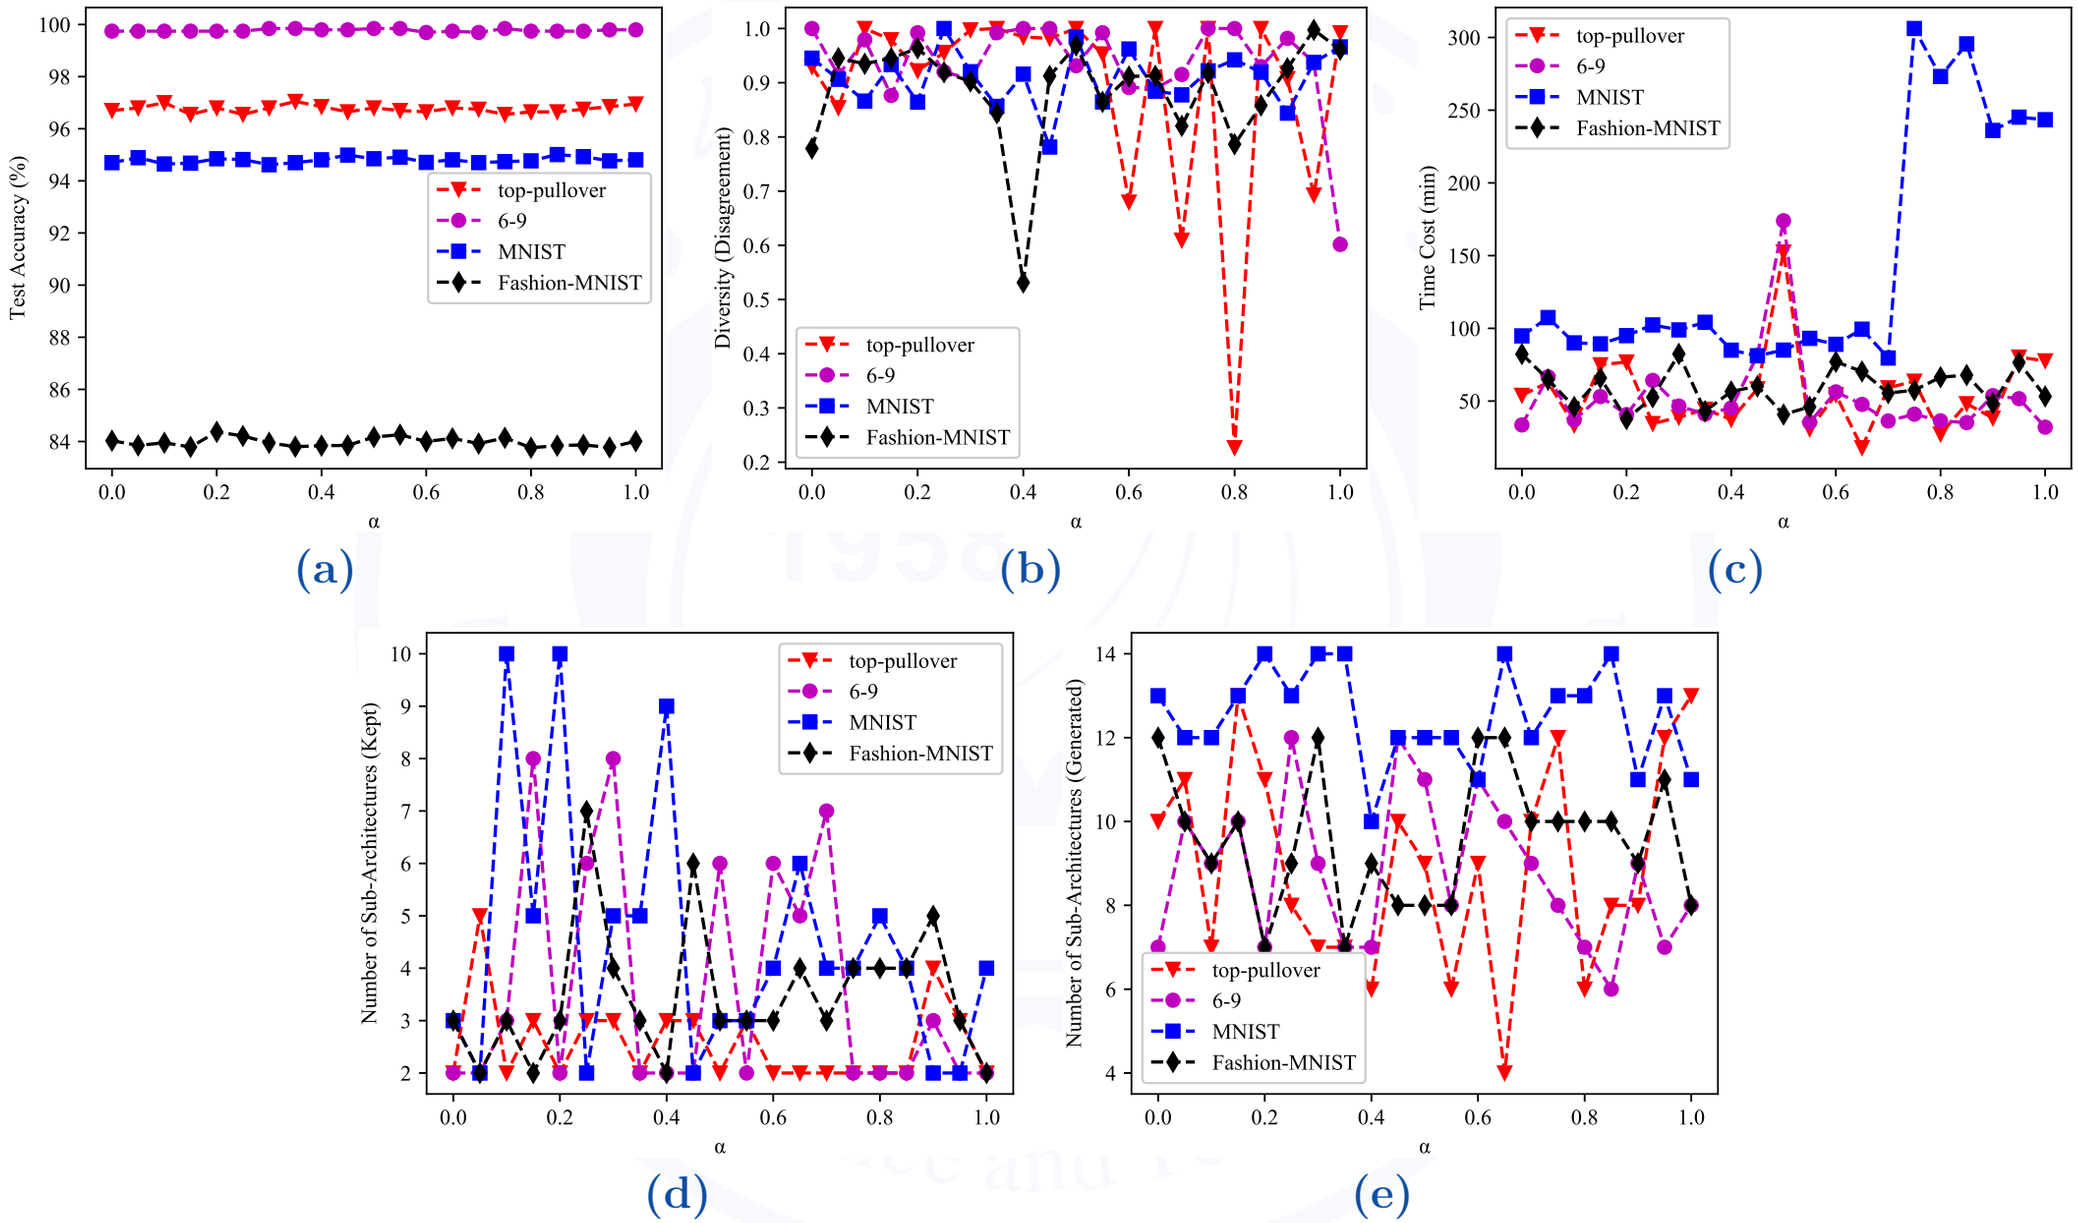
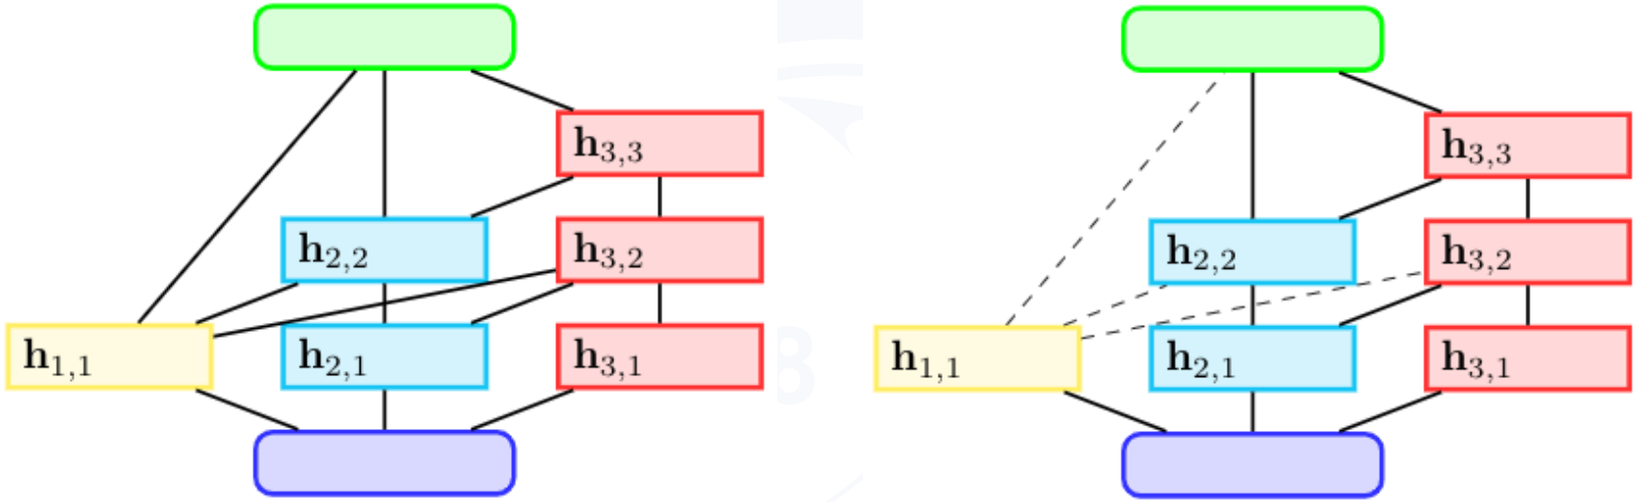


Figure 20: 图像分类任务中 *SAEP* 使用 α 值的不同所造成的影响

本章小结



- 神经架构搜索中的集成子结构剪枝 (*SAEP*)
  - 基于随机选择的剪枝 (*PRS*)
  - 基于准确度性能的剪枝 (*PAP*)
  - 基于信息熵的剪枝 (*PIE*)

大纲

1 研究意义

2 分类问题中集成器的多样性与泛化性能的关系

3 基于信息熵的集成剪枝方法及其通用并行框架

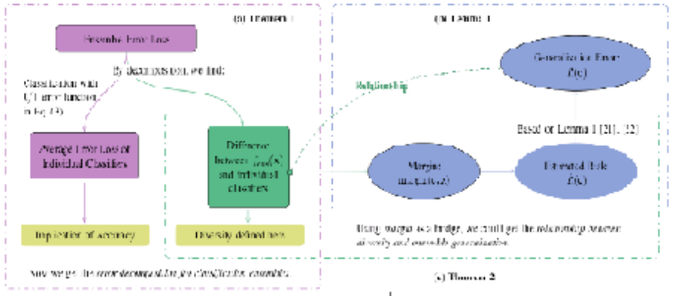
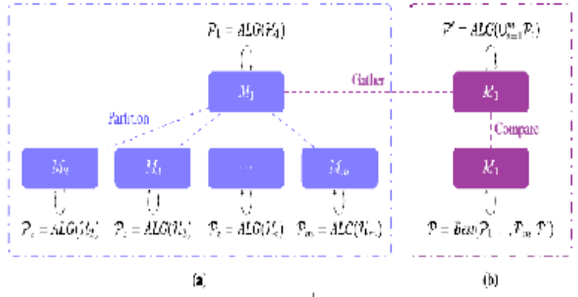
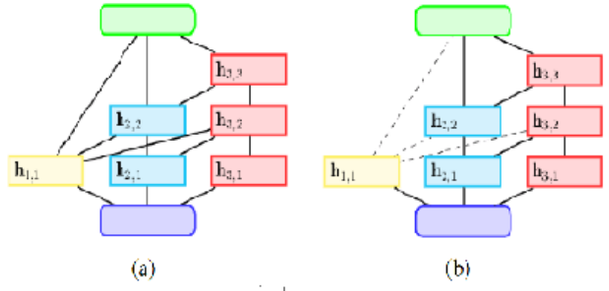
4 神经架构搜索中的集成子结构剪枝

5 总结与展望

6 附录

研究整体框架

分类集成问题中的多样性研究与应用

	集成学习领域		其他领域
主要挑战	多样性在集成器中所起的作用不够明确	多样性与准确度因有所冲突而难以平衡	在利用集成学习的同时却忽视了多样性
出发点	探索多样性在集成学习中的作用	合理平衡二者并加速剪枝过程	弥补多样性的缺口研究
技术方案			
研究内容	分类集成问题中集成器的多样性与泛化性能的关系	基于信息熵的集成剪枝方法及其通用并行框架	神经架构搜索中的集成子结构剪枝

创新之处

- 二分类问题
  - 使用 0/1 损失函数的误差分解，及多样性度量
  - 量化集成器的多样性与其泛化性能之间的关系
  - 显式利用多样性进行剪枝，提高集成器性能
- 多分类问题
  - 从信息熵角度对集成器的准确度和多样性进行平衡，将集成剪枝问题形式化为目标函数最大化问题
  - 将剪枝方法并行化，可以加速算法执行过程
- 应用到其他领域
  - 利用多样性获取一个规模更小的子集成网络结构
  - 当网络结构中多样性不足时，可探索更深层的网络结构

主要研究成果

- 已发表论文
  1. **Yijun Bian**, Yijun Wang, Yaqiang Yao, and Huanhuan Chen, "Ensemble Pruning based on Objection Maximization with a General Distributed Framework," *IEEE Transactions on Neural Networks and Learning Systems*, Accepted.
- 评审中论文
  1. **Yijun Bian** and Huanhuan Chen, "When does Diversity Help Generalization in Classification Ensembles?" *IEEE Transactions on Cybernetics*, Under Review.
  2. **Yijun Bian**, Qingquan Song, Mengnan Du, Jun Yao, Huanhuan Chen, and Xia Hu, "Sub-Architecture Ensemble Pruning in Neural Architecture Search," *IEEE Transactions on Neural Networks and Learning Systems*, Under Review.

参考文献

[1] DIETTERICH T. Ensemble methods in machine learning[C]//MCS: volume 1857. 2000: 1-15.

[2] HERBRICH R, GRAEPEL T. A pac-bayesian margin bound for linear classifiers: Why svms work[C]//NIPS. 2001: 224-230.

[3] HERBRICH R, GRAEPEL T. A pac-bayesian margin bound for linear classifiers[J]. IEEE T Inform Theory, 2002, 48 (12): 3140-3150.

[4] DEMŠAR J. Statistical comparisons of classifiers over multiple data sets[J]. J Mach Learn Res, 2006, 7(Jan): 1-30.

[5] QIAN C, YU Y, ZHOU Z H. Pareto ensemble pruning[C]//AAAI. 2015: 2935-2941.

[6] COVER T, THOMAS J. Elements of information theory[M]. John Wiley & Sons, 2012.

[7] ZADEH S, GHADIRI M, MIRROKNI V, et al. Scalable feature selection via distributed diversity maximization[C]// AAAI. 2017: 2876-2883.

[8] ZOPH B, LE Q. Neural architecture search with reinforcement learning[C]//ICLR. 2017.

[9] CORTES C, GONZALVO X, KUZNETSOV V, et al. Adanet: Adaptive structural learning of artificial neural networks [C]//ICML. 2017: 874-883.

[10] MACKO V, WEILL C, MAZZAWI H, et al. Improving neural architecture search image classifiers via ensemble learning [J]. arXiv preprint arXiv:1903.06236, 2019.

[11] HUANG F, ASH J, LANGFORD J, et al. Learning deep resnet blocks sequentially using boosting theory[C]//ICML. 2018.

大纲

1 研究意义

2 分类问题中集成器的多样性与泛化性能的关系

3 基于信息熵的集成剪枝方法及其通用并行框架

4 神经架构搜索中的集成子结构剪枝

5 总结与展望

6 附录
- 分类问题中集成器的多样性与泛化性能的关系
- 基于信息熵的集成剪枝方法及其通用并行框架
- 神经架构搜索中的集成子结构剪枝

谢谢！

敬请各位老师批评指正

大纲

1. 研究意义
2. 分类问题中集成器的多样性与泛化性能的关系
3. 基于信息熵的集成剪枝方法及其通用并行框架
4. 神经架构搜索中的集成子结构剪枝
5. 总结与展望
6. 附录
   - 分类问题中集成器的多样性与泛化性能的关系
   - 基于信息熵的集成剪枝方法及其通用并行框架
   - 神经架构搜索中的集成子结构剪枝

评估 *EPBD*

Table 3: 对比现有剪枝算法与 *EPBD* 的性能，使用自助法来构建集成器

Data Set	Ensem	ES	KL	KP	OO	DREP	SEP	PEP	MRMR	MRMC	DiscEP	TSP.AP	TSP.DP	GMA	LCS	*EPBD*
waveform	89.09±1.27	84.34±8.76	83.48±8.39	83.48±8.39	89.47±0.40	89.35±0.66	89.03±0.83	89.19±0.81	88.43±0.94‡	89.43±0.82	89.37±0.38	**89.71±0.75**	88.19±0.95‡	88.51±1.29	88.95±1.37	89.53±0.48
heart	55.56±0.00	55.56±0.00	55.56±0.00	55.56±0.00	55.56±0.00	55.56±0.00	55.56±0.00	**55.93±0.74**	**55.93±0.74**	**55.93±0.74**	**55.93±0.74**	55.56±0.00	55.56±0.00	55.56±0.00	55.56±0.00	**55.93±0.74**
page	91.26±0.22‡	91.28±0.19	91.26±0.24	91.33±0.29	91.37±0.29	91.35±0.20	91.24±0.11	91.28±0.27	91.33±0.20	91.19±0.20‡	91.24±0.16	91.26±0.19	**91.39±0.21**	91.12±0.16‡	91.12±0.16‡	91.39±0.26
sensor (2d)	94.12±0.80‡	94.08±0.95‡	94.15±0.98	93.97±0.93‡	94.21±1.08	94.37±1.01	94.02±0.92‡	**94.41±0.83**	94.24±0.55	94.21±1.01	93.73±0.95‡	94.10±1.09	94.08±0.80	94.02±1.04‡	94.10±1.02	94.37±0.85
sensor (24d)	89.37±0.61	89.13±0.27	88.95±0.73	88.91±0.75	**89.39±1.38**	88.82±1.05‡	88.82±1.11‡	89.31±1.25	89.15±0.97	89.09±0.92	88.87±0.86	88.93±0.93‡	88.95±1.02	89.07±0.93	88.74±1.16	89.33±0.95
EEGEyeState	55.13±0.01	**55.13±0.00**	**55.13±0.00**	**55.13±0.00**	55.13±0.01	**55.13±0.00**	**55.13±0.00**	**55.13±0.00**	55.13±0.01	55.13±0.01	55.13±0.01	**55.13±0.00**	55.13±0.01	**55.13±0.00**	**55.13±0.00**	55.13±0.01
gmm (10d)	99.70±0.60	99.70±0.60	99.70±0.60	99.70±0.60	**99.80±0.40**	99.70±0.60	99.70±0.60	**99.80±0.40**	**99.80±0.40**	**99.80±0.40**	**99.80±0.40**	99.70±0.60	99.60±0.59	99.70±0.60	99.60±0.59	**99.80±0.40**
ames	61.17±4.01	58.54±7.61	55.77±6.67‡	56.50±4.72	59.71±6.93	57.96±5.57‡	58.54±4.53	59.85±5.28	59.12±4.21	57.66±3.72	**61.61±4.49**	60.44±4.78	59.71±6.04	56.50±2.64	59.56±3.53	61.02±5.80
wisconsin	96.89±0.55	96.44±0.55	96.44±0.86	96.89±0.73	96.59±1.00	96.59±0.76	96.00±0.59	96.44±0.98	96.74±0.76	96.89±1.09	97.04±0.47	96.74±1.00	96.89±0.55	96.59±0.36	**96.89±0.30**	96.89±0.73
ecoli	95.76±2.23	95.76±2.42	95.76±2.42	95.76±2.42	95.76±2.42	95.76±2.42	95.76±2.42	**96.36±2.06**	**96.36±2.06**	95.76±2.23	95.76±2.23	95.76±2.23	95.76±2.42	96.06±2.06	96.06±2.27	**96.36±2.06**
liver	62.90±2.98‡	61.16±2.49	62.03±5.75	65.22±2.43	63.77±3.04	65.51±3.60	64.64±3.38	66.38±2.96	65.80±2.98	63.19±2.98	62.90±2.84	61.74±2.98	64.93±3.82	61.45±6.12	61.74±4.36‡	**66.96±3.36**
yeast	69.59±4.61	67.77±2.86‡	67.70±2.36‡	69.39±1.66	69.73±3.27	65.41±2.60‡	69.80±4.23	69.39±3.44	69.86±3.06	69.12±2.89	68.24±3.82‡	68.58±3.15	68.72±3.44	67.36±3.66‡	68.45±3.95	**70.54±2.92**
sonar	80.00±6.62	76.59±5.69	78.05±6.90	79.02±6.28	80.49±6.54	80.00±5.85	79.51±3.65	79.51±5.89	**81.95±8.10**	80.49±6.36	76.10±4.97	79.02±3.31	76.10±6.79	79.51±7.49	80.49±6.17	80.49±7.07
wilt	93.90±1.34	93.71±1.49	94.37±0.85	93.34±1.51	94.33±0.87	92.12±1.81‡	93.90±1.44	93.59±1.59	94.33±0.98	94.35±0.93	94.00±1.25	94.46±0.95	93.86±1.00	93.92±1.44	93.75±1.17	**94.48±0.87**
spam	78.67±3.44	78.54±2.74	77.34±2.18	73.32±5.74	74.56±6.96	79.09±2.84	77.87±1.39	79.61±2.67	79.04±2.80	72.82±8.46	78.91±3.13	79.76±2.42	77.87±3.55	73.93±5.00	77.39±1.58	**79.80±2.41**
landsat	96.25±0.63	96.31±0.63	95.57±0.98	95.30±1.02	96.27±0.58	95.68±0.84	96.31±0.54	95.96±0.91	96.22±0.56	95.65±1.16	96.22±0.61	**96.33±0.50**	95.69±0.90	96.13±0.75	96.07±0.58	96.27±0.65
t-test (W/T/L)	3/13/0	2/14/0	2/14/0	1/15/0	0/16/0	4/12/0	2/14/0	0/16/0	1/15/0	1/15/0	2/14/0	1/15/0	1/15/0	4/12/0	2/14/0	—
Average Rank	7.47	10.84	11.47	11.03	6.00	9.41	9.78	6.56	5.13	7.88	8.28	8.22	9.28	11.44	10.69	2.53

[1] 表中所汇报的实验结果均是每种剪枝方法使用标准 5-交叉验证的实验在各个数据集的测试集上的平均准确度 (%) 与其相应的标准差。

[2] 通过在 5% 显著水平下的双尾成对 *t*-检验对比各算法之间是否有明显差异，其中 ‡ 和 † 分别表示 *EPBD* 显著优于或者是显著差于对比算法的性能；若无符号标记，则表示 *EPBD* 与相应对比算法之间没有显著差异。

[3] 表中最后两行分别展示了 *t*-检验的结果和各算法的平均序值。而 *t*-检验中的 “W/T/L” 则表示 *EPBD* 显著优于、并无显著不同或者显著差于相应的对比算法的次数。各算法的平均序值由 Friedman 检验 [4] 计算而得。

评估 *EPBD*

Table 3: 对比现有剪枝算法与 *EPBD* 的性能，使用自适应增强法来构建集成器

Data Set	Ensem	ES	KL	KP	OO	DREP	SEP	PEP	MRMR	MRMC	DiscEP	TSP.AP	TSP.DP	GMA	LCS	*EPBD*
spam	79.33±2.04	81.44±1.58	79.39±3.15	78.32±2.76	79.17±2.23	79.91±1.44	79.06±2.90	**81.85±1.36**	81.44±1.58	78.78±2.24	78.78±2.24	79.04±2.11	76.63±2.51	73.54±6.13	79.04±2.11	79.98±2.12
credit	77.96±0.06	77.93±0.06	77.93±0.13	77.91±0.12	77.99±0.08	77.99±0.09	77.93±0.09	77.95±0.08	77.98±0.14	77.98±0.09	77.96±0.14	77.91±0.13	77.88±0.11‡	77.86±0.10	77.95±0.06	**78.03±0.10**
page	90.40±0.12‡	90.35±0.26‡	90.40±0.27‡	90.29±0.33‡	90.93±0.32	**90.99±0.24**	90.49±0.32	90.88±0.35	90.60±0.25	90.93±0.32	90.91±0.31	**90.99±0.24**	90.22±0.42‡	90.80±0.32	90.77±0.38	**90.99±0.24**
shuttle	96.75±0.08‡	97.33±0.06‡	97.33±0.06‡	92.40±2.09‡	97.81±0.10	97.70±0.05‡	94.75±2.43	96.80±2.10	**97.85±0.05**	97.65±0.10‡	**97.85±0.05**	**97.85±0.05**	92.05±2.09‡	97.59±0.12‡	**97.85±0.05**	**97.85±0.05**
wilt	94.64±0.04	94.66±0.08	94.66±0.08	94.66±0.08	94.66±0.08	94.66±0.08	94.62±0.00	94.62±0.00	**94.71±0.10**	94.66±0.08	**94.71±0.10**	**94.71±0.10**	**94.71±0.10**	94.66±0.08	**94.71±0.10**	**94.71±0.10**
segmentation	**67.40±0.56**	65.93±0.67‡	65.19±1.24‡	63.94±0.95‡	67.14±1.14	68.14±1.07†	66.02±1.79	66.32±3.21	65.89±0.87‡	65.71±0.95‡	66.67±0.43	66.28±0.73	65.50±1.66	66.15±0.67	66.54±0.45	66.80±0.56
iono	81.43±1.56	77.71±5.16	78.00±7.15	80.57±5.16	**84.29±3.61**	83.71±3.68	80.57±6.43	81.43±6.32	82.57±3.43	82.00±5.90	82.57±2.77	82.57±2.77	76.00±6.29	72.86±4.52‡	80.57±5.16	84.00±2.91
wilt	97.17±0.24	96.38±0.52	97.35±0.38	95.37±1.25‡	97.29±0.65	97.35±0.38	97.13±0.56	97.31±0.44	97.27±0.29	97.25±0.51	**97.37±0.40**	97.35±0.38	96.34±1.28	97.35±0.38	97.13±0.48	97.35±0.38
ecoli	**69.70±2.71**	64.24±4.35	62.73±4.94	63.33±3.76	66.36±6.24	64.55±3.26	63.94±3.76	63.03±4.75	64.55±3.12	61.82±4.64	60.91±8.10	66.06±6.82	65.15±1.66	64.55±4.94	62.73±4.66	67.27±4.85
yeast	63.45±1.90	**66.15±2.35**	63.24±1.94	63.31±1.04	63.78±2.80	60.61±2.65	61.96±1.46	63.18±2.73	62.84±3.64	62.64±3.29	62.50±2.87	63.18±2.79	59.80±3.74	62.09±2.85	62.50±2.45	63.78±3.60
ringnorm	68.32±1.27‡	68.67±1.21	68.21±1.69	67.88±0.68‡	69.20±0.90	**69.86±1.31**	67.05±1.40‡	68.55±1.22	69.17±0.82	68.53±1.03	68.88±1.10	69.32±1.04	68.15±1.22‡	68.80±0.86	68.86±0.77	69.17±0.92
waveform	83.46±0.60	83.00±0.64	82.52±0.62	81.72±1.11‡	82.78±1.21	83.26±0.78	82.82±1.03‡	82.86±0.74	83.44±0.19	83.14±1.14	82.40±0.94‡	82.90±0.30‡	82.80±1.05	82.32±0.67‡	82.54±0.47‡	**83.86±0.74**
gmm (10d)	99.70±0.25	**99.80±0.25**	95.58±5.24	97.59±4.58	99.70±0.25	99.60±0.38	99.70±0.60	**99.80±0.25**	97.39±4.48	99.60±0.38	97.49±4.53	99.50±0.32	99.50±0.32	99.70±0.25	99.60±0.38	**99.80±0.25**
t-test (W/T/L)	3/10/0	3/10/0	3/10/0	6/7/0	0/13/0	1/11/1	2/11/0	0/13/0	1/12/0	2/11/0	1/12/0	1/12/0	4/9/0	3/10/0	1/12/0	—
Average Rank	7.62	8.85	10.96	13.15	5.35	5.42	11.19	8.08	6.58	9.23	8.04	6.35	12.77	10.58	9.15	2.69

[1] 表中所汇报的实验结果均是每种剪枝方法使用标准 5-交叉验证的实验在各个数据集的测试集上的平均准确度 (%) 与其相应的标准差。
[2] 通过在 5% 显著水平下的双尾成对 *t*-检验对比各算法之间是否有明显差异，其中 ‡ 和 † 分别表示 *EPBD* 显著优于或者是显著差于对比算法的性能；若无符号标记，则表示 *EPBD* 与相应对比算法之间没有显著差异。
[3] 表中最后两行分别展示了 *t*-检验的结果和各算法的平均序值。而 *t*-检验中的 “W/T/L” 则表示 *EPBD* 显著优于、并无显著不同或者显著差于相应的对比算法的次数。各算法的平均序值由 Friedman 检验 [4] 计算而得。

评估 *FTAD*

Table 4: 对比在 *FTAD* 中使用不同多样性度量方法的性能，其中使用朴素贝叶斯分类器基分类器和自助法来构建集成器

Data Set	Ensem	Disag	QStat	Corre	KStat	DoubF	KWVar	Inter	EntCC	EntSK	Diffi	GeneD	CFail	*EPBD*
ames	57.37±3.53‡	**59.71±4.39**	59.12±4.36	59.12±4.36	59.12±4.36	58.69±4.07	59.12±4.36	59.12±4.36	58.39±4.08	58.39±4.08	59.12±4.36	58.69±4.07	58.69±4.07	58.69±4.07
card	**79.56±4.48**	79.42±5.57	79.12±5.03	79.12±5.03	79.12±5.03	79.42±5.57	79.42±5.57	79.42±5.57	79.56±5.44	79.56±5.44	79.12±5.03	79.42±5.57	79.42±4.85	79.42±5.57
heart	84.07±3.23	**84.44±1.89**	84.07±2.22	84.07±2.22	84.07±2.22	83.70±2.72	84.07±3.01	84.07±3.01	83.70±2.72	83.70±2.72	84.07±2.22	83.70±2.72	83.70±2.72	83.70±2.72
ringnorm	**98.69±0.24**	98.66±0.25	98.66±0.25	98.66±0.25	98.66±0.25	98.66±0.25	98.66±0.25	98.66±0.25	98.66±0.25	98.66±0.25	98.66±0.25	98.66±0.25	98.66±0.25	98.66±0.25
wisconsin	**96.00±1.11**	96.00±1.37	96.00±1.37	96.00±1.37	96.00±1.37	96.00±1.37	96.00±1.37	96.00±1.37	96.00±1.37	96.00±1.37	96.00±1.37	96.00±1.37	96.00±1.37	96.00±1.37
landsat	90.30±0.73	**90.48±0.73**	**90.48±0.73**	**90.48±0.73**	**90.48±0.73**	**90.48±0.73**	**90.48±0.73**	**90.48±0.73**	90.47±0.71	**90.48±0.73**	**90.48±0.73**	**90.48±0.73**	90.47±0.71	**90.48±0.73**
shuttle	89.48±0.16‡	**89.71±0.14**	**89.71±0.14**	**89.71±0.14**	**89.71±0.14**	**89.71±0.14**	**89.71±0.14**	**89.71±0.14**	**89.71±0.14**	**89.71±0.14**	**89.71±0.14**	**89.71±0.14**	**89.71±0.14**	**89.71±0.14**
ecoli	92.12±2.78	**92.42±3.46**	**92.42±3.46**	**92.42±3.46**	**92.42±3.46**	94.24±2.61	**92.42±3.46**	**92.42±3.46**	**92.42±3.46**	**92.42±3.46**	**92.42±3.46**	**92.42±3.46**	**92.42±3.46**	94.24±2.61
yeast	58.24±2.64‡	60.20±1.67	57.30±3.33	57.30±3.33	57.30±3.33	**61.82±1.46**	**61.82±1.46**	**61.82±1.46**	60.27±1.64	60.20±1.67	57.30±3.33	61.69±1.70	61.49±1.61	**61.82±1.46**
mammo_graphic	**80.73±3.04**	79.79±2.76	79.69±2.57	79.69±2.57	79.69±2.57	79.58±2.72	79.48±2.61	79.48±2.61	79.79±2.76	79.79±2.76	79.69±2.57	79.58±2.72	79.58±2.72	79.58±2.72
madelon	58.85±2.37	58.96±2.28	59.19±1.31	59.19±1.31	59.19±1.31	59.04±2.07	59.04±2.07	59.04±2.07	**59.58±2.39**	58.96±2.28	59.19±1.31	59.04±2.07	58.92±2.22	59.04±2.07
sensor (2d)	81.41±0.86	81.61±0.91	81.81±0.57	81.81±0.57	81.81±0.57	**82.02±0.70**	81.81±0.57	81.81±0.57	81.59±0.93	81.61±0.91	81.81±0.57	**82.02±0.70**	81.92±0.76	**82.02±0.70**
sensor (4d)	74.57±0.88‡	75.44±0.99	**75.55±0.89**	**75.55±0.89**	**75.55±0.89**	**75.55±0.89**	**75.55±0.89**	**75.55±0.89**	75.33±0.85	75.44±0.99	**75.55±0.89**	**75.55±0.89**	75.51±0.94	**75.55±0.89**
waveform	85.29±0.95	85.35±0.94	85.33±0.92	85.33±0.92	85.33±0.92	85.33±0.92	85.33±0.92	85.33±0.92	**85.35±0.91**	85.35±0.94	85.33±0.92	85.33±0.92	85.33±0.92	85.33±0.92
t-test (W/T/L)	4/10/0	0/14/0	0/14/0	0/14/0	0/14/0	0/14/0	0/14/0	0/14/0	0/14/0	0/14/0	0/14/0	0/14/0	0/14/0	—
Average Rank	9.89	6.71	7.21	7.21	7.21	6.79	7.21	7.21	7.68	7.86	7.21	7.43	8.57	6.79

[1] 表中所汇报的实验结果均是每种剪枝方法使用标准 5-交叉验证的实验在各个数据集的测试集上的平均准确度 (%) 与其相应的标准差。

[2] 通过在 5% 显著水平下的双尾成对 *t*-检验对比各算法之间是否有明显差异，其中 ‡ 和 † 分别表示 *EPBD* 显著优于或者是显著差于对比算法的性能；若无符号标记，则表示 *EPBD* 与相应对比算法之间没有显著差异。

[3] 表中最后两行分别展示了 *t*-检验的结果和各算法的平均序值。而 *t*-检验中的 “W/T/L” 则表示 *EPBD* 显著优于、并无显著不同或者显著差于相应的对比算法的次数。各算法的平均序值由 Friedman 检验 [4] 计算而得。

评估 *FTAD*

Table 4: 对比在 *FTAD* 中使用不同多样性度量方法的性能，其中使用 k-近邻分类器作为基分类器和自助法来构建集成器

Data Set	Ensem	Disag	QStat	Corre	KStat	DoubF	KWVar	Inter	EntCC	EntSK	Diffi	GeneD	CFail	*EPBD*
gmm (2d)	96.90±0.63	96.92±0.66	**96.97±0.66**	**96.97±0.66**	**96.97±0.66**	**96.97±0.66**	**96.97±0.66**	**96.97±0.66**	96.92±0.66	96.92±0.66	**96.97±0.66**	**96.97±0.66**	**96.97±0.66**	**96.97±0.66**
card	67.74±2.33	68.03±2.67	67.74±3.28	67.74±3.28	67.74±3.28	**68.91±2.83**	**68.91±2.83**	**68.91±2.83**	67.88±2.85	68.03±2.67	67.74±3.28	68.32±2.15	**68.91±2.83**	**68.91±2.83**
liver	64.06±4.62	62.61±5.45	63.48±5.53	63.48±5.53	63.48±5.53	**64.35±4.36**	63.19±6.77	63.19±6.77	62.61±5.45	62.61±5.45	63.48±5.53	62.61±6.94	63.48±5.53	**64.35±4.36**
credit	74.18±0.35‡	74.69±0.44	74.63±0.45	74.63±0.45	74.63±0.45	**74.72±0.35**	**74.72±0.35**	**74.72±0.35**	74.70±0.44	74.69±0.44	74.63±0.45	**74.72±0.35**	74.62±0.31	**74.72±0.35**
page	95.96±0.35	96.11±0.34	**96.11±0.29**	**96.11±0.29**	**96.11±0.29**	**96.11±0.29**	**96.11±0.29**	**96.11±0.29**	96.11±0.34	96.11±0.34	**96.11±0.29**	**96.11±0.29**	**96.11±0.29**	**96.11±0.29**
shuttle	**99.84±0.03**	99.83±0.02	99.83±0.03	99.83±0.03	99.83±0.03	99.83±0.03	99.83±0.03	99.83±0.03	99.83±0.02	99.83±0.02	99.83±0.03	99.83±0.03	99.83±0.03	99.83±0.03
wilt	98.01±0.50	97.97±0.54	97.81±0.34	97.81±0.34	97.81±0.34	**98.04±0.38**	97.75±0.34	97.75±0.34	97.97±0.54	97.97±0.54	97.81±0.34	97.91±0.48	97.95±0.47	**98.04±0.38**
ecoli	**96.36±1.55**	95.76±1.13	95.76±1.13	95.76±1.13	95.76±1.13	95.76±1.13	95.76±1.13	95.76±1.13	95.76±1.13	95.76±1.13	95.76±1.13	95.76±1.13	95.76±1.13	95.76±1.13
mammo_graphic	77.71±2.70	78.02±2.76	77.92±2.90	77.92±2.90	77.92±2.90	77.92±2.90	77.92±2.90	77.92±2.90	**78.12±2.81**	78.02±2.76	77.92±2.90	77.92±2.90	77.71±3.06	77.92±2.90
madelon	70.38±2.21	**70.46±1.96**	69.69±2.05	69.69±2.05	69.69±2.05	70.31±1.89	69.92±1.58	69.92±1.58	70.15±1.96	**70.46±1.96**	69.69±2.05	70.31±1.89	70.35±1.94	70.31±1.89
sensor (4d)	**96.99±0.50**	96.83±0.45	96.98±0.43	96.98±0.43	96.98±0.43	96.98±0.43	96.98±0.43	96.98±0.43	96.87±0.43	96.83±0.45	96.98±0.43	96.98±0.43	96.98±0.43	96.98±0.43
sensor (24d)	**88.82±0.78**	88.78±0.74	88.43±0.66	88.43±0.66	88.43±0.66	88.56±0.57	88.56±0.57	88.56±0.57	88.74±0.75	88.78±0.74	88.43±0.66	88.56±0.57	88.56±0.57	88.56±0.57
waveform	85.03±0.83	85.09±0.60	85.07±0.78	85.07±0.78	85.07±0.78	**85.19±0.53**	85.15±0.57	85.15±0.57	85.05±0.63	85.09±0.60	85.07±0.78	85.07±0.32	85.17±0.26	**85.19±0.53**
EEGEyeState	**96.72±0.20**†	96.37±0.21	96.24±0.24	96.24±0.24	96.24±0.24	96.38±0.15	96.38±0.15	96.38±0.15	96.37±0.21	96.37±0.21	96.24±0.24	96.38±0.15	96.38±0.15	96.38±0.15
t-test (W/T/L)	1/12/1	0/14/0	0/14/0	0/14/0	0/14/0	0/14/0	0/14/0	0/14/0	0/14/0	0/14/0	0/14/0	0/14/0	0/14/0	—
Average Rank	6.64	7.68	9.18	9.18	9.18	5.00	6.89	6.89	8.50	7.68	9.18	7.18	6.82	5.00

[1] 表中所汇报的实验结果均是每种剪枝方法使用标准 5-交叉验证的实验在各个数据集的测试集上的平均准确度 (%) 与其相应的标准差。

[2] 通过在 5% 显著水平下的双尾成对 t-检验对比各算法之间是否有明显差异，其中 ‡ 和 † 分别表示 *EPBD* 显著优于或者是显著差于对比算法的性能；若无符号标记，则表示 *EPBD* 与相应对比算法之间没有显著差异。

[3] 表中最后两行分别展示了 t-检验的结果和各算法的平均序值。而 t-检验中的 “W/T/L” 则表示 *EPBD* 显著优于、并无显著不同或者显著差于相应的对比算法的次数。各算法的平均序值由 Friedman 检验 [4] 计算而得。

评估 *FTAD*

Table 4: 对比在 *FTAD* 中使用不同多样性度量方法的性能，其中使用支持向量机作为基分类器和自助法来构建集成器

Data Set	Ensem	Disag	QStat	Corre	KStat	DoubF	KWVar	Inter	EntCC	EntSK	Diffi	GeneD	CFail	*EPBD*
gmm (10d)	**99.80±0.25**	99.80±0.40	99.80±0.40	99.80±0.40	99.80±0.40	99.80±0.40	99.80±0.40	99.80±0.40	99.80±0.40	99.80±0.40	99.80±0.40	99.80±0.40	99.80±0.40	99.80±0.40
sonar	62.93±3.90	64.39±4.25	64.39±7.96	64.39±7.96	64.39±7.96	62.44±4.25	65.85±7.40	65.85±7.40	61.46±4.47	61.95±5.69	64.39±7.96	65.85±7.40	65.85±7.40	**66.83±7.00**
waveform	88.21±0.50‡	89.97±0.52	89.81±0.48‡	89.81±0.48‡	89.81±0.48‡	89.51±0.77‡	89.51±0.77‡	89.51±0.77‡	89.97±0.52	89.97±0.52	89.81±0.48‡	89.51±0.77‡	89.51±0.77‡	**90.71±0.75**
landsat	**65.24±0.00**	**65.24±0.00**	**65.24±0.00**	**65.24±0.00**	**65.24±0.00**	**65.24±0.00**	**65.24±0.00**	**65.24±0.00**	**65.24±0.00**	**65.24±0.00**	**65.24±0.00**	**65.24±0.00**	**65.24±0.00**	**65.24±0.00**
page	90.59±0.21	90.99±0.51	90.95±0.48	90.95±0.48	90.95±0.48	90.95±0.48	90.95±0.48	90.95±0.48	90.86±0.49	90.86±0.49	90.95±0.48	90.95±0.48	90.97±0.44	**90.99±0.41**
shuttle	97.12±0.15	97.28±0.18	**97.28±0.16**	**97.28±0.16**	**97.28±0.16**	**97.28±0.16**	**97.28±0.16**	**97.28±0.16**	97.28±0.18	97.28±0.18	**97.28±0.16**	**97.28±0.16**	**97.28±0.16**	95.25±2.08
yeast	65.00±1.14	55.41±12.42	55.41±12.42	55.41±12.42	55.41±12.42	54.93±12.09	54.93±12.09	54.93±12.09	59.80±9.89	59.93±9.93	55.41±12.42	54.93±12.09	45.20±10.17‡	**65.07±1.18**
sensor (4d)	**85.63±0.90**	84.47±0.78	84.00±1.45	84.00±1.45	84.00±1.45	77.58±8.33	84.01±0.85	84.01±0.85	84.47±0.78	84.47±0.78	84.00±1.45	81.21±7.51	81.28±7.54	84.01±0.85
EEGEyeState	**55.13±0.00**	**55.13±0.00**	**55.13±0.00**	**55.13±0.00**	**55.13±0.00**	**55.13±0.00**	**55.13±0.00**	**55.13±0.00**	**55.13±0.00**	**55.13±0.00**	**55.13±0.00**	**55.13±0.00**	**55.13±0.00**	**55.13±0.00**
t-test (W/T/L)	1/8/0	0/9/0	1/8/0	1/8/0	1/8/0	1/8/0	1/8/0	1/8/0	0/9/0	0/9/0	1/8/0	1/8/0	2/7/0	—
Average Rank	9.33	5.39	7.56	7.56	7.56	9.56	7.72	7.72	6.72	6.50	7.56	8.50	8.17	5.17

[1] 表中所汇报的实验结果均是每种剪枝方法使用标准 5-交叉验证的实验在各个数据集的测试集上的平均准确度 (%) 与其相应的标准差。

[2] 通过在 5% 显著水平下的双尾成对 *t*-检验对比各算法之间是否有明显差异，其中 ‡ 和 † 分别表示 *EPBD* 显著优于或者是显著差于对比算法的性能；若无符号标记，则表示 *EPBD* 与相应对比算法之间没有显著差异。

[3] 表中最后两行分别展示了 *t*-检验的结果和各算法的平均序值。而 *t*-检验中的 “W/T/L” 则表示 *EPBD* 显著优于、并无显著不同或者显著差于相应的对比算法的次数。各算法的平均序值由 Friedman 检验 [4] 计算而得。

大纲

1. 研究意义
2. 分类问题中集成器的多样性与泛化性能的关系
3. 基于信息熵的集成剪枝方法及其通用并行框架
4. 神经架构搜索中的集成子结构剪枝
5. 总结与展望
6. 附录
   - 分类问题中集成器的多样性与泛化性能的关系
   - 基于信息熵的集成剪枝方法及其通用并行框架
   - 神经架构搜索中的集成子结构剪枝

COMEP, *DOMEP* vs. 基准剪枝算法

Table 5: 对比基准剪枝算法和 *COMEP* 及 *DOMEP*，其中使用决策树作为基分类器和自助法来构建集成器

Dataset	KL	KP	OO	RE	DREP	SEP	OEP	PEP	*COMEP*	*DOMEP*
Iono	89.43±3.44	90.29±3.41	90.57±4.69	88.57±3.03	89.71±3.70	90.86±2.96	89.71±4.33	**91.71±3.41**	91.14±3.41	91.71±3.56
Liver	61.45±8.24	62.32±5.12	64.06±7.35	61.16±4.96‡	56.23±8.41	60.87±4.35‡	64.64±4.54	62.32±4.23	62.90±4.18	**64.64±4.30**
Spam	93.28±1.13	93.21±0.93	93.30±1.43	93.54±1.16	92.08±1.48	93.43±0.82	**93.56±1.24**	93.38±0.80	93.41±0.90	93.45±1.00
Wisconsin	94.37±3.58	94.67±3.25‡	95.56±4.06	95.41±3.25	93.93±3.68	94.96±3.86‡	95.26±3.50	95.41±3.79	95.56±3.70	**95.70±3.45**
Credit	100.00±0.00	100.00±0.00	100.00±0.00	100.00±0.00	100.00±0.00	100.00±0.00	100.00±0.00	100.00±0.00	100.00±0.00	100.00±0.00
Landsat	97.34±0.45	97.22±0.66	97.29±0.37	97.31±0.28	96.08±1.06‡	97.26±0.26	97.34±0.35	97.29±0.56	97.15±0.43	**97.42±0.34**
Wilt	98.24±0.32	98.24±0.26	98.37±0.42	98.28±0.32	98.01±0.51	98.37±0.51	98.16±0.18	98.39±0.53	**98.41±0.33**	98.35±0.38
Shuttle	99.96±0.03	99.96±0.03	**99.97±0.02**	**99.97±0.02**	**99.97±0.02**	99.96±0.03	99.96±0.03	**99.97±0.02**	99.96±0.03	99.97±0.03
Ecoli	94.55±3.14	94.85±2.03	93.64±2.71	95.15±2.49	91.52±3.49‡	94.85±2.75	93.03±2.30	94.24±2.71	95.15±2.49	**95.15±1.98**
SensorReadings	99.25±0.40	99.19±0.50	99.41±0.47	**99.52±0.24**	99.28±0.25	99.45±0.23	99.50±0.19	99.36±0.43	99.43±0.33	99.38±0.41
t-Test (W/T/L)	0/10/0	1/9/0	0/10/0	1/9/0	2/8/0	2/8/0	0/10/0	0/10/0	0/10/0	—
Average Rank	7.15	7.20	4.80	4.60	8.40	5.55	5.20	4.75	4.40	2.95

[1] 表中所汇报的实验结果均是每种剪枝方法使用标准 5-交叉验证的实验在各个数据集的测试集上的平均准确度 (%) 与其相应的标准差。更优的准确度和更低的标准差将以粗体字表示。

[2] 通过在 5% 显著水平下的双尾成对 *t*-检验对比各算法之间是否有明显差异，其中 ‡ 和 † 分别表示 *DOMEP* 显著优于或者是显著差于对比算法的性能；若无符号标记，则表示 *DOMEP* 与相应对比算法之间没有显著差异。

[3] 表中最后两行分别展示了 *t*-检验的结果和各算法的平均序值。而 *t*-检验中的 “W/T/L” 则表示 *DOMEP* 显著优于、并无显著不同或者显著差于相应的对比算法的次数。各算法的平均序值由 Friedman 检验 [4] 计算而得。

COMEP, *DOMEP* vs. 基准剪枝算法

Table 5: 对比基准剪枝算法和 *COMEP* 及 *DOMEP*，其中使用支持向量机作为基分类器和自助法来构建集成器

Dataset	KL	KP	OO	RE	DREP	SEP	OEP	PEP	*COMEP*	*DOMEP*
Liver	**58.84±1.65**	**58.84±1.65**	58.26±1.21	**58.84±1.65**	**58.84±1.65**	58.55±1.65	**58.84±1.65**	58.55±1.65	**58.84±1.65**	**58.84±1.65**
Ringnorm	98.43±0.37	**98.53±0.30**†	98.51±0.36†	98.47±0.29	98.43±0.29	98.47±0.36	98.39±0.25	98.44±0.31	98.43±0.31	98.43±0.31
Waveform	91.45±1.60	91.23±1.50	91.35±1.58	91.17±1.67	90.83±1.52‡	91.27±1.53	91.13±1.61	91.37±1.63	**91.45±1.49**	91.23±1.63
Credit	78.02±0.07	78.01±0.11	78.03±0.08	78.02±0.08	77.96±0.12	**78.04±0.12**	78.02±0.11	78.02±0.13	78.00±0.09	78.01±0.11
Landsat	65.24±0.00	65.24±0.00	65.24±0.00	65.24±0.00	65.24±0.00	65.24±0.00	65.24±0.00	65.24±0.00	65.24±0.00	65.24±0.00
Page	91.26±0.41	91.26±0.45	91.28±0.44	91.24±0.46	91.28±0.52	91.22±0.32	91.24±0.44	**91.30±0.53**	91.26±0.45	91.22±0.44
Wilt	94.68±0.09	94.68±0.09	94.68±0.09	94.68±0.09	94.68±0.09	94.68±0.09	94.68±0.09	94.68±0.09	94.68±0.09	94.68±0.09
SensorReadings	89.17±0.78	89.24±0.88	89.28±0.52	89.35±0.51	88.91±0.60	89.11±0.91‡	89.26±0.50	**89.51±0.94**	89.42±0.83	89.37±1.04
EEGEyeState	55.13±0.00	55.13±0.00	55.13±0.00	55.13±0.00	55.13±0.00	55.13±0.00	55.13±0.01	55.13±0.00	55.13±0.00	55.13±0.00
WaveformNoise	86.35±0.74	86.11±0.83	86.37±0.79	86.21±0.94	85.99±0.83	86.49±1.02	86.11±0.98	86.29±0.77	**86.55±0.68**	86.43±0.81
t-Test (W/T/L)	0/10/0	0/9/1	0/9/1	0/10/0	1/9/0	1/9/0	0/10/0	0/10/0	0/10/0	—
Average Rank	5.20	5.60	4.60	5.50	7.05	5.50	6.60	4.55	4.65	5.75

[1] 表中所汇报的实验结果均是每种剪枝方法使用标准 5-交叉验证的实验在各个数据集的测试集上的平均准确度 (%) 与其相应的标准差。更优的准确度和更低的标准差将以粗体字表示。

[2] 通过在 5% 显著水平下的双尾成对 t-检验对比各算法之间是否有明显差异，其中 ‡ 和 † 分别表示 *DOMEP* 显著优于或者是显著差于对比算法的性能；若无符号标记，则表示 *DOMEP* 与相应对比算法之间没有显著差异。

[3] 表中最后两行分别展示了 t-检验的结果和各算法的平均序值。而 t-检验中的 “W/T/L” 则表示 *DOMEP* 显著优于、并无显著不同或者显著差于相应的对比算法的次数。各算法的平均序值由 Friedman 检验 [4] 计算而得。

COMEP, *DOMEP* vs. 基准剪枝算法

Table 5: 对比基准剪枝算法和 *COMEP* 及 *DOMEP*，其中使用 k-近邻分类器作为基分类器和自助法来构建集成器

Dataset	KL	KP	OO	RE	DREP	SEP	OEP	PEP	*COMEP*	*DOMEP*
Ames	58.83±5.48	58.54±7.20	**60.29±7.45**	57.81±7.14	57.52±7.29	59.71±6.18	59.56±6.96	58.69±5.90	60.15±6.90	59.12±5.95
Card	67.59±2.10	66.86±1.68	66.72±1.68	67.01±2.27	64.38±2.27	67.88±2.87	65.99±1.22	65.55±2.39‡	**68.32±3.33**	68.03±3.44
Sonar	80.98±7.98	80.00±8.52	81.95±7.03	81.95±5.62	79.02±5.62	81.46±5.87	80.00±5.29	78.05±5.72	**82.44±7.19**	80.98±8.69
Page	95.87±0.35	95.87±0.49	95.81±0.45	95.76±0.35	95.76±0.39	95.80±0.57	95.87±0.55	95.81±0.46	95.87±0.64	**95.89±0.64**
Wilt	97.93±0.28	97.89±0.32	**98.01±0.24**	97.99±0.20	97.77±0.36	97.93±0.35	97.89±0.40	98.01±0.32	97.97±0.19	98.01±0.26
Landsat	90.28±0.88	90.22±1.18	90.30±0.95	90.40±0.83	90.31±0.94	**90.47±0.78**	90.37±0.85	90.37±0.76	90.47±1.21	90.44±0.87
Shuttle	99.82±0.03	99.81±0.03	99.82±0.04	**99.82±0.02**	99.82±0.04	99.81±0.04	99.81±0.03	99.81±0.03	99.80±0.03‡	99.82±0.04
Ecoli	95.15±2.91	94.55±3.14	**95.76±2.91**	95.45±3.03	93.33±3.14	94.85±2.95	94.24±3.11	94.85±3.65	95.45±3.03	**95.76±2.91**
WaveformNoise	84.34±1.05	84.20±1.46	84.48±2.09	84.36±2.24	83.54±0.74	84.36±1.33	84.48±2.24	84.16±1.58	84.48±1.81	**84.62±1.77**
EEGEyeState	95.99±0.55	96.06±0.52	96.16±0.50	95.98±0.59	95.03±0.37‡	96.11±0.50	96.08±0.66	**96.28±0.55**	96.19±0.62	96.01±0.46
SensorReadings	96.29±0.47	96.11±0.39	96.33±0.62	96.37±0.53	96.00±0.51	96.29±0.64	96.39±0.42	96.28±0.60	**96.42±0.64**	96.31±0.31
t-Test (W/T/L)	0/11/0	0/11/0	0/11/0	0/11/0	1/10/0	0/11/0	0/11/0	1/10/0	1/10/0	—
Average Rank	5.82	7.45	3.77	5.27	8.95	5.09	5.77	6.55	3.05	3.27

[1] 表中所汇报的实验结果均是每种剪枝方法使用标准 5-交叉验证的实验在各个数据集的测试集上的平均准确度 (%) 与其相应的标准差。更优的准确度和更低的标准差将以粗体字表示。

[2] 通过在 5% 显著水平下的双尾成对 t-检验对比各算法之间是否有明显差异，其中 ‡ 和 † 分别表示 *DOMEP* 显著优于或者是显著差于对比算法的性能；若无符号标记，则表示 *DOMEP* 与相应对比算法之间没有显著差异。

[3] 表中最后两行分别展示了 t-检验的结果和各算法的平均序值。而 t-检验中的 “W/T/L” 则表示 *DOMEP* 显著优于、并无显著不同或者显著差于相应的对比算法的次数。各算法的平均序值由 Friedman 检验 [4] 计算而得。

评估优化目标

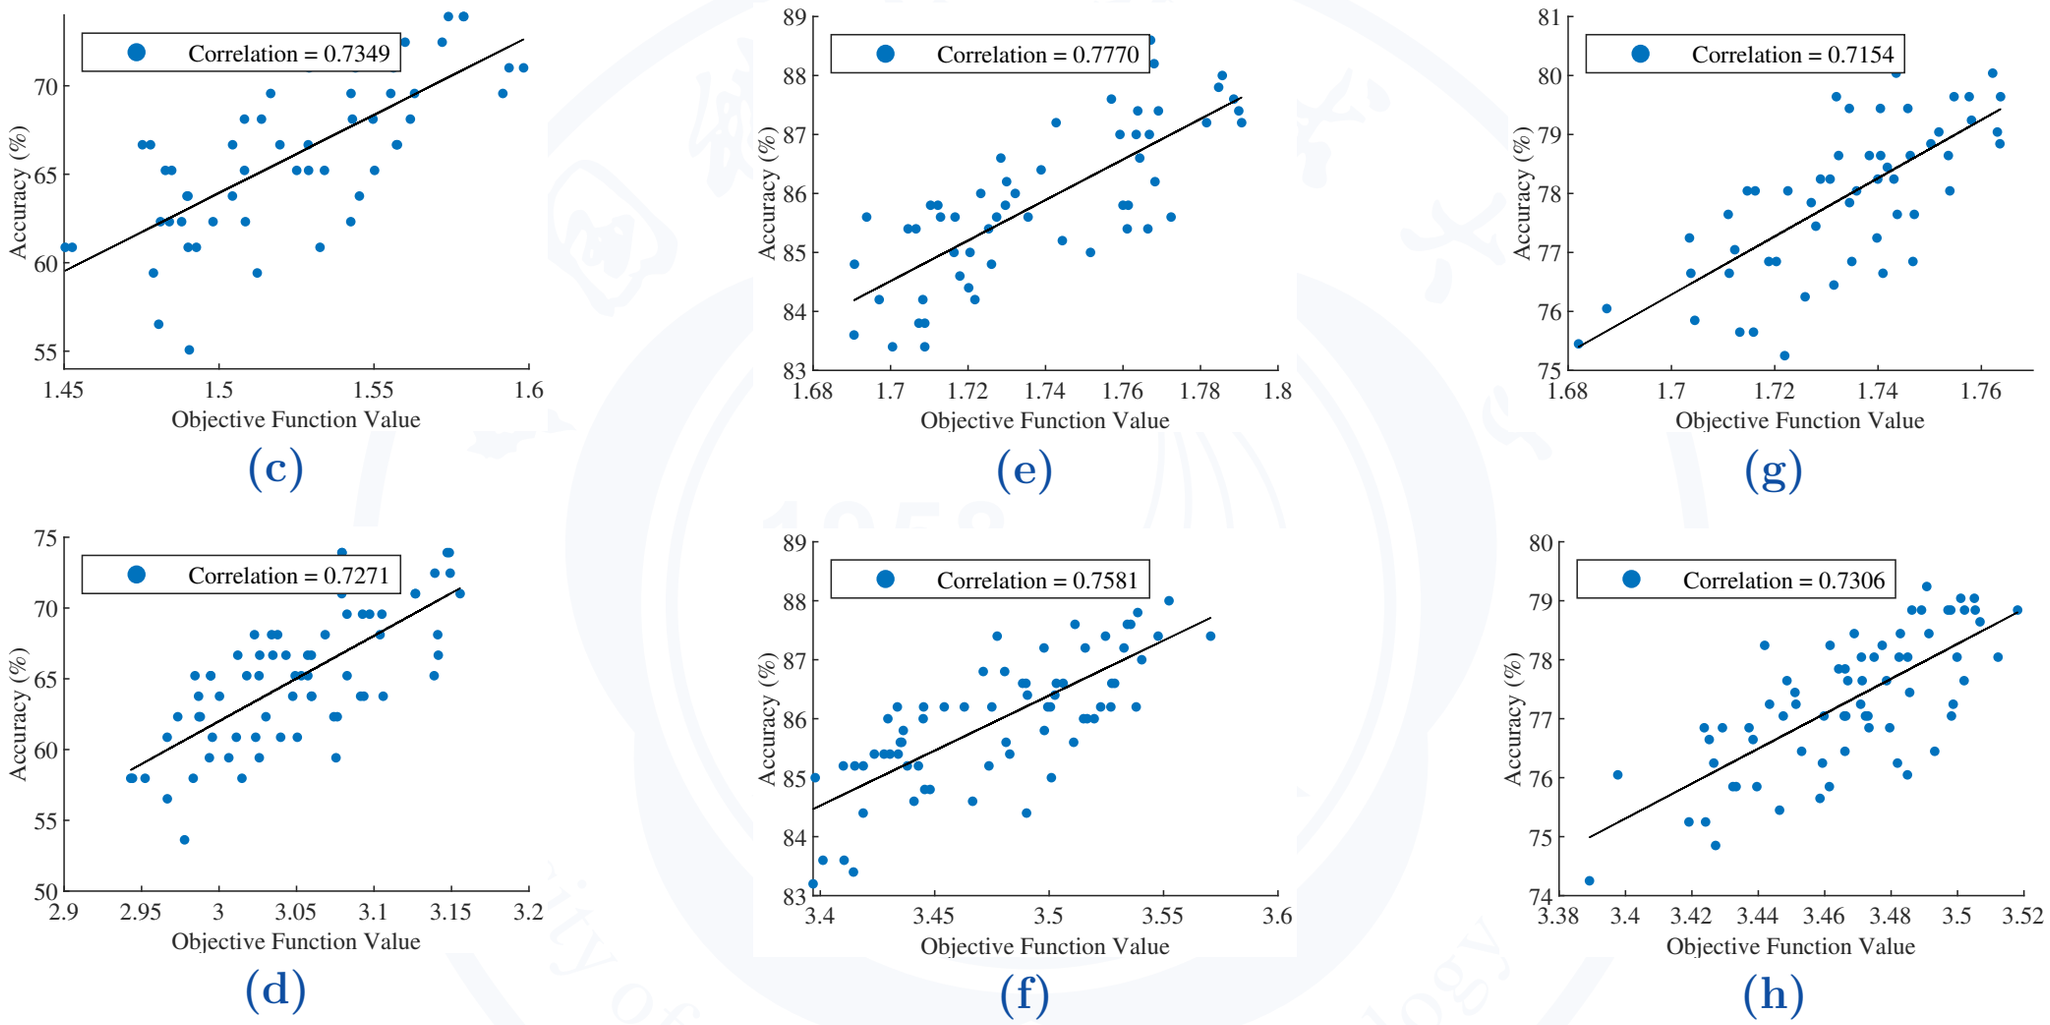


Figure 21: 测试准确度和目标函数值之间的关系图，使用决策树作为基分类器和自助法来构造集成器。注：上下两行分别表示基分类器之间的 3-组合和 4-组合。(a–b) 在 Ames 数据集上的二分类准确度和目标函数值之间的关系图；(c–d) 在 Waveform 数据集上的二分类准确度和目标函数值之间的关系图；(e–f) 在 Waveform 数据集上的多分类准确度和目标函数值之间的关系图。

参数 λ 值的影响

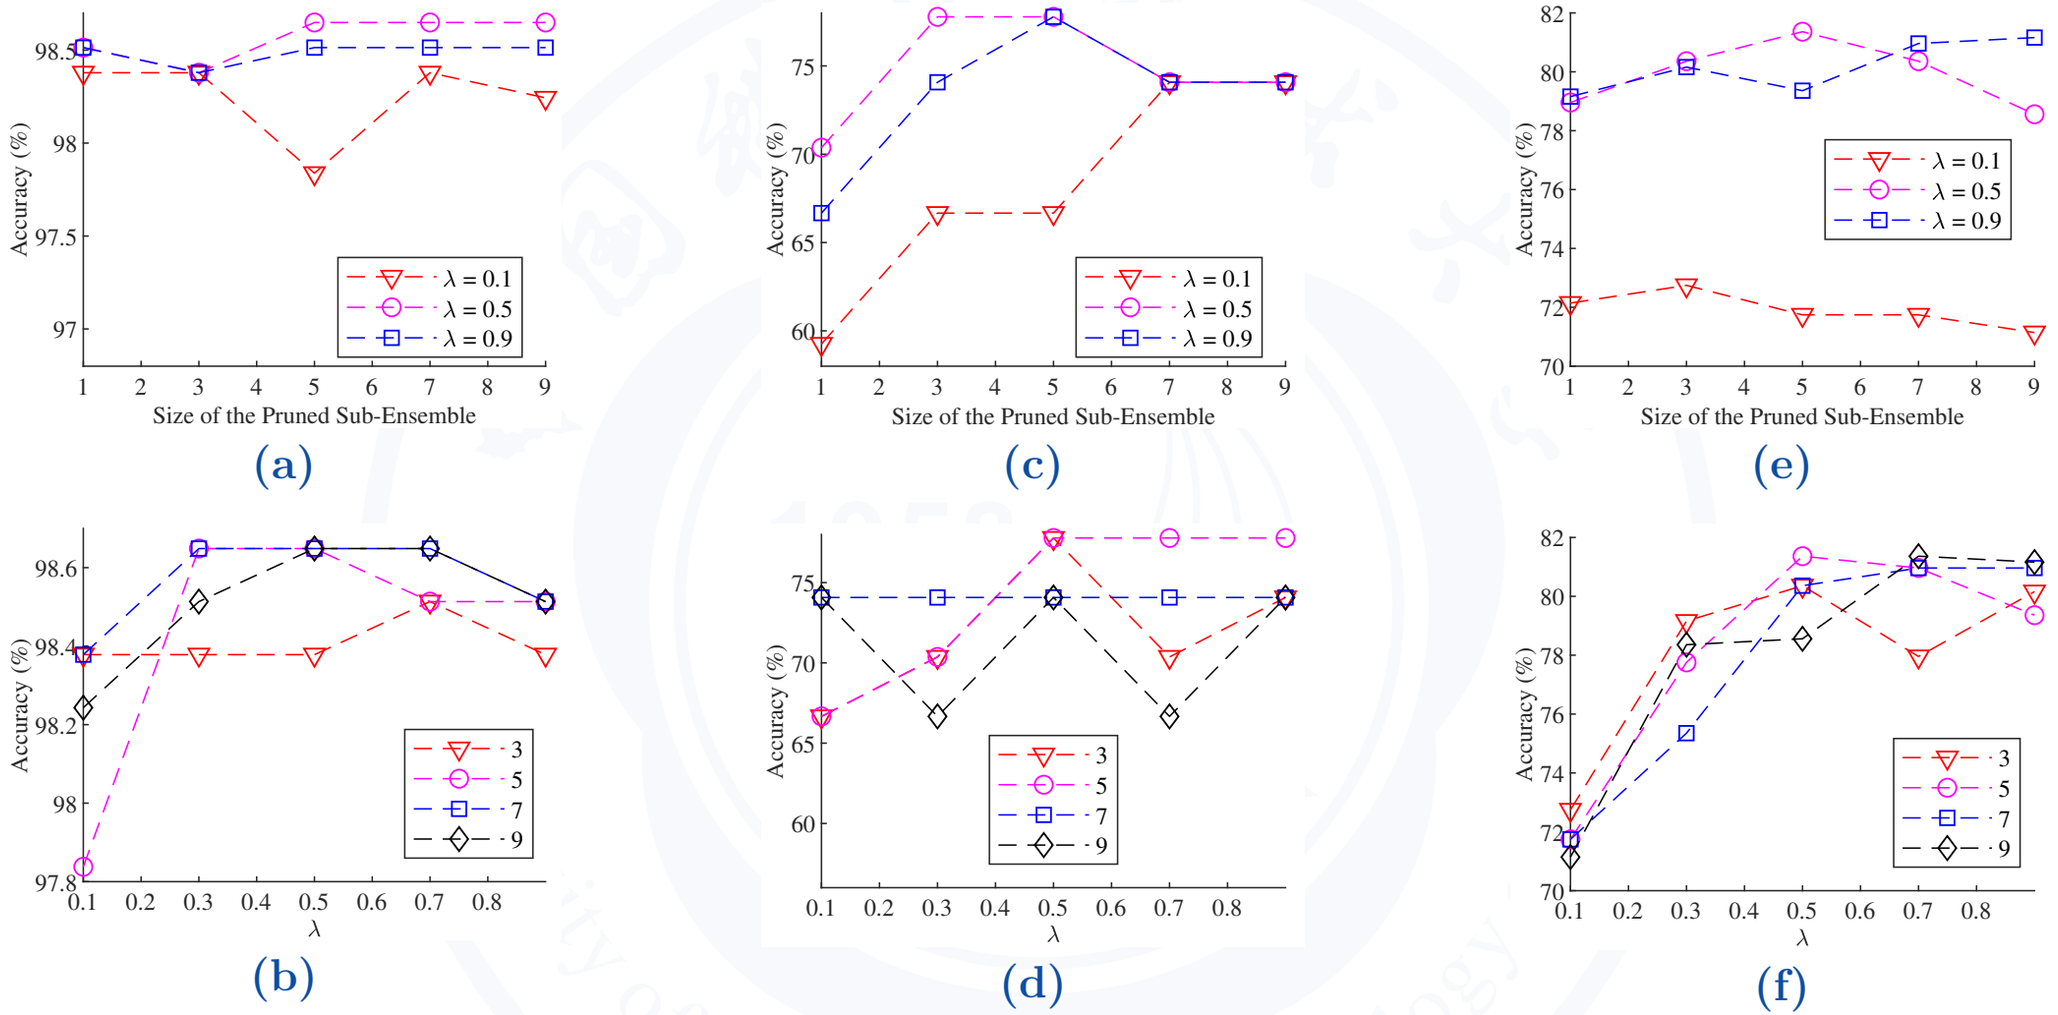


Figure 22: 使用自助法来构建集成器时, 不同 λ 值对准确度的影响. 注：上一行表示 “分别使用每个准则的准确度” 时的情形; 下一行表示 “当选择不同规模的子集成器 (即由 3, 5, 7, 或 9 个基分类器组成) 时, 不同 λ 值的些微不同”. (a–b) 在 Ringnorm 数据集上学习二分类问题时, 使用支持向量机作为基分类器; (c–d) 在 Heart 数据集上学习二分类问题时, 使用 k-近邻分类器作为基分类器; (e–f) 在 Waveform 数据集上学习多分类问题时, 使用决策树作为基分类器.

大纲

1. 研究意义
2. 分类问题中集成器的多样性与泛化性能的关系
3. 基于信息熵的集成剪枝方法及其通用并行框架
4. 神经架构搜索中的集成子结构剪枝
5. 总结与展望
6. 附录
   - 分类问题中集成器的多样性与泛化性能的关系
   - 基于信息熵的集成剪枝方法及其通用并行框架
   - 神经架构搜索中的集成子结构剪枝

评估 *SAEP*

Table 6: 二分类问题中的 (子) 集成网络结构的实验性能结果表

(a) AdaNet 和 *SAEP* 的性能对比

标签对	测试准确度 (%)				子网络的数量 (最终保留/总计生成)				多样性 (分歧度量)				时间代价 (min)			
	AdaNet	*PRS*	*PAP*	*PIE*	AdaNet	*PRS*	*PAP*	*PIE*	AdaNet	*PRS*	*PAP*	*PIE*	AdaNet	*PRS*	*PAP*	*PIE*
deer-truck	94.60	**94.65**	**94.65**	94.5	12/12	**2**/8	3/10	5/6	0.9029	0.7969	**0.9792**	0.8469	131.98	174.86	142.03	**116.19**
deer-horse	84.30	83.90	83.40	**85.40**	8/8	**3**/7	9/11	**3**/10	0.9322	**0.9948**	0.8850	0.9323	**89.42**	102.47	195.96	179.84
automobile-truck	83.80	84.20	**84.70**	83.95	6/6	**3**/11	**3**/9	4/6	**0.9453**	0.8724	0.9219	0.9297	**67.55**	185.17	191.88	102.57
top-pullover	96.45	96.55	**96.80**	96.65	9/9	4/13	**2**/9	5/12	0.9119	0.8073	**1.0000**	0.7758	110.38	233.98	152.51	**81.96**
top-coat	**98.55**	98.40	**98.55**	**98.55**	8/8	**2**/9	5/9	**2**/5	0.9021	**1.0000**	0.9094	0.9688	81.03	138.58	156.74	**69.90**
top-shirt	84.50	84.50	**85.10**	84.70	9/9	4/11	**3**/9	**3**/8	0.9329	0.9648	**0.9844**	0.7760	**84.14**	172.26	151.19	114.27
trouser-dress	97.90	97.90	**97.95**	97.80	10/10	**2**/7	**2**/7	3/12	0.9184	**1.0000**	**1.0000**	**1.0000**	55.92	**40.09**	47.86	96.34
sandal-ankle boot	98.60	**98.65**	98.55	**98.65**	10/10	5/7	4/10	2/10	0.9007	0.9383	**0.9583**	0.7500	50.43	46.41	**45.94**	52.12
digits 6-9	99.69	99.75	**99.85**	99.80	5/5	3/10	6/11	**2**/11	0.9266	0.7630	0.9313	**0.9766**	**67.41**	155.93	173.97	132.11
digits 5-8	**99.25**	99.20	**99.25**	99.09	13/13	**2**/11	7/11	**2**/9	0.9036	0.9531	0.8925	**0.9922**	178.73	258.03	124.30	**62.83**

(b) 相应变体的性能对比

标签对	测试准确度 (%)				子网络的数量 (最终保留/总计生成)				多样性 (分歧度量)				时间代价 (min)			
	AdaNet.W	*PRS.W*	*PAP.W*	*PIE.W*	AdaNet.W	*PRS.W*	*PAP.W*	*PIE.W*	AdaNet.W	*PRS.W*	*PAP.W*	*PIE.W*	AdaNet.W	*PRS.W*	*PAP.W*	*PIE.W*
deer-truck	**94.85**	94.80	94.50	94.70	11/11	5/6	**3**/11	**3**/9	0.9176	**0.9297**	0.8958	0.9245	114.67	**125.62**	235.32	171.98
deer-horse	**84.70**	84.50	84.25	84.60	12/12	5/13	6/13	**2**/10	0.9118	0.9305	**0.9370**	0.8281	**158.54**	299.24	268.77	232.93
automobile-truck	83.05	83.30	**84.15**	82.55	12/12	3/11	8/9	**2**/8	0.9091	**0.9505**	0.8884	0.8828	179.00	232.36	159.90	**136.38**
top-pullover	96.85	96.95	96.75	**97.10**	9/9	**3**/6	5/6	4/7	0.8650	0.7656	0.8766	**0.9766**	45.86	**39.07**	42.85	43.91
top-coat	**98.60**	98.50	98.45	98.35	11/11	3/7	**2**/4	7/8	0.9040	**0.9974**	0.9922	0.9182	92.13	40.03	**24.66**	59.74
top-shirt	84.75	84.70	84.90	**85.00**	8/8	3/7	**2**/5	4/8	0.8747	0.9349	**0.9922**	0.8763	37.31	47.77	**23.30**	55.70
trouser-dress	**97.95**	97.90	97.85	97.70	5/5	**3**/9	5/6	6/8	0.9484	0.8620	**0.9547**	0.9177	**21.10**	111.75	108.13	144.54
sandal-ankle boot	98.55	**98.65**	98.45	**98.65**	8/8	4/9	**2**/6	3/7	0.9336	0.8698	**0.9766**	0.9323	**35.48**	46.35	37.70	122.58
digits 6-9	99.75	**99.80**	**99.80**	99.69	6/6	5/10	5/10	**4**/9	0.8854	0.8633	0.8836	**0.9089**	**26.52**	55.84	63.78	41.01
digits 5-8	**99.30**	99.09	99.14	**99.30**	9/9	3/14	**2**/9	**2**/8	0.9041	0.7552	0.6797	**0.9922**	**48.58**	110.93	154.58	167.09

SAEP 可生成规模更小的子网络结构

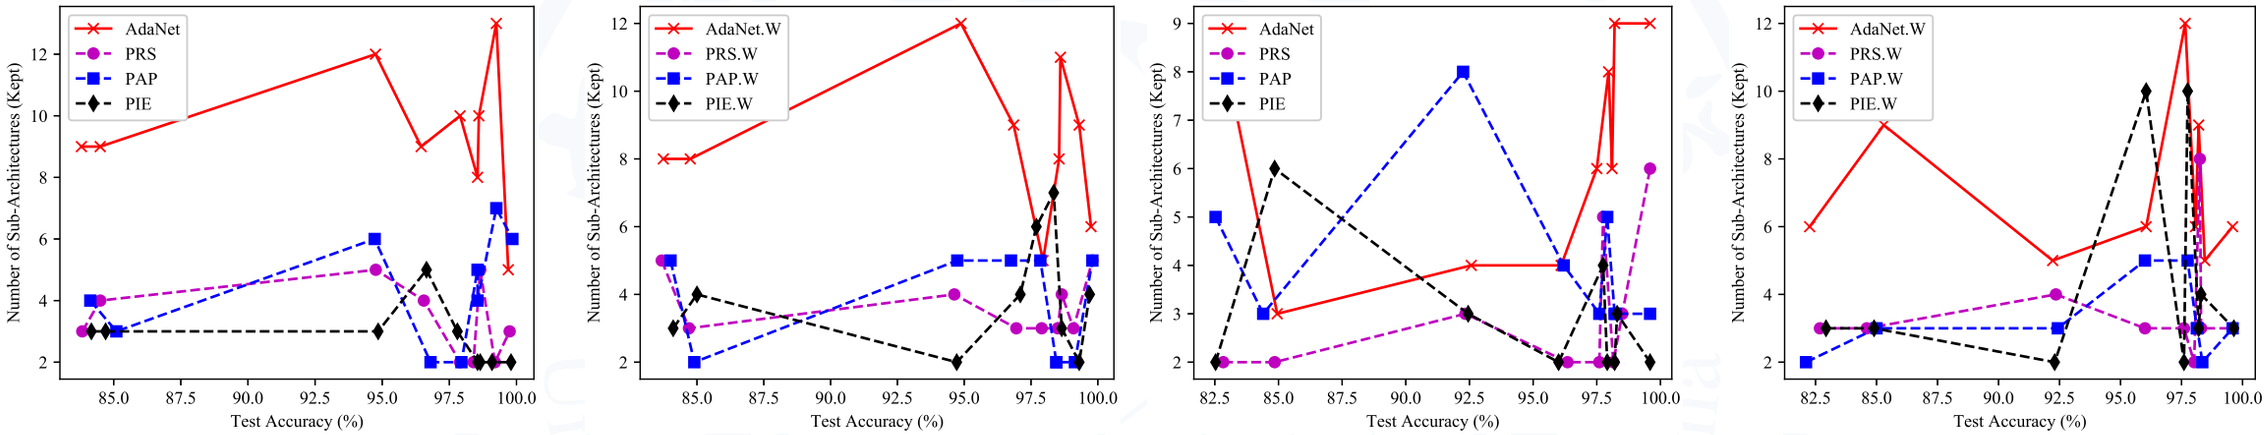


Figure 23: 图像分类任务的测试准确度和子网络结构数量的实验结果图。注：AdaNet 与 *SAEP* 及其相应变体的性能对比，(a–b) 和 (c–d) 分别使用多层感知机/卷积神经网络来构造子网络。

SAEP 可生成更多样化的子网络结构

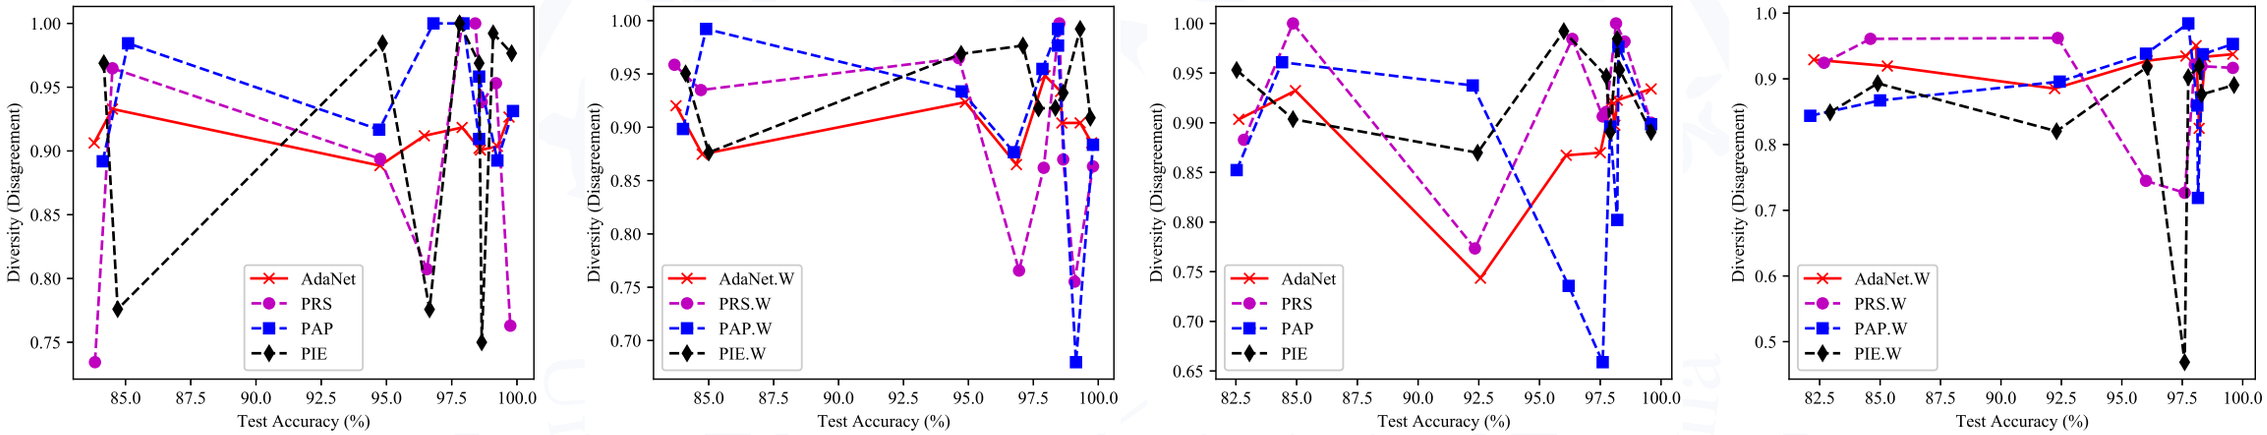


Figure 24: 图像分类任务的测试准确度和多样性 (分歧度量) 的实验结果图。注：AdaNet 与 *SAEP* 及其相应变体的性能对比，(a–b) 和 (c–d) 分别使用多层感知机/卷积神经网络来构造子网络。

多样性的影响

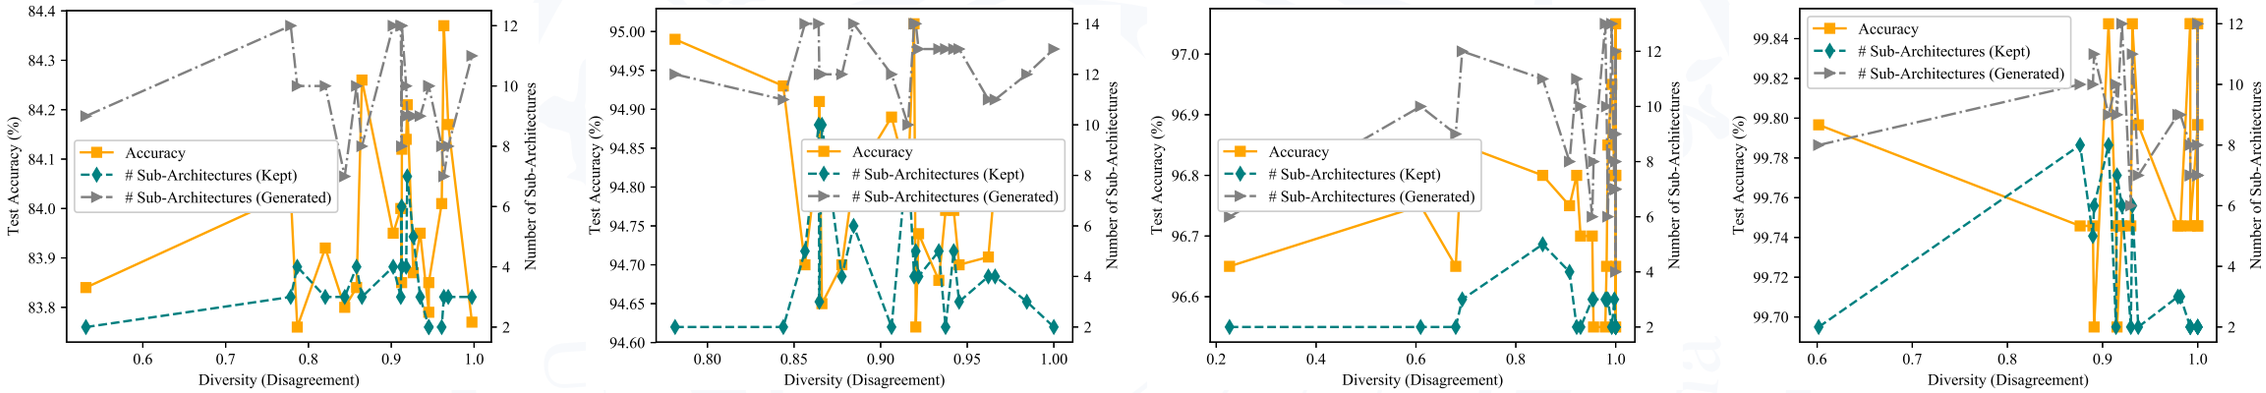


Figure 25: 图像分类任务中多样性对测试准确度和子网络结构数量的影响. (a–b) 分别在 Fashion-MNIST/MNIST 数据集上学习多分类任务; (c–d) 分别在 Fashion-MNIST/MNIST 数据集上学习二分类任务.

参数 α 值的影响

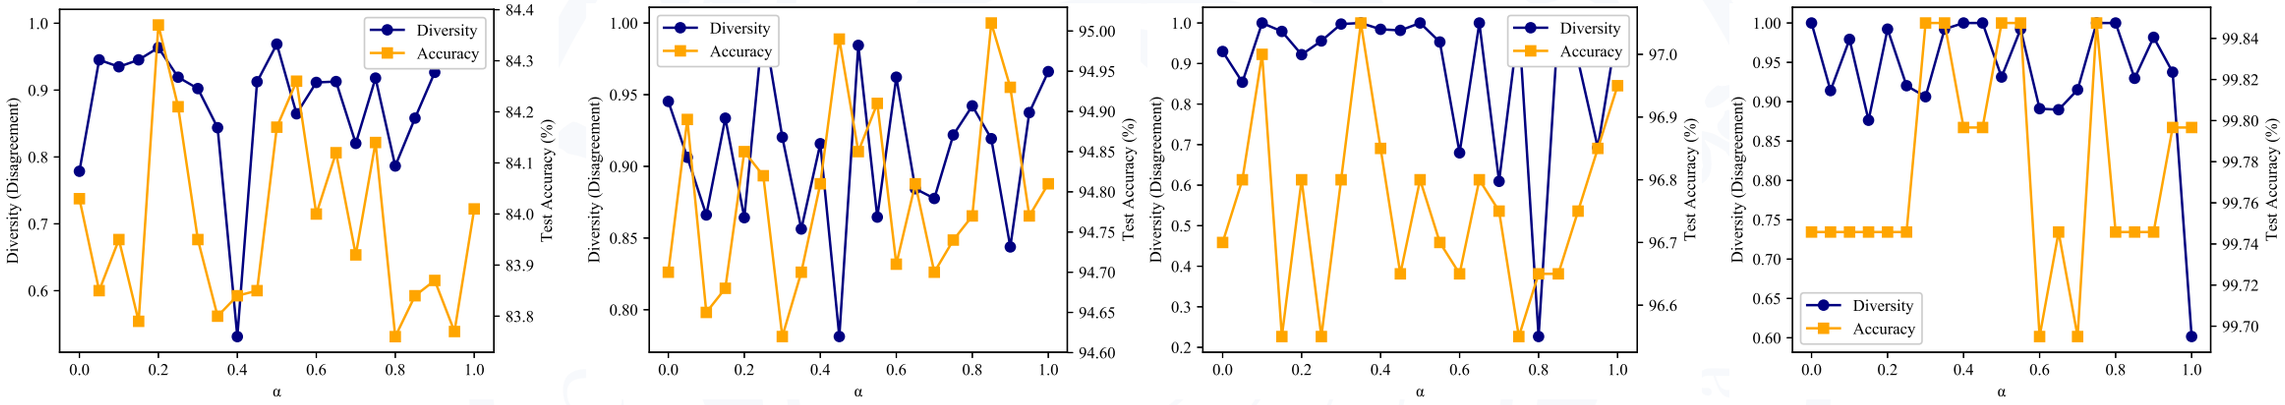


Figure 26: 图像分类任务中使用 *PIE* 策略进行剪枝时，参数 α 值的变化对子集成网络结构的多样性和测试准确度的影响. (a–b) 分别在 Fashion-MNIST/MNIST 数据集上学习多分类任务; (c–d) 分别在 Fashion-MNIST/MNIST 数据集上学习二分类任务.

参数 α 值的影响

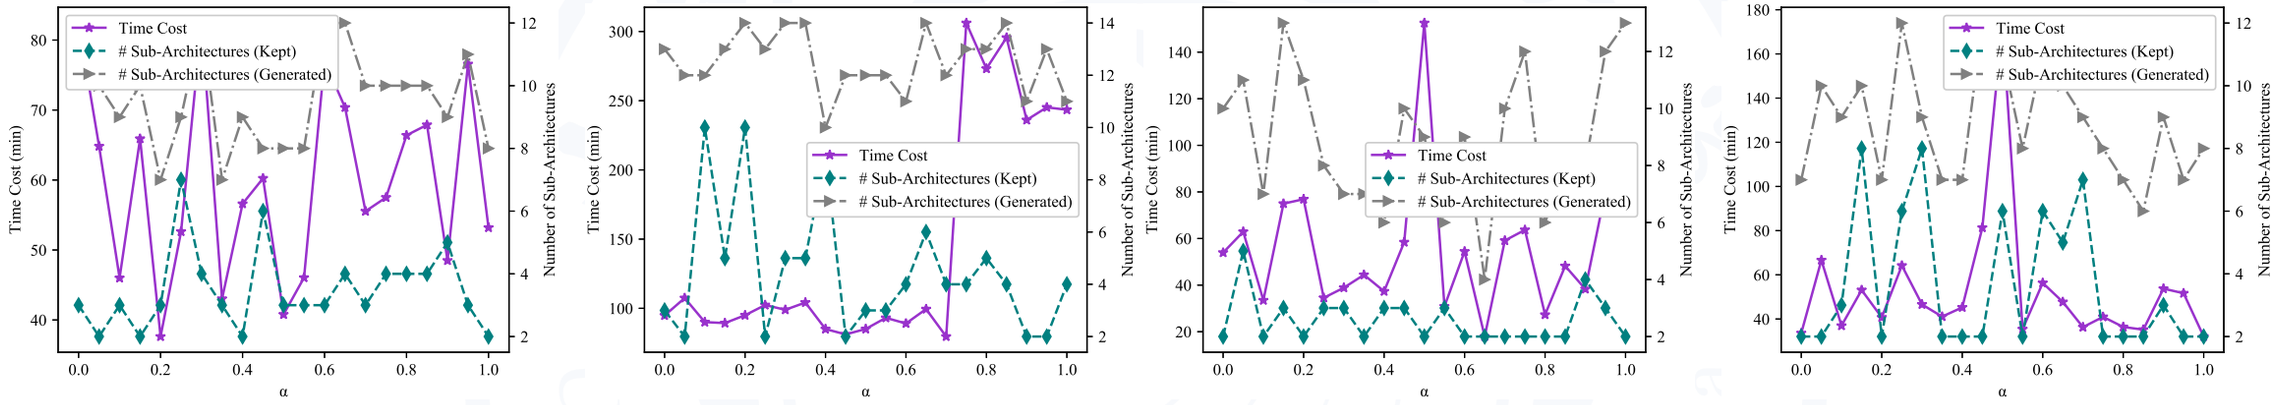


Figure 27: 图像分类任务中使用 *PIE* 策略进行剪枝时，参数 α 值的变化对子集成网络结构的时间代价和生成规模的影响. (a–b) 分别在 Fashion-MNIST/MNIST 数据集上学习多分类任务; (c–d) 分别在 Fashion-MNIST/MNIST 数据集上学习二分类任务.

参数 α 值的影响（续.）

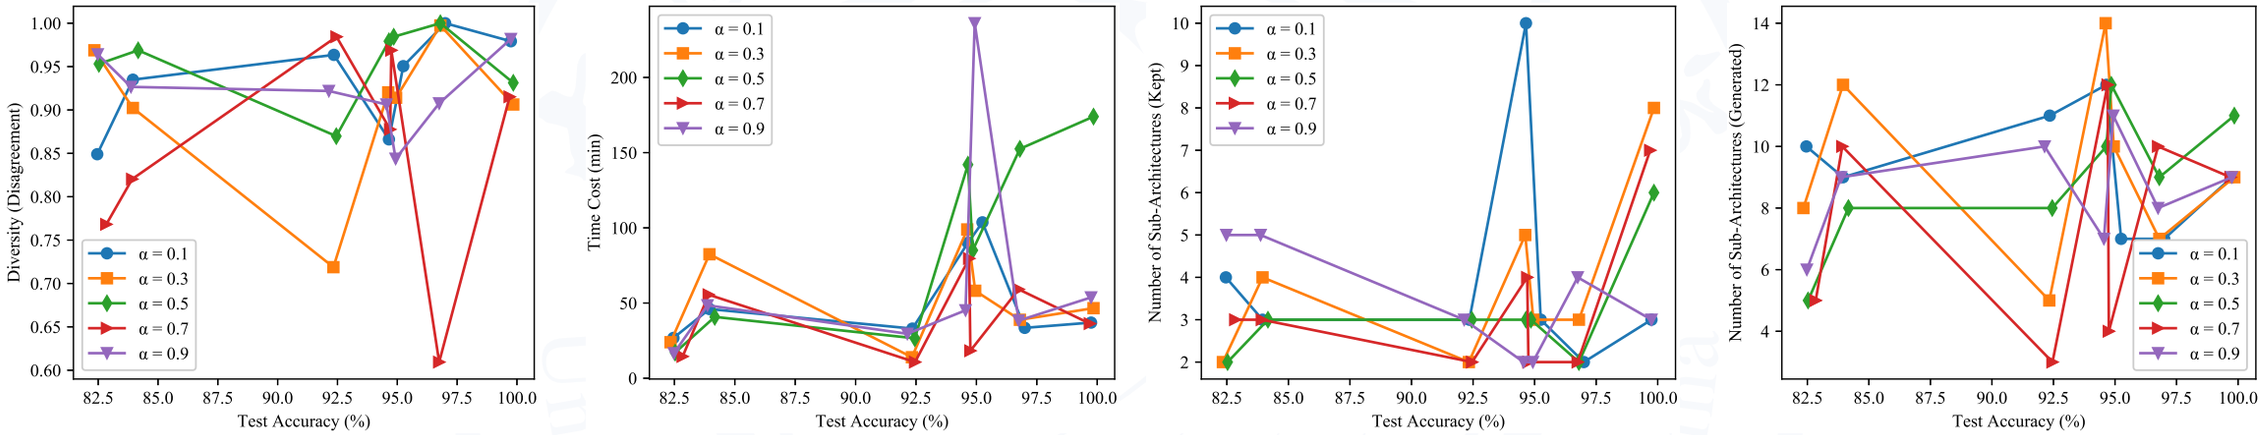


Figure 28: 在不同 α 值下由 *SAEP* 生成的子集成网络结构的性能

SAEP vs. AdaNet（时间代价）

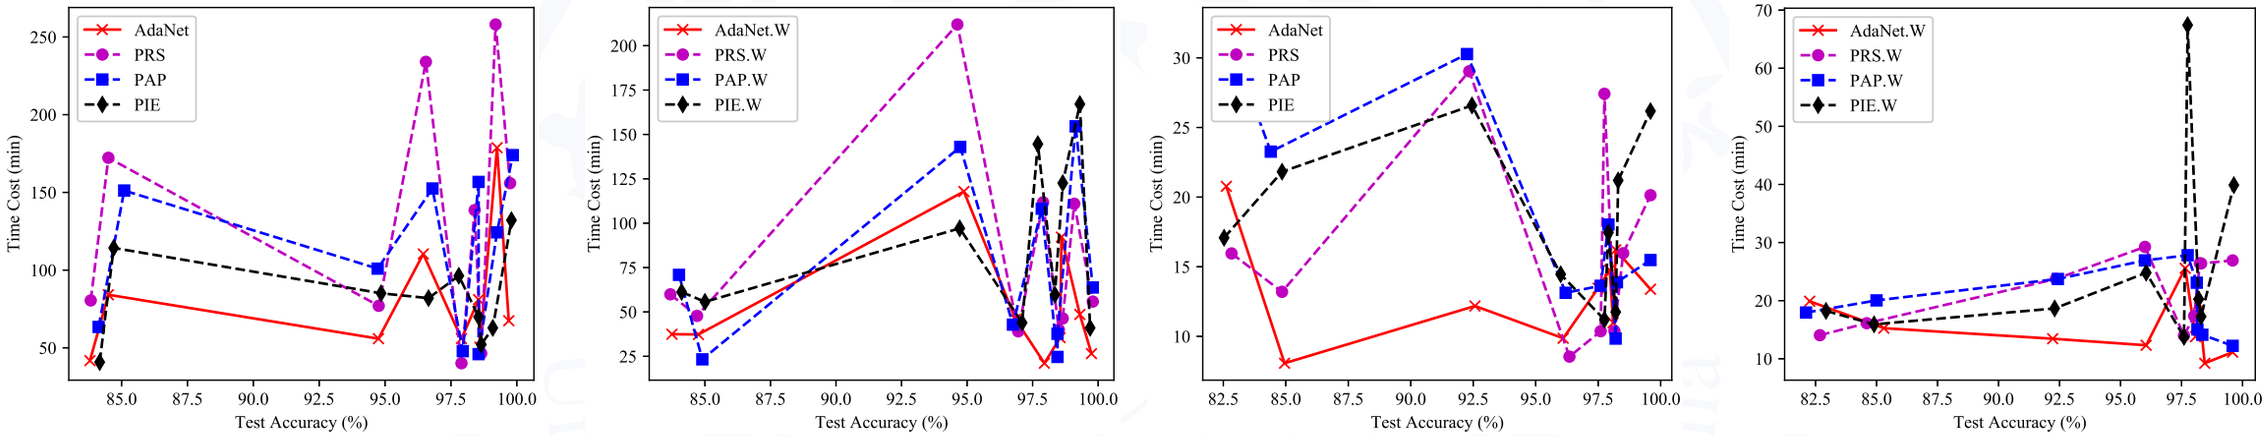


Figure 29: 图像分类任务的测试准确度和时间代价的实验结果图。注：AdaNet 与 *SAEP* 及其相应变体的性能对比，(a–b) 和 (c–d) 分别使用多层感知机/卷积神经网络来构造子网络。

谢谢！

敬请各位老师批评指正